第五章
统计量及其分布

§5.1 总体与样本

内容概要

1. 总体 在一个统计问题中,研究对象的全体称为总体,构成总体的每个成员称为个体.

若关心的是总体中每个个体的一个数量指标,则该总体称为一维总体,总体就是一个一维分布.

若关心的是总体中的每个个体的两个数量指标,则该总体称为二维总体,二维总体就是一个二维分布.以此类推.

2. 有限总体与无限总体 若总体中的个体数是有限的,此总体称为有限总体.

若总体中的个体数是无限的,此总体称为无限总体.

实际中总体中的个体数大多是有限的.当个体数充分大时,将有限总体看作无限总体是一种合理的抽象.

3. 样本 从总体中随机抽取的部分个体组成的集合称为样本,样本中的个体称为样品,样品个数称为样本容量或样本量.

样本常用 n 个指标值 $x_1,x_2,\cdots,x_n$ 表示.样本具有二重性:它可看作 n 个随机变量,又可看作其观察值,这可由上下文加以区别.

4. 分组样本 只知样本观测值所在区间,而不知具体值的样本称为分组样本.

缺点:与完全样本相比损失部分信息.

优点:在样本量较大时,用分组样本既简明扼要,又能帮助人们更好地认识总体.

5. 简单随机样本 若样本 $x_1,x_2,\cdots,x_n$ 是 n 个相互独立的具有同一分布(总体分布)的随机变量,则称该样本为简单随机样本,仍简称样本.

若总体的分布函数为 $F(x)$,则其样本的(联合)分布函数为 $\prod_{i=1}^{n}F(x_i)$;

若总体的密度函数为 $p(x)$,则其样本的(联合)密度函数为 $\prod_{i=1}^{n}p(x_i)$;

若总体的分布列为$\{p(x_i)\}$,则其样本的(联合)分布列为$\prod_{i=1}^{n} p(x_i)$.

习题与解答 5.1

1. 某地电视台想了解某电视栏目(如:每晚九点至九点半的体育节目)在该地区的收视率情况,于是委托一家市场咨询公司进行一次电话访查.

(1) 该项研究的总体是什么?

(2) 该项研究的样本是什么?

解　(1) 该项研究的总体是该地区全体电视观众;

(2) 该项研究的样本是该地区被电话访查的电视观众.

2. 某市要调查成年男子的吸烟率,特聘请50名统计专业本科生作街头随机调查,要求每位学生调查100名成年男子,问该项调查的总体和样本分别是什么,总体用什么分布描述为宜?

解　(1) 总体是该市所有成年男子(的吸烟情况);

(2) 样本是被调查的5 000名成年男子(的吸烟情况);

(3) 总体分布为二点分布$b(1,p)$,其中p为该市成年男子的吸烟率.

3. 设某厂大量生产某种产品,其不合格品率p未知,每m件产品包装为一盒.为了检查产品的质量,任意抽取n盒,查其中的不合格品数,试说明什么是总体,什么是样本,并指出样本的分布.

解　总体为该厂生产的每盒产品中的不合格品数;样本是任意抽取的n盒中每盒产品的不合格品数;

样本中每盒产品中的不合格品数为$x_1,x_2,\cdots,x_n$,因$x_i \sim b(m,p)$,$i=1,2,\cdots,n$,所以样本$(x_1,x_2,\cdots,x_n)$的分布为$\prod_{i=1}^{n}\binom{m}{x_i}p^{x_i}(1-p)^{m-x_i}=\left(\prod_{i=1}^{n}\binom{m}{x_i}\right)p^{t}(1-p)^{nm-t}$,其中$t=x_1+x_2+\cdots+x_n$.

4. 为估计鱼塘里有多少鱼,一位统计学家设计了一个方案如下:从鱼塘中打捞出一网鱼,计有n条,涂上不会被水冲刷掉的红漆后放回,一天后再从鱼塘里打捞一网,发现共有m条鱼,而涂有红漆的鱼则有k条,你能估计出鱼塘里大概有多少条鱼么?该问题的总体和样本又分别是什么呢?

解　直观上我们可以给出鱼数的估计,按照成比例的设想,我们应能估算出鱼塘里大概有nm/k条鱼,这就是我们将在第六章介绍的频率替换的思想.该问题中总体为鱼塘里所有的鱼,而样本为一天后从鱼塘里打捞出的鱼,主要观测其是否有记号.

思考:如果要提高估计精度,可作何设想?

5. 某厂生产的电容器的使用寿命服从指数分布,为了解其平均寿命,从中抽出n件产品测其实际使用寿命,试说明什么是总体,什么是样本,并指出样本的分布.

解　总体是该厂生产的电容器的寿命全体,或者可以说总体是指数分布,其分布为$Exp(\lambda)$;

样本是该厂中抽出的n个电容器的寿命;

记第 i 个电容器的寿命为 x_i，则 $x_i \sim Exp(\lambda)$，$i=1,2,\cdots,n$，样本 $(x_1,x_2,\cdots,x_n)$ 的分布为 $\prod_{i=1}^{n}\lambda e^{-\lambda x_i}=\lambda^n e^{-\lambda t}$，其中 $t=x_1+x_2+\cdots+x_n$.

6. 美国某高校根据毕业生返校情况记录，宣布该校毕业生的年平均工资为 5 万美元，你对此有何评论？

解 毕业生返校记录是全体毕业生中的一个特殊群体（子总体）的一个样本，它只能反映该子总体的特征，不能反映全体毕业生的状况，故此说法有失偏颇.

补充习题及解答

7. 设有 N 个产品，其中有 M 个不合格品.进行放回抽样.定义 x_i 如下：

$$x_i=\begin{cases}1, & \text{第 } i \text{ 次取得不合格品},\\ 0, & \text{第 } i \text{ 次取得合格品}.\end{cases}$$

求样本 $x_1,x_2,\cdots,x_n$ 的联合分布.

解 总体的分布列为

$$P(X=1)=\frac{M}{N},P(X=0)=1-\frac{M}{N},$$

也可以写成

$$P(X=x)=\left(\frac{M}{N}\right)^x\left(1-\frac{M}{N}\right)^{1-x},\quad x=0,1.$$

因此样本 $x_1,x_2,\cdots,x_n$ 的联合分布列为

$$P(x_1,x_2,\cdots,x_n)=\prod_{i=1}^{n}\left(\frac{M}{N}\right)^{x_i}\left(1-\frac{M}{N}\right)^{1-x_i}=\left(\frac{M}{N}\right)^t\left(1-\frac{M}{N}\right)^{n-t},\quad x_i=0,1,$$

其中 $t=x_1+x_2+\cdots+x_n$.

8. 设离散总体的分布列为

$$P(X=k)=\frac{1}{N},k=1,2,\cdots,N.$$

现进行不放回抽样，$x_1,x_2,\cdots,x_n$ 为样本，$\bar{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$ 为样本均值，求 $E(\bar{x})$ 与 $\mathrm{Var}(\bar{x})$（表示成 N 的函数）.

解 由于 N 有限，抽样是不放回的，所以样本 $x_1,x_2,\cdots,x_n$ 中诸 x_i 的分布列与总体的分布列相同，但诸 x_i 间不相互独立，即此样本不是简单随机样本.以下我们先求诸 x_i 的期望、方差与协方差：

$$E(x_i)=\sum_{k=1}^{N}\frac{k}{N}=\frac{1}{N}\cdot\frac{N(N+1)}{2}=\frac{N+1}{2},\qquad i=1,2,\cdots,n,$$

$$\mathrm{Var}(x_i)=E(x_i^2)-[E(x_i)]^2=\sum_{k=1}^{N}\frac{k^2}{N}-\left(\frac{N+1}{2}\right)^2$$

$$=\frac{N(N+1)(2N+1)}{6N}-\left(\frac{N+1}{2}\right)^2=\frac{N^2-1}{12},\quad i=1,2,\cdots,n,$$

$$\mathrm{Cov}(x_i,x_j)=E(x_ix_j)-E(x_i)E(x_j)=\sum_{k\neq l}^{N}\frac{k}{N}\cdot\frac{l}{N-1}-\left(\frac{N+1}{2}\right)^2,$$

其中

$$\sum_{k\neq l}^{N}kl=\left(\sum_{k=1}^{N}k\right)^2-\sum_{k=1}^{N}k^2=\frac{N^2(N+1)^2}{4}-\frac{N(N+1)(2N+1)}{6}$$
$$=\frac{N}{12}(N+1)(N-1)(3N+2),$$

代回原协方差表达式,可得

$$\mathrm{Cov}(x_i,x_j)=\frac{N(N+1)(N-1)(3N+2)}{12N(N-1)}-\frac{(N+1)^2}{4}$$
$$=-\frac{N+1}{12},i\neq j\text{ 且 }i,j=1,2,\cdots,N,$$

由此可得样本均值 $\bar{x}$ 的期望与方差

$$E(\bar{x})=\frac{1}{n}\sum_{i=1}^{n}E(x_i)=\frac{N+1}{2},$$

$$\mathrm{Var}(\bar{x})=\frac{1}{n^2}\left[\sum_{i=1}^{n}\mathrm{Var}(x_i)+\sum_{i\neq j}^{n}\mathrm{Cov}(x_i,x_j)\right]$$
$$=\frac{1}{n^2}\left[\frac{n(N^2-1)}{12}-n(n-1)\cdot\frac{N+1}{12}\right]$$
$$=\frac{1}{12n}(N+1)(N-n).$$

§5.2　样本数据的整理与显示

内容概要

1. 经验分布函数　若将样本观测值 $x_1,x_2,\cdots,x_n$ 由小到大进行排列,得有序样本 $x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(n)}$,用有序样本定义如下函数

$$F_n(x)=\begin{cases}0, & x<x_{(1)},\\ k/n, & x_{(k)}\leqslant x<x_{(k+1)},k=1,2,\cdots,n-1,\\ 1, & x\geqslant x_{(n)},\end{cases}$$

则称 $F_n(x)$ 为该样本的**经验分布函数**.

格利文科定理　设 $x_1,x_2,\cdots,x_n$ 是取自总体分布函数为$F(x)$ 的样本,$F_n(x)$ 是该样本的经验分布函数,则当 $n\to\infty$ 时,有

$$P(\sup_{-\infty<x<\infty}|F_n(x)-F(x)|\to 0)=1.$$

此定理表明:当 n 相当大时,经验分布函数 $F_n(x)$ 是总体分布函数 $F(x)$ 的一个良好的近似.它是经典统计学的一块基石.