$$\mathrm{Cov}(x_i,x_j)=E(x_ix_j)-E(x_i)E(x_j)=\sum_{k\neq l}^{N}\frac{k}{N}\cdot\frac{l}{N-1}-\left(\frac{N+1}{2}\right)^2,$$

其中

$$\sum_{k\neq l}^{N}kl=\left(\sum_{k=1}^{N}k\right)^2-\sum_{k=1}^{N}k^2=\frac{N^2(N+1)^2}{4}-\frac{N(N+1)(2N+1)}{6}$$
$$=\frac{N}{12}(N+1)(N-1)(3N+2),$$

代回原协方差表达式,可得

$$\mathrm{Cov}(x_i,x_j)=\frac{N(N+1)(N-1)(3N+2)}{12N(N-1)}-\frac{(N+1)^2}{4}$$
$$=-\frac{N+1}{12},i\neq j\text{ 且 }i,j=1,2,\cdots,N,$$

由此可得样本均值 $\bar{x}$ 的期望与方差

$$E(\bar{x})=\frac{1}{n}\sum_{i=1}^{n}E(x_i)=\frac{N+1}{2},$$

$$\mathrm{Var}(\bar{x})=\frac{1}{n^2}\left[\sum_{i=1}^{n}\mathrm{Var}(x_i)+\sum_{i\neq j}^{n}\mathrm{Cov}(x_i,x_j)\right]$$
$$=\frac{1}{n^2}\left[\frac{n(N^2-1)}{12}-n(n-1)\cdot\frac{N+1}{12}\right]$$
$$=\frac{1}{12n}(N+1)(N-n).$$

§5.2　样本数据的整理与显示

内容概要

1. 经验分布函数　若将样本观测值 $x_1,x_2,\cdots,x_n$ 由小到大进行排列,得有序样本 $x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(n)}$,用有序样本定义如下函数

$$F_n(x)=\begin{cases}0, & x<x_{(1)},\\ k/n, & x_{(k)}\leqslant x<x_{(k+1)},k=1,2,\cdots,n-1,\\ 1, & x\geqslant x_{(n)},\end{cases}$$

则称 $F_n(x)$ 为该样本的**经验分布函数**.

格利文科定理　设 $x_1,x_2,\cdots,x_n$ 是取自总体分布函数为$F(x)$ 的样本,$F_n(x)$ 是该样本的经验分布函数,则当 $n\to\infty$ 时,有

$$P(\sup_{-\infty<x<\infty}|F_n(x)-F(x)|\to 0)=1.$$

此定理表明:当 n 相当大时,经验分布函数 $F_n(x)$ 是总体分布函数 $F(x)$ 的一个良好的近似.它是经典统计学的一块基石.

2. 频数频率表　由样本数据 $x_1, x_2, \cdots, x_n$ 制作频数频率表的操作步骤如下：

- 确定组数 k；
- 确定每组组距，通常取每组组距相等为 d；
- 确定每组组限；
- 统计样本数据落入每个区间的频数，并计算频率.

综合上述，列入表中，即得该样本的频数频率表. 该表就是一个分组样本，它能简明扼要地把样本特点表述出来. 不足之处是该表依赖于分组，不同的分组方式有不同的频数频率表.

3. 样本数据的图形表示

(1) 直方图

- 利用频数频率分布表上的区间（横坐标）和频数（纵坐标）可作出频数直方图；
- 若把纵坐标改为频率就得频率直方图；
- 若把纵坐标改为频率 / 组距，就得到单位频率直方图. 这时长条矩形的面积之和为 1.

此三种直方图的差别仅在纵坐标的设置上，直方图图形本身并无变化.

(2) 茎叶图

把样本中的每个数据分为茎与叶，把茎放于一侧，叶放于另一侧，就得到一张该样本的茎叶图. 比较两个样本时，可画出背靠背的茎叶图.

茎叶图保留数据中全部信息. 当样本量较大，数据很分散，横跨二、三个数量级时，茎叶图并不适用.

习题与解答 5.2

1. 以下是某工厂通过抽样调查得到的 10 名工人一周内生产的产品数

149　156　160　138　149　153　153　169　156　156

试由这批数据构造经验分布函数并作图.

解　此样本容量为 10，经排序可得有序样本：

$$x_{(1)} = 138, x_{(2)} = x_{(3)} = 149, x_{(4)} = x_{(5)} = 153,$$
$$x_{(6)} = x_{(7)} = x_{(8)} = 156, x_{(9)} = 160, x_{(10)} = 169,$$

其经验分布函数

$$F_n(x) = \begin{cases} 0, & x < 138, \\ 0.1, & 138 \leqslant x < 149, \\ 0.3, & 149 \leqslant x < 153, \\ 0.5, & 153 \leqslant x < 156, \\ 0.8, & 156 \leqslant x < 160, \\ 0.9, & 160 \leqslant x < 169, \\ 1, & x \geqslant 169. \end{cases}$$

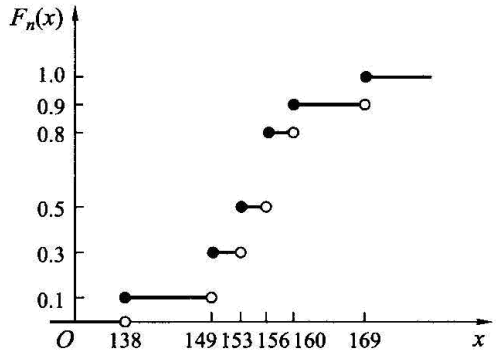

图 5.1

其图形如图 5.1 所示.

2. 下表是经过整理后得到的分组样本：

组序	1	2	3	4	5
分组区间	(38,48]	(48,58]	(58,68]	(68,78]	(78,88]
频数	3	4	8	3	2

试写出此分组样本的经验分布函数.

解　样本的经验分布函数为

$$F_n(x)=\begin{cases}0, & x<38,\\ 0.15, & 38\leqslant x<48,\\ 0.35, & 48\leqslant x<58,\\ 0.75, & 58\leqslant x<68,\\ 0.9, & 68\leqslant x<78,\\ 1, & x\geqslant 78.\end{cases}$$

3. 假若某地区 30 名 2018 年某专业毕业生实习期满后的月薪数据如下：

9 090	10 860	11 200	9 990	13 200	10 910
10 710	10 810	11 300	13 360	9 670	15 720
8 250	9 140	9 920	12 320	9 500	7 750
12 030	10 250	10 960	8 080	12 240	10 440
8 710	11 640	9 710	9 500	8 660	7 380

(1) 构造该批数据的频率分布表(分 6 组)；

(2) 画出直方图.

解　此处数据最大观测值为 15 720,最小观测值为 7 380,故组距近似为

$$d=\frac{15\ 720-7\ 380}{6}\approx 1\ 390,$$

取 $d=1\ 400$,确定每组区间端点为 $a_0, a_0+d=a_1, a_0+2d=a_2, \cdots, a_0+kd=a_k$,此处可取 $a_0=7\ 350$,于是分组区间为

(7 350,8 750],(8 750,10 150],(10 150,11 550],(11 550,12 950],(12 950,14 350],(14 350,15 750].

其频数频率表如下：

组序	分组区间	组中值	频数	频率	累计频率 /%
1	(7 350,8 750]	8 050	6	0.20	20
2	(8 750,10 150]	9 450	8	0.27	47
3	(10 150,11 550]	10 850	9	0.30	77
4	(11 550,12 950]	12 250	4	0.13	90
5	(12 950,14 350]	13 650	2	0.07	97
6	(14 350,15 750]	15 050	1	0.03	100
合计			30	1	

其直方图如图 5.2.

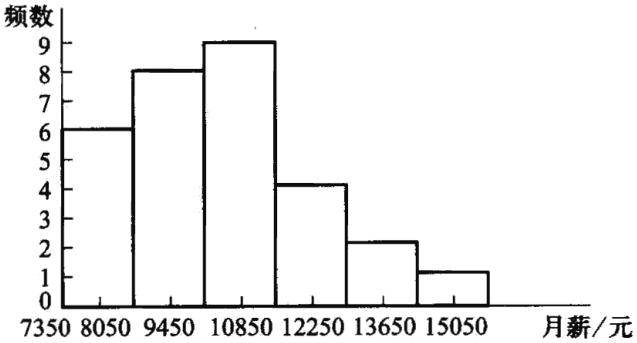

图 5.2

4. 某公司对其250名职工上班所需时间(单位:min)进行了调查,下面是其不完整的频率分布表:

所需时间	频率
0 ~ 10	0.10
10 ~ 20	0.24
20 ~ 30	
30 ~ 40	0.18
40 ~ 50	0.14

(1) 试将频率分布表补充完整;

(2) 该公司上班所需时间在半小时以内有多少人?

解 (1) 由于频率和为1,故空缺的频率为 $1-0.1-0.24-0.18-0.14=0.34$.

(2) 该公司上班所需时间在半小时以内的人所占频率为 $0.1+0.24+0.34=0.68$,该公司有职工250人,故该公司上班所需时间在半小时以内的人有 $250\times0.68=170$ 人.

5. 40种刊物的月发行量(单位:百册)如下:

5 954	5 022	14 667	6 582	6 870	1 840	2 662	4 508
1 208	3 852	618	3 008	1 268	1 978	7 963	2 048
3 077	993	353	14 263	1 714	11 127	6 926	2 047
714	5 923	6 006	14 267	1 697	13 876	4 001	2 280
1 223	12 579	13 588	7 315	4 538	13 304	1 615	8 612

(1) 建立该批数据的频数分布表,取组距为1 700(百册);

(2) 画出直方图.

解 此处数据最大观测值为14 667,最小观测值为353,由于组距为1 700,故组数为

$$k \geqslant \frac{14\,667-353}{1\,700}=8.42,$$

所以分9组.接下来确定每组区间端点,要求

$$a_0<353, a_0+9\times1\,700>14\,667$$

此处可取 $a_0=300$,于是可列出其频数频率表.

组序	分组区间	组中值	频数	频率	累计频率 /%
1	(300,2 000]	1 150	12	0.3	30
2	(2 000,3 700]	2 850	6	0.15	45
3	(3 700,5 400]	4 550	5	0.125	57.5
4	(5 400,7 100]	6 250	6	0.15	72.5
5	(7 100,8 800]	7 950	3	0.075	80
6	(8 800,10 500]	9 650	0	0	80
7	(10 500,12 200]	11 350	1	0.025	82.5
8	(12 200,13 900]	13 050	4	0.1	92.5
9	(13 900,15 600]	14 750	3	0.075	100
合计			40	1	

其直方图如图 5.3.

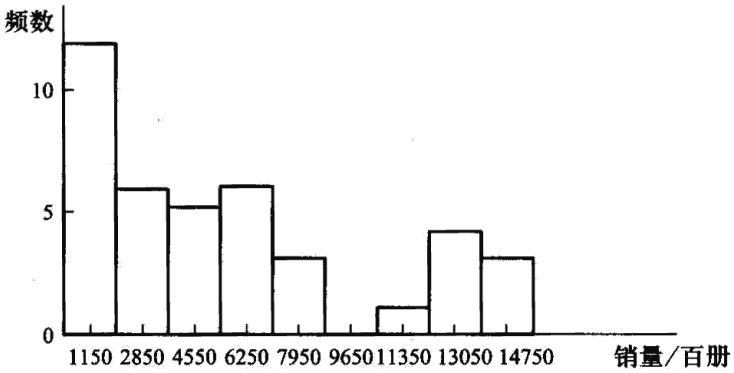

图 5.3

6. 对下列数据构造茎叶图

472	425	447	377	341	369	412	399
400	382	366	425	399	398	423	384
418	392	372	418	374	385	439	408
429	428	430	413	405	381	403	479
381	443	441	433	399	379	386	387

解　取百位数与十位数组成茎,个位数为叶,这组数据的茎叶图如下:

34	1						
35							
36	6	9					
37	2	4	7	9			
38	1	1	2	4	5	6	7
39	2	8	9	9	9		
40	0	3	5	8	9		
41	2	3	8	8			
42	3	5	5	8			
43	0	3	9				
44	1	3	7				
45	2						
46	9						

7. 根据调查,某集团公司的中层管理人员的年薪(单位:万元)数据如下:

40.6	39.6	37.8	36.2	38.8
38.6	39.6	40.0	34.7	41.7
38.9	37.9	37.0	35.1	36.7
37.1	37.7	39.2	36.9	38.3

试画出茎叶图.

解 取整数部分为茎,小数部分为叶,这组数据的茎叶图如下:

34	7				
35	1				
36	2	7	9		
37	0	1	7	8	9
38	3	6	8	9	
39	2	6	6		
40	0	6			
41	7				

补充习题及解答

8. 设总体 X 的分布函数为 $F(x)$,经验分布函数为 $F_n(x)$,试证

$$E[F_n(x)] = F(x), \mathrm{Var}[F_n(x)] = \frac{1}{n}F(x)[1 - F(x)].$$

证 设 $x_1, x_2, \cdots, x_n$ 是取自总体分布函数为 $F(x)$ 的样本,则经验分布函数为

$$F_n(x) = \begin{cases} 0, & 当\ x < x_{(1)}, \\ k/n, & 当\ x_{(k)} \leqslant x < x_{(k+1)}, k = 1, 2, \cdots, n-1, \\ 1, & 当\ x \geqslant x_{(n)}. \end{cases}$$

若令 $y_i = I_{\{X_i \leqslant x\}}, i = 1, 2, \cdots, n$,则 $y_1, y_2, \cdots, y_n$ 是独立同分布的随机变量,且

$$E(y_1) = P(X_1 \leqslant x) = F(x), E(y_1^2) = P(X_1 \leqslant x) = F(x),$$

于是

$$\mathrm{Var}(y_1) = F(x) - [F(x)]^2 = F(x)[1 - F(x)].$$

又 $F_n(x)$ 可写为 $F_n(x) = \frac{1}{n}\sum_{i=1}^{n} y_i$,故有

$$E[F_n(x)] = E(y_1) = F(x), \mathrm{Var}[F_n(x)] = \frac{1}{n}\mathrm{Var}(y_1) = \frac{1}{n}F(x)[1 - F(x)].$$

§5.3　统计量及其分布

内容概要

1. 统计量　不含未知参数的样本函数称为统计量.统计量的分布称为抽样分布.

2. 样本均值　样本 $x_1,x_2,\cdots,x_n$ 的算术平均值称为样本均值,记为 $\bar{x}$.

分组样本均值:$\bar{x}=\frac{1}{n}\sum_{i=1}^{k}x_if_i$,其中 n 为样本量,k 为组数,x_i 与 f_i 为第 i 组的组中值与频数,分组样本均值是完全样本均值的一种较好的近似.

样本均值是样本的位置特征,样本中大多数值位于 $\bar{x}$ 左右.平均可消除一些随机干扰,等价交换也是在平均数中实现的.

样本均值的性质:

(1) $\sum_{i=1}^{n}(x_i-\bar{x})=0$,样本数据 x_i 对样本均值 $\bar{x}$ 的偏差之和为零;

(2) 样本数据 x_i 与样本均值 $\bar{x}$ 的偏差平方和最小,即对任意的实数 c 有

$$\sum_{i=1}^{n}(x_i-\bar{x})^2\leqslant\sum_{i=1}^{n}(x_i-c)^2$$

(3) 若总体分布为 $N(\mu,\sigma^2)$,则 $\bar{x}$ 的**精确分布**为 $N(\mu,\sigma^2/n)$;

(4) 若总体分布未知,但其期望 μ 与方差 σ^2 存在,则当 n 较大时,$\bar{x}$ 的**渐近分布**为 $N(\mu,\sigma^2/n)$.

3. 样本方差与样本标准差　样本方差有两个,样本方差 s_n^2 与样本无偏方差 s^2

$$s_n^2=\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2,\qquad s^2=\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2.$$

实际中常用的是无偏样本方差 s^2,这是因为:当 σ^2 为总体方差时,总有

$$E(s_n^2)=\frac{n-1}{n}\sigma^2,\qquad E(s^2)=\sigma^2.$$

这表明:s_n^2 系统偏小而 s^2 无此系统偏差.今后称 s^2 为样本方差.$s=\sqrt{s^2}$ 为样本标准差.

样本方差是样本的散布特征,s^2 愈大样本愈分散,s^2 愈小样本愈集中,样本标准差 s 与样本均值 $\bar{x}$ 有相同单位,s 使用更频繁,但 s 的计算必须通过 s^2 才能获得.

s^2 的计算有如下三个公式可供选用:

$$s^2=\frac{1}{n-1}\sum(x_i-\bar{x})^2=\frac{1}{n-1}\left[\sum x_i^2-\frac{(\sum x_i)^2}{n}\right]=\frac{1}{n-1}(\sum x_i^2-n\bar{x}^2).$$

在分组样本场合,样本方差可如下计算

$$s^2=\frac{1}{n-1}\sum_{i=1}^{k}f_i(x_i-\bar{x})^2=\frac{1}{n-1}\left(\sum_{i=1}^{k}f_ix_i^2-n\bar{x}^2\right),$$