$$E(X)=\sum_{k=1}^{\infty}kP(X=k)=-\frac{1}{\ln(1-p)}\sum_{k=1}^{\infty}p^k=-\frac{p}{(1-p)\ln(1-p)},$$

$$E(X^2)=\sum_{k=1}^{\infty}k^2P(X=k)=-\frac{1}{\ln(1-p)}\sum_{k=1}^{\infty}kp^k=-\frac{p}{(1-p)^2\ln(1-p)},$$

因此有 $1-p=\frac{E(X)}{E(X^2)}$,从而得到 p 的一个矩估计 $\hat{p}=1-\frac{\sum x_i}{\sum x_i^2}$.

9. 设 $x_1,x_2,\cdots,x_n$ 独立同分布;$E(x_1)=\mu$,$\mathrm{Var}(x_1)<\infty$,证明:$\hat{\mu}=\frac{2}{n(n+1)}\sum_{i=1}^{n}ix_i$ 是 μ 的相合估计.

证　由于

$$E(\hat{\mu})=\frac{2\mu}{n(n+1)}\cdot\sum_{i=1}^{n}i=\frac{2\mu}{n(n+1)}\cdot\frac{n(n+1)}{2}=\mu,$$

$$\mathrm{Var}(\hat{\mu})=\frac{4\mathrm{Var}(x_1)}{n^2(n+1)^2}\cdot\sum_{i=1}^{n}i^2=\frac{4\mathrm{Var}(x_1)}{n^2(n+1)^2}\cdot\frac{n(n+1)(2n+1)}{6}\to 0(n\to\infty),$$

这就证明了 $\hat{\mu}=\frac{2}{n(n+1)}\sum_{i=1}^{n}ix_i$ 是 μ 的相合估计.

§6.3　最大似然估计与 EM 算法

内容概要

1. 最大似然估计　利用"最大似然原理"获得的估计,它只能在总体概率函数形式已知的情况下使用,具体步骤如下:设总体的概率函数为 $p(x;\theta)$,$\theta\in\Theta$,$x_1,x_2,\cdots,x_n$ 是来自该总体的样本.

- 写出似然函数 $L(\theta)=L(\theta;x_1,x_2,\cdots,x_n)=p(x_1;\theta)p(x_2;\theta)\cdots p(x_n;\theta)$;
- 使似然函数 $L(\theta)$ 达到最大的统计量 $\hat{\theta}=\hat{\theta}(x_1,x_2,\cdots,x_n)$ 称为 θ 的最大似然估计,简称 MLE,即 $\hat{\theta}$ 满足 $L(\hat{\theta})=\max\limits_{\theta\in\Theta}L(\theta)$.

注意:使得对数似然函数 $\ln L(\theta)$ 最大的 $\hat{\theta}$ 也使似然函数 $L(\theta)$ 最大,寻找最大值可以从定义出发,也可以对 $l(\theta)=\ln L(\theta)$ 使用微分法,后者更为常用.

2. 最大似然估计的不变性　若 $\hat{\theta}$ 是 θ 的最大似然估计,则对任一函数 $g(\theta)$,$g(\hat{\theta})$ 是其最大似然估计.

3. EM 算法　当分布中有多余参数或数据为截尾或缺失时,其 MLE 的求取是比较困难的.Dempster 等人于 1977 年提出了 EM 算法,其出发点是把求 MLE 的过程分两步走,第一步求期望(E 步),以便把多余的部分去掉,第二步求极大值(M 步).重复使用这两步直至收敛可得 MLE 的近似解.这是一种非常有效的方法.

4. MLE 的渐近正态性　在很一般条件下,总体分布 $p(x;\theta)$ 中 θ 的 MLE $\hat{\theta}_n$ 具有

相合性和渐近正态性，即 $\hat{\theta}_n \sim AN\left(\theta, \frac{1}{nI(\theta)}\right)$，其中 n 为样本容量，$I(\theta) = \int_{-\infty}^{\infty}\left(\frac{\partial \ln p}{\partial \theta}\right)^2 p(x;\theta)\mathrm{d}x$ 为费希尔信息量.

习题与解答 6.3

1. 设总体概率函数如下，$x_1, x_2, \cdots, x_n$ 是样本，试求未知参数的最大似然估计：

(1) $p(x;\theta) = \sqrt{\theta}x^{\sqrt{\theta}-1}, 0 < x < 1, \theta > 0$;

(2) $p(x;\theta) = \theta c^{\theta} x^{-(\theta+1)}, x > c, c > 0$ 已知，$\theta > 1$.

解 (1) 似然函数为 $L(\theta) = (\sqrt{\theta})^n (x_1 x_2 \cdots x_n)^{\sqrt{\theta}-1}$，其对数似然函数为

$$\ln L(\theta) = \frac{n}{2}\ln\theta + (\sqrt{\theta} - 1)(\ln x_1 + \ln x_2 + \cdots + \ln x_n).$$

将 $\ln L(\theta)$ 关于 θ 求导并令其为 0 即得到似然方程

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{n}{2\theta} + (\ln x_1 + \ln x_2 + \cdots + \ln x_n)\frac{1}{2\sqrt{\theta}} = 0.$$

解之得

$$\hat{\theta} = \left(\frac{1}{n}\sum_{i=1}^{n}\ln x_i\right)^{-2}.$$

由于

$$\left.\frac{\partial^2 \ln L(\theta)}{\partial \theta^2}\right|_{\hat{\theta}} = \left.\left(-\frac{n}{2\theta^2} - \frac{\sum \ln x_i}{4\theta^{3/2}}\right)\right|_{\hat{\theta}} = -\frac{3(\sum \ln x_i)^4}{4n^3} < 0,$$

所以 $\hat{\theta}$ 是 θ 的最大似然估计.

(2) 似然函数为 $L(\theta) = \theta^n c^{n\theta}(x_1 x_2 \cdots x_n)^{-(\theta+1)}$，其对数似然函数为

$$\ln L(\theta) = n\ln\theta + n\theta\ln c - (\theta + 1)(\ln x_1 + \ln x_2 + \cdots + \ln x_n).$$

将 $\ln L(\theta)$ 关于 θ 求导并令其为 0 得到似然方程

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{n}{\theta} + n\ln c - (\ln x_1 + \ln x_2 + \cdots + \ln x_n) = 0,$$

解之可得

$$\hat{\theta} = \left(\frac{1}{n}\sum_{i=1}^{n}\ln x_i - \ln c\right)^{-1}.$$

由于 $\frac{\partial^2 \ln L(\theta)}{\partial \theta^2} = \frac{-n}{\theta^2} < 0$，这说明 $\hat{\theta}$ 是 θ 的最大似然估计.

2. 设总体概率函数如下，$x_1, x_2, \cdots, x_n$ 是样本，试求未知参数的最大似然估计：

(1) $p(x;\theta) = c\theta^c x^{-(c+1)}, x > \theta, \theta > 0, c > 0$ 已知；

(2) $p(x;\theta,\mu) = \frac{1}{\theta}\mathrm{e}^{-\frac{x-\mu}{\theta}}, x > \mu, \theta > 0$;

(3) $p(x;\theta) = (k\theta)^{-1}, \theta < x < (k+1)\theta, \theta > 0, k > 0$ 已知.

解　(1) 样本 $x_1,x_2,\cdots,x_n$ 的似然函数为

$$L(\theta)=c^n\theta^{nc}(x_1x_2\cdots x_n)^{-(c+1)}I_{\{x_{(1)}>\theta\}}.$$

要使 $L(\theta)$ 达到最大,首先示性函数应为 1,其次是 θ^{nc} 尽可能大.由于 $c>0$,故 θ^{nc} 是 θ 的单调增函数,所以 θ 的取值应尽可能大,但示性函数的存在决定了 θ 的取值不能大于 $x_{(1)}$,由此给出 θ 的最大似然估计为 $x_{(1)}$.

(2) 此处的似然函数为

$$L(\theta)=\left(\frac{1}{\theta}\right)^n\exp\left\{-\frac{1}{\theta}\sum_{i=1}^n(x_i-\mu)\right\},\qquad x_{(1)}>\mu.$$

其对数似然函数为

$$\ln L(\theta,\mu)=-n\ln\theta-\frac{\sum_{i=1}^n(x_i-\mu)}{\theta}.$$

由上式可以看出,$\ln L(\theta,\mu)$ 是 μ 的单调增函数,要使其最大,μ 的取值应该尽可能的大,由于限制 $\mu<x_{(1)}$,这给出 μ 的最大似然估计为 $\hat{\mu}=x_{(1)}$.

将 $\ln L(\theta,\hat{\mu})$ 关于 θ 求导并令其为 0 得到关于 θ 的似然方程

$$\frac{\partial\ln L(\theta,\hat{\mu})}{\partial\theta}=-\frac{n}{\theta}+\frac{\sum_{i=1}^n(x_i-\hat{\mu})}{\theta^2}=0,$$

解之

$$\hat{\theta}=\frac{\sum_{i=1}^n(x_i-\hat{\mu})}{n}=\bar{x}-x_{(1)}.$$

(3) 样本 $x_1,x_2\cdots,x_n$ 的似然函数为

$$L(\theta)=\left(\frac{1}{k\theta}\right)^nI_{\{\theta<x_{(1)}\leqslant x_{(n)}<(k+1)\theta\}}.$$

由于 $L(\theta)$ 的主体 $\left(\frac{1}{k\theta}\right)^n$ 是关于 θ 的单调递减函数,要使 $L(\theta)$ 达到最大,θ 应尽可能小,但由限制 $\theta<x_{(1)}\leqslant x_{(n)}<(k+1)\theta$ 可以得到 $\frac{x_{(n)}}{k+1}<\theta<x_{(1)}$,这说明 θ 不能小于 $\frac{x_{(n)}}{k+1}$,因而 θ 的最大似然估计为 $\hat{\theta}=\frac{x_{(n)}}{k+1}$.

3. 设总体概率函数如下,$x_1,x_2,\cdots,x_n$ 是样本,试求未知参数的最大似然估计:

(1) $p(x;\theta)=\frac{1}{2\theta}e^{-|x|/\theta},\theta>0$;

(2) $p(x;\theta)=1,\theta-\frac{1}{2}<x<\theta+\frac{1}{2}$;

(3) $p(x;\theta_1,\theta_2)=\frac{1}{\theta_2-\theta_1},\theta_1<x<\theta_2$.

解　(1) 不难写出似然函数为

$$L(\theta)=\left(\frac{1}{2\theta}\right)^{n}\mathrm{e}^{-\frac{\sum_{i=1}^{n}|x_i|}{\theta}},$$

对数似然函数为

$$\ln L(\theta)=-n\ln 2\theta-\frac{\sum_{i=1}^{n}|x_i|}{\theta}.$$

将之关于 θ 求导并令其为 0 得到似然方程

$$\frac{\partial\ln L(\theta)}{\partial\theta}=\frac{-n}{\theta}+\frac{\sum_{i=1}^{n}|x_i|}{\theta^2}=0,$$

解之可得

$$\hat{\theta}=\frac{\sum_{i=1}^{n}|x_i|}{n}.$$

而

$$\left.\frac{\partial^2\ln L(\theta)}{\partial\theta^2}\right|_{\hat{\theta}}=\left.\left(\frac{n}{\theta^2}-\frac{2\sum|x_i|}{\theta^3}\right)\right|_{\hat{\theta}}=-\frac{n^3}{(\sum|x_i|)^2}<0,$$

故 $\hat{\theta}$ 是 θ 的最大似然估计.

(2) 此处的似然函数为

$$L(\theta)=I_{\left\{\theta-\frac{1}{2}<x_{(1)}\leqslant x_{(n)}<\theta+\frac{1}{2}\right\}}.$$

它只有两个取值 0 和 1,为使得似然函数取 1,θ 的取值范围应是 $x_{(n)}-\frac{1}{2}<\theta<x_{(1)}+\frac{1}{2}$,因而 θ 的最大似然估计 $\hat{\theta}$ 可取 $\left(x_{(n)}-\frac{1}{2},x_{(1)}+\frac{1}{2}\right)$ 中的任意值.这说明 MLE 可能不止一个.

(3) 由条件,似然函数为

$$L(\theta)=\frac{1}{(\theta_2-\theta_1)^n}I_{\{\theta_1<x_{(1)}\leqslant x_{(n)}<\theta_2\}}.$$

要使 $L(\theta)$ 尽量大,首先示性函数应为 1,这说明 $\theta_1<x_{(1)}\leqslant x_{(n)}<\theta_2$;其次 $\theta_2-\theta_1$ 要尽量小,综上可知,θ_1 的最大似然估计应为 $x_{(1)}$,θ_2 的最大似然估计应为 $x_{(n)}$.

4. 一地质学家为研究密歇根湖的湖滩地区的岩石成分,随机地自该地区取 100 个样品,每个样品有 10 块石子,记录了每个样品中属石灰石的石子数.假设这 100 次观察相互独立,求这地区石子中石灰石的比例 p 的最大似然估计.该地质学家所得的数据如下:

样本中的石子数	0	1	2	3	4	5	6	7	8	9	10
样品个数	0	1	6	7	23	26	21	12	3	1	0

解 本题中,总体 X 为样品中石灰石的个数,且 X 服从参数为 $(10,p)$ 的二项分

布，即

$$p(X=x)=\binom{10}{x}p^x(1-p)^{10-x}.$$

$x_1,x_2,\cdots,x_{100}$ 为样本，则其似然函数为（忽略常数）

$$L(p)=p^{\sum_{i=1}^{100}x_i}(1-p)^{10\times 100-\sum_{i=1}^{100}x_i},$$

对数似然函数为

$$\ln L(p)=\sum_{i=1}^{100}x_i\ln p+(10\times 100-\sum_{i=1}^{100}x_i)\ln(1-p).$$

将对数似然函数关于 p 求导并令其为 0 得到似然方程

$$\frac{\partial\ln L(p)}{\partial p}=\frac{\sum_{i=1}^{100}x_i}{p}-\frac{10\times 100-\sum_{i=1}^{100}x_i}{1-p}=0,$$

解之得

$$\hat{p}=\frac{\sum_{i=1}^{100}x_i}{1\ 000}.$$

由于

$$\frac{\partial^2\ln L(p)}{\partial p^2}=-\frac{\sum_{i=1}^{100}x_i}{p^2}-\frac{1\ 000-\sum_{i=1}^{100}x_i}{(1-p)^2}<0,$$

由二阶导数的性质知，p 的最大似然估计为

$$\hat{p}=\frac{\sum_{i=1}^{100}x_i}{1\ 000}=\frac{499}{1\ 000}=0.499.$$

5. 在遗传学研究中经常要从截尾二项分布中抽样，其总体概率函数为

$$P(X=k;p)=\frac{\binom{m}{k}p^k(1-p)^{m-k}}{1-(1-p)^m},\qquad k=1,2,\cdots,m.$$

若已知 $m=2,x_1,x_2,\cdots,x_n$ 是样本，试求 p 的最大似然估计.

解　当 $m=2$ 时，该截尾二项分布只能取 1 与 2，不妨设 $x_1,x_2,\cdots,x_n$ 的样本中有 n_1 个 x_i 为 1，有 $n-n_1$ 个 x_i 为 2，则其似然函数为（忽略常数）

$$L(p)=\frac{p^{n_1}(1-p)^{n_1}p^{2(n-n_1)}}{(1-(1-p)^2)^n}=\frac{p^{2n-n_1}(1-p)^{n_1}}{(1-(1-p)^2)^n}=\frac{p^{n-n_1}(1-p)^{n_1}}{(2-p)^n},$$

对数似然函数为

$$\ln L(p)=(n-n_1)\ln p+n_1\ln(1-p)-n\ln(2-p).$$

将对数似然函数关于 p 求导并令其为 0 得到似然方程

$$\frac{n-n_1}{p}-\frac{n_1}{1-p}+\frac{n}{2-p}=0,$$

解之得

$$\hat{p}=\frac{2(n-n_1)}{2n-n_1}=\frac{2(\bar{x}-1)}{\bar{x}}.$$

后一个等式是由于 $\sum_{i=1}^{n} x_i = n_1 + 2(n-n_1) = n\bar{x}$,所以 $n_1 = 2n - n\bar{x}$,代入上式即得.

6. 已知在文学家萧伯纳的"*The Intelligent Woman's Guide To Socialism and Capitalism*"一书中,一个句子的单词数 X 近似地服从对数正态分布,即 $Z = \ln X \sim N(\mu,\sigma^2)$.今从该书中随机地取 20 个句子,这些句子中的单词数分别为

52	24	15	67	15	22	63	26	16	32
7	33	28	14	7	29	10	6	59	30

求该书中一个句子单词数均值 $E(X) = e^{\mu+\sigma^2/2}$ 的最大似然估计.

解 正态分布 $N(\mu,\sigma^2)$ 的参数的最大似然估计分别为样本均值和方差.即

$$\hat{\mu}=\frac{1}{20}\sum_{i=1}^{20}\ln x_i = 3.0890,\quad \hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(\ln x_i - 3.0890)^2 = 0.5081.$$

由于最大似然估计具有不变性,因而 $E(X) = e^{\mu+\sigma^2/2}$ 的最大似然估计为

$$\widehat{E(X)} = e^{3.0890+0.5081/2} = 28.3053.$$

7. 总体 $X \sim U(\theta,2\theta)$,其中 $\theta > 0$ 是未知参数,$x_1,x_2,\cdots,x_n$ 为取自该总体的样本,$\bar{x}$ 为样本均值.

(1) 证明 $\hat{\theta}=\frac{2}{3}\bar{x}$ 是参数 θ 的无偏估计和相合估计;

(2) 求 θ 的最大似然估计,它是无偏估计吗?是相合估计吗?

解 (1) 总体 $X \sim U(\theta,2\theta)$,则 $E(X)=\frac{3\theta}{2}$, $\mathrm{Var}(X)=\frac{\theta^2}{12}$,从而

$$E(\bar{x})=\frac{3\theta}{2},\quad \mathrm{Var}(\bar{x})=\frac{\theta^2}{12n}.$$

于是 $E(\hat{\theta})=\frac{2}{3}E(\bar{x})=\theta$,这说明 $\hat{\theta}=\frac{2}{3}\bar{x}$ 是参数 θ 的无偏估计.进一步,

$$\mathrm{Var}(\hat{\theta})=\frac{4}{9}\times\frac{\theta^2}{12n}=\frac{\theta^2}{27n}\to 0.$$

这就证明了 $\hat{\theta}$ 也是 θ 的相合估计.

(2) 似然函数为 $L(\theta)=\left(\frac{1}{\theta}\right)^n I_{\{\theta<x_{(1)}\leqslant x_{(n)}<2\theta\}}$,显然 $L(\theta)$ 是 θ 的减函数,且 θ 的取值范围为 $\frac{x_{(n)}}{2}<\theta<x_{(1)}$,因而 θ 的最大似然估计为

$$\hat{\theta}=\frac{x_{(n)}}{2}.$$

下求 $\hat{\theta}$ 的均值与方差,由于 $x_{(n)}$ 的密度函数为

$$f(x)=n\left(\frac{x-\theta}{\theta}\right)^{n-1}\cdot\frac{1}{\theta}=\frac{n}{\theta^n}(x-\theta)^{n-1},\qquad \theta<x<2\theta,$$

故

$$E(x_{(n)})=\int_{\theta}^{2\theta}x\frac{n}{\theta^n}(x-\theta)^{n-1}\mathrm{d}x=\frac{n}{\theta^n}\int_0^{\theta}(t+\theta)t^{n-1}\mathrm{d}t=\frac{2n+1}{n+1}\theta,$$

$$E(x_{(n)}^2)=\int_{\theta}^{2\theta}x^2\frac{n}{\theta^n}(x-\theta)^{n-1}\mathrm{d}x=\frac{4n^2+8n+2}{(n+2)(n+1)}\theta^2,$$

$$\mathrm{Var}(x_{(n)})=\frac{n\theta^2}{(n+2)(n+1)^2},$$

从而

$$E(\hat{\theta})=\frac{1}{2}E(x_{(n)})=\frac{2n+1}{2(n+1)}\theta\to\theta\quad(n\to\infty),$$

这说明 $\hat{\theta}$ 不是 θ 的无偏估计,而是 θ 的渐近无偏估计.又

$$\mathrm{Var}(\hat{\theta})=\frac{1}{4}\mathrm{Var}(x_{(n)})=\frac{n\theta^2}{4(n+1)^2(n+2)}\to 0\quad(n\to\infty),$$

因而 $\hat{\theta}$ 是 θ 的相合估计.

8. 设 $x_1,x_2,\cdots,x_n$ 是来自密度函数为 $p(x;\theta)=\mathrm{e}^{-(x-\theta)},x>\theta$ 的总体的样本,

(1) 求 θ 的最大似然估计 $\hat{\theta}_1$,它是否是相合估计?是否是无偏估计?

(2) 求 θ 的矩估计 $\hat{\theta}_2$,它是否是相合估计?是否是无偏估计?

解　(1) 似然函数为

$$L(\theta)=\prod_{i=1}^{n}\{\mathrm{e}^{-(x_i-\theta)}I_{\{x_i>\theta\}}\}=\exp\Big\{-\sum_{i=1}^{n}x_i+n\theta\Big\}I_{\{x_{(1)}>\theta\}}.$$

显然 $L(\theta)$ 在示性函数为 1 的条件下是 θ 的严增函数,因此 θ 的最大似然估计为 $\hat{\theta}_1=x_{(1)}$.

又 $x_{(1)}$ 的密度函数为 $f(x)=n\mathrm{e}^{-n(x-\theta)},x>\theta$,故

$$E(\hat{\theta}_1)=\int_{\theta}^{\infty}xn\mathrm{e}^{-n(x-\theta)}\mathrm{d}x=\int_0^{\infty}(t+\theta)n\mathrm{e}^{-nt}\mathrm{d}t=\frac{1}{n}+\theta,$$

故 $\hat{\theta}_1$ 不是 θ 的无偏估计,但是 θ 的渐近无偏估计.由于 $E(\hat{\theta}_1)\to\theta(n\to\infty)$ 且

$$E(\hat{\theta}_1^2)=\int_{\theta}^{\infty}x^2n\mathrm{e}^{-n(x-\theta)}\mathrm{d}x=\int_0^{\infty}(t^2+2\theta t+\theta^2)n\mathrm{e}^{-nt}\mathrm{d}t=\frac{2}{n^2}+\frac{2}{n}\theta+\theta^2,$$

$$\mathrm{Var}(\hat{\theta}_1)=\frac{2}{n^2}+\frac{2\theta}{n}+\theta^2-\left(\frac{1}{n}+\theta\right)^2=\frac{1}{n^2}\to 0,$$

这说明 $\hat{\theta}_1$ 是 θ 的相合估计.

(2) 由于 $E(X)=\int_{\theta}^{\infty}x\mathrm{e}^{-(x-\theta)}\mathrm{d}x=\theta+1$,这给出 $\theta=E(X)-1$,所以 θ 的矩估计为

$$\hat{\theta}_2=\bar{x}-1.$$

又 $E(X^2)=\int_{\theta}^{\infty}x^2\mathrm{e}^{-(x-\theta)}\mathrm{d}x=\theta^2+2\theta+2$,所以 $\mathrm{Var}(X)=1$,从而有

$$E(\hat{\theta}_2)=E(\bar{x})-1=\theta,\quad \mathrm{Var}(\hat{\theta}_2)=\frac{1}{n}\mathrm{Var}(X)=\frac{1}{n}\to 0\quad(n\to\infty),$$

这说明 $\hat{\theta}_2$ 既是 θ 的无偏估计,也是相合估计.

9. 为了估计湖中有多少条鱼,从中捞出 1 000 条,标上记号后放回湖中,然后再捞出150条鱼发现其中有10条鱼有记号.问湖中有多少条鱼,才能使150条鱼中出现10条带记号的鱼的概率最大?

解 设第二次捞出的标有记号的鱼的数目为 X,则 X 服从超几何分布,150 条鱼中出现 10 条带记号的鱼的概率

$$P(X=10)=\frac{\binom{1\,000}{10}\binom{N-1\,000}{140}}{\binom{N}{150}},$$

其中 N 表示湖中的鱼的条数,是未知参数.似然函数为

$$L(N;10)=\frac{\binom{1\,000}{10}\binom{N-1\,000}{140}}{\binom{N}{150}},$$

考察相邻两项比值

$$\begin{aligned}A(N,10)&=\frac{L(N;10)}{L(N-1;10)}=\frac{(N-1\,000)(N-150)}{N(N-1\,000-140)}\\&=\frac{N^2-1\,150N+150\,000}{N^2-1\,150N+10N},\end{aligned}$$

当且仅当 $N<15\,000$ 时,$A(N,10)>1$;当且仅当 $N>15\,000$ 时,$A(N,10)<1$,因此,只有在 $N=15\,000$ 时,$L(N;10)$ 达到最大.这里的 $N=15\,000$ 即为湖中鱼数的最大似然估计.

10. 证明:对正态分布 $N(\mu,\sigma^2)$,若只有一个观测值,则 σ^2 的最大似然估计不存在.

证 在只有一个观测值场合,对数似然函数为

$$l(\mu,\sigma^2;x)=-\ln(\sqrt{2\pi}\sigma)-\frac{(x-\mu)^2}{2\sigma^2}.$$

该函数在 $\sigma\to 0$ 时趋于 ∞,这说明该函数没有最大值,或者说极大值无法实现,从而 σ^2 的最大似然估计不存在.

补充习题及解答

11. 若总体 X 服从如下柯西分布:

$$p(x)=\frac{1}{\pi[1+(x-\mu)^2]},\ -\infty<x<\infty,$$

而 $x_1,x_2,\cdots,x_n$ 是它的一个样本,试求 μ 的估计量.

解 由于柯西分布的数学期望不存在,因此不能用一阶矩法估计得到 μ 的估计量.但注意到,μ 是该总体分布的中位数,因此,若用替换原理,可以给出 μ 的一个矩估计为 $\hat{\mu}=m_{0.5}$.

若用最小二乘法(见第八章),即使$\sum_{i=1}^{n}(x_i-\mu)^2=$最小,则得$\hat{\mu}=\bar{x}$,很难说$\bar{x}$是$\mu$的一个合适的估计量,因为这时无偏性、有效性都失去意义,而且$\bar{x}$与x_1同分布(读者自行验证),说明$\bar{x}$也没有起到汇集μ的信息的作用,因而,这个估计量的相合性也就无从谈起.

我们转而讨论μ的最大似然估计.其似然函数为

$$L(\mu)=\prod_{i=1}^{n}\frac{1}{\pi[1+(x_i-\mu)^2]},$$

其对数似然函数为

$$\ln L(\mu)=-n\ln\pi-\sum_{i=1}^{n}\ln(1+(x_i-\mu)^2),$$

对μ求导并令其为0可得对数似然方程为

$$\sum_{i=1}^{n}\frac{x_i-\mu}{1+(x_i-\mu)^2}=0.$$

这个方程只能求数值解,比如用牛顿迭代法.由于μ是总体分布的中位数,因此可以用样本中位数$m_{0.5}$作为迭代的初值,所求得的这个数值解即为μ的最大似然估计.从似然角度看,该方法得到的估计要比样本中位数估计更好些.

12. 一个罐子里装有黑球和白球,有放回地抽取一个容量为n的样本,其中有k个白球,求罐子里黑球数和白球数之比R的最大似然估计.

解　解法一　记p为罐子中白球的比例,令x_i表示第i次有放回抽样所得的白球数,则$x_i\sim b(1,p)$,$i=1,2,\cdots,n$,故p的最大似然估计为$\hat{p}=\bar{x}$.

因为黑球数与白球数比值$R=\frac{n(1-p)}{np}=\frac{1-p}{p}$,根据最大似然估计的不变性,有

$$\hat{R}=\frac{1-\hat{p}}{\hat{p}}=\frac{1-\bar{x}}{\bar{x}}.$$

对具体的样本值,即n个中抽到k个白球来讲,R的最大似然估计为$\hat{R}=\frac{n-k}{k}$.

解法二　设罐子里有白球l个,则有黑球Rl个,从而罐中共有$(1+R)l$个球.从中有放回地抽一个球为白球的概率为

$$\frac{l}{(1+R)l}=\frac{1}{1+R}.$$

从罐中有放回地抽n个球,可视为从二点分布

x	0(黑球)	1(白球)
p	$\frac{R}{1+R}$	$\frac{1}{1+R}$

中抽取一个样本容量为n的样本.当样本中有k个白球时,似然函数为

$$L(R)=\left(\frac{1}{1+R}\right)^{k}\left(\frac{R}{1+R}\right)^{n-k}=\frac{R^{n-k}}{(1+R)^{n}},$$

其对数似然函数为

$$\ln L(R)=(n-k)\ln R-n\ln(1+R),$$

将对数似然函数对 R 求导,并令其为 0,得似然方程

$$\frac{n-k}{R}-\frac{n}{1+R}=0,$$

解之可得 $\hat{R}=\frac{n}{k}-1$.由于其对数似然函数的二阶导数为

$$\left.\frac{\partial^2\ln L(R)}{\partial R^2}\right|_{\hat{R}}=\left[-\frac{n-k}{R^2}+\frac{n}{(1+R)^2}\right]_{\hat{R}}=-\frac{k^3}{n(n-k)}<0,$$

所以 $\hat{R}=\frac{n}{k}-1$ 是 R 的最大似然估计.

譬如,在 $n=10,k=2$ 场合,R 的最大似然估计 $\hat{R}=\frac{10}{2}-1=4$,即罐中黑球数与白球数之比的最大似然估计为 4,即白球 1 个,黑球 4 个;或者白球 2 个,黑球 8 个等.

13. 设 $x_1,x_2,\cdots,x_m$ 和 $y_1,y_2,\cdots,y_n$ 分别为来自总体 $N(\mu_1,\sigma^2)$ 和 $N(\mu_2,\sigma^2)$ 的两个独立样本.试求 $\theta=(\mu_1,\mu_2,\sigma^2)$ 的最大似然估计.

解 合样本的似然函数为

$$L=\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{m}(x_i-\mu_1)^2-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu_2)^2\right\},$$

对数似然函数为

$$l=\ln L=-\frac{m+n}{2}\ln(2\pi\sigma^2)+\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{m}(x_i-\mu_1)^2-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\mu_2)^2\right].$$

将对数似然函数对 μ_1,μ_2,σ^2 分别求导并令其为 0(忽略常数),得

$$\left.\frac{\partial l}{\partial\mu_1}\right|_{\hat{\mu}_1}=\sum_{i=1}^{m}(x_i-\hat{\mu}_1)=0,\qquad \left.\frac{\partial l}{\partial\mu_2}\right|_{\hat{\mu}_2}=\sum_{i=1}^{n}(y_i-\hat{\mu}_2)=0,$$

$$\left.\frac{\partial l}{\partial\sigma^2}\right|_{\hat{\mu}_1,\hat{\mu}_2,\hat{\sigma}^2}=-\frac{m+n}{2\hat{\sigma}^2}+\frac{1}{2\hat{\sigma}^4}\left[\sum_{i=1}^{m}(x_i-\hat{\mu}_1)^2+\sum_{i=1}^{n}(y_i-\hat{\mu}_2)^2\right]=0,$$

由此得到 μ_1,μ_2,σ^2 的最大似然估计为

$$\hat{\mu}_1=\bar{x},\quad \hat{\mu}_2=\bar{y},$$

$$\hat{\sigma}^2=\frac{\sum_{i=1}^{m}(x_i-\bar{x})^2+\sum_{i=1}^{n}(y_i-\bar{y})^2}{m+n}.$$

14. 某批产品含有 N 件,其中 M 件为不合格品,现从中随机抽取 n 件中有 X 件不合格品,则 X 服从超几何分布,即

$$P(X=x)=\frac{\binom{M}{x}\binom{N-M}{n-x}}{\binom{N}{n}},\qquad x=1,2,\cdots,\min\{M,n\}.$$

假如 N 与 n 已知，寻求该批产品中不合格品数 M 的最大似然估计.

解　记未知参数 M 的似然函数为 $L(M;x)=P(X=x)$.考察似然比

$$\frac{L(M+1,x)}{L(M,x)}=\frac{\binom{M+1}{x}\binom{N-M-1}{n-x}}{\binom{M}{x}\binom{N-M}{n-x}}=\frac{M+1}{M+1-x}\cdot\frac{N-M-n+x}{N-M}.$$

要使似然比 $L(M+1,x)/L(M,x)\geqslant 1$，必导致

$$(M+1)(N-M-n+x)\geqslant(M+1-x)(N-M).$$

化简此式可得 $M\leqslant\frac{x}{n}(N+1)-1\overset{\text{def}}{=\!=}M_0$，这表明：当 M_0 为整数和 $M\leqslant M_0$ 时，似然函数 $L(M,x)$ 是 M 的增函数，即

$$L(0,x)\leqslant L(1,x)\leqslant\cdots\leqslant L(M_0,x)\leqslant L(M_0+1,x).\qquad ①$$

类似地，要使似然比 $L(M+1,x)/L(M,x)\leqslant 1$，必导致 $M\geqslant\frac{x}{n}(N+1)-1=M_0$，这表明，当 M_0 为整数且 $M\geqslant M_0$ 时，似然函数 $L(M,x)$ 是 M 的减函数，即

$$L(M_0,x)\geqslant L(M_0+1,x)\geqslant\cdots\geqslant L(M,x).\qquad ②$$

比较 ① 式和 ② 式可知，当 M_0 为整数时，M 的最大似然估计为 $\hat{M}=M_0$ 或 M_0+1，而当 M_0 不为整数时，M 的最大似然估计为 $\hat{M}=[M_0+1]=\left[\frac{x}{n}(N+1)\right]$，其中 $[a]$ 为不超过 a 的最大整数.综合上述，M 的最大似然估计为

$$\hat{M}=\begin{cases}\frac{x}{n}(N+1)-1\text{ 或 }\frac{x}{n}(N+1), & \frac{x}{n}(N+1)\text{ 为整数},\\ \left[\frac{x}{n}(N+1)\right], & \frac{x}{n}(N+1)\text{ 不为整数}.\end{cases}$$

譬如，在 $N=19,n=5,x=2$ 场合，$M_0=\frac{x}{n}(N+1)-1=\frac{2}{5}\times(19+1)-1=7$，由于 M_0 为整数，故 M 的最大似然估计为 7 或 8. 下面以实际计算加以佐证，几个 $L(M,2)=P(x=2)$ 如下表所示：

M	6	7	8	9	10
$L(M,2)$	0.368 9	0.397 3	0.397 3	0.371 5	0.325 1

可见 M 取 7 或 8 可使似然函数达到最大.

又如，在 $N=16,n=5,x=2$ 场合，$M_0=\frac{x}{n}(N+1)-1=\frac{2}{5}\times(16+1)-1=5.8$（不为整数），这时 M 的最大似然估计 $\hat{M}=[M_0+1]=[5.8+1]=6$.实际计算表明

M	5	6	7	8
$L(M,2)$	0.377 7	0.412 1	0.403 8	0.359

可见 M 取 6 可使似然函数达到最大.

§6.4 最小方差无偏估计

内容概要

1. 均方误差 设 $\hat{\theta}$ 是 θ 的一个估计(无偏的或有偏的),则称

$$\mathrm{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \mathrm{Var}(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2$$

为 $\hat{\theta}$ 的均方误差.均方误差较小意味着:$\hat{\theta}$ 不仅方差较小,而且偏差($E(\hat{\theta}) - \theta$) 也小,所以均方误差是评价点估计的最一般标准.

- 使均方误差一致最小的估计量一般是不存在的,但两个估计的优劣可用均方误差评估;
- 在无偏估计类中使均方误差最小就是使方差最小.

2. 一致最小方差无偏估计 设 $\hat{\theta}$ 是 θ 的一个无偏估计,如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$,在参数空间 $\Theta = \{\theta\}$ 上都有

$$\mathrm{Var}_\theta(\hat{\theta}) \leqslant \mathrm{Var}_\theta(\tilde{\theta}),$$

则称 $\hat{\theta}$ 是 θ 的一致最小方差无偏估计,简记为 UMVUE.

3. 判断准则 设 $\hat{\theta} = \hat{\theta}(x_1, x_2, \cdots, x_n)$ 是 θ 的一个无偏估计,$\mathrm{Var}(\hat{\theta}) < \infty$.如果对任意一个满足 $E(\varphi(x_1, x_2, \cdots, x_n)) = 0$ 和 $\mathrm{Var}(\varphi(x_2, x_2, \cdots, x_n)) < \infty$ 的 φ,都有

$$\mathrm{Cov}_\theta(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta,$$

则 $\hat{\theta}$ 是 θ 的 UMVUE.

4. 充分性原则

- 任一参数 θ 的 UMVUE 不一定存在,若存在,则它一定可表示为充分统计量的函数;
- 若 θ 的某个无偏估计 $\hat{\theta}$ 不是充分统计量 $T = T(x_1, x_2, \cdots, x_n)$ 的函数,则通过条件期望可以获得一个新的无偏估计 $\tilde{\theta} = E(\hat{\theta} \mid T)$,且方差不超过原估计的方差;
- 考虑 θ 的估计时,只需要在其充分统计量的函数中寻找即可,该说法对所有统计推断都是正确的.这便是充分性原则.

5. 费希尔信息量 $I(\theta)$ 设总体的概率函数 $p(x;\theta)$,$\theta \in \Theta$ 满足下列条件:

(1) 参数空间 Θ 是直线上的一个开区间;

(2) 支撑 $S = \{x : p(x;\theta) > 0\}$ 与 θ 无关;