M	5	6	7	8
$L(M,2)$	0.377 7	0.412 1	0.403 8	0.359

可见 M 取 6 可使似然函数达到最大.

§6.4 最小方差无偏估计

内容概要

1. 均方误差 设 $\hat{\theta}$ 是 θ 的一个估计(无偏的或有偏的),则称

$$\mathrm{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \mathrm{Var}(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2$$

为 $\hat{\theta}$ 的均方误差.均方误差较小意味着:$\hat{\theta}$ 不仅方差较小,而且偏差($E(\hat{\theta}) - \theta$) 也小,所以均方误差是评价点估计的最一般标准.

- 使均方误差一致最小的估计量一般是不存在的,但两个估计的优劣可用均方误差评估;
- 在无偏估计类中使均方误差最小就是使方差最小.

2. 一致最小方差无偏估计 设 $\hat{\theta}$ 是 θ 的一个无偏估计,如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$,在参数空间 $\Theta = \{\theta\}$ 上都有

$$\mathrm{Var}_\theta(\hat{\theta}) \leqslant \mathrm{Var}_\theta(\tilde{\theta}),$$

则称 $\hat{\theta}$ 是 θ 的一致最小方差无偏估计,简记为 UMVUE.

3. 判断准则 设 $\hat{\theta} = \hat{\theta}(x_1, x_2, \cdots, x_n)$ 是 θ 的一个无偏估计,$\mathrm{Var}(\hat{\theta}) < \infty$.如果对任意一个满足 $E(\varphi(x_1, x_2, \cdots, x_n)) = 0$ 和 $\mathrm{Var}(\varphi(x_2, x_2, \cdots, x_n)) < \infty$ 的 φ,都有

$$\mathrm{Cov}_\theta(\hat{\theta}, \varphi) = 0, \quad \forall \theta \in \Theta,$$

则 $\hat{\theta}$ 是 θ 的 UMVUE.

4. 充分性原则

- 任一参数 θ 的 UMVUE 不一定存在,若存在,则它一定可表示为充分统计量的函数;
- 若 θ 的某个无偏估计 $\hat{\theta}$ 不是充分统计量 $T = T(x_1, x_2, \cdots, x_n)$ 的函数,则通过条件期望可以获得一个新的无偏估计 $\tilde{\theta} = E(\hat{\theta} \mid T)$,且方差不超过原估计的方差;
- 考虑 θ 的估计时,只需要在其充分统计量的函数中寻找即可,该说法对所有统计推断都是正确的.这便是充分性原则.

5. 费希尔信息量 $I(\theta)$ 设总体的概率函数 $p(x;\theta)$,$\theta \in \Theta$ 满足下列条件:

(1) 参数空间 Θ 是直线上的一个开区间;

(2) 支撑 $S = \{x : p(x;\theta) > 0\}$ 与 θ 无关;

(3) 导数$\frac{\partial}{\partial\theta}p(x;\theta)$对一切$\theta\in\Theta$都存在;

(4) 对$p(x;\theta)$,积分与微分运算可交换次序,即

$$\frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}p(x;\theta)\mathrm{d}x=\int_{-\infty}^{\infty}\frac{\partial}{\partial\theta}p(x;\theta)\mathrm{d}x;$$

(5) 期望$I(\theta)=E\left[\frac{\partial}{\partial\theta}\ln p(x;\theta)\right]^2$存在,

则称该期望$I(\theta)$为总体分布的费希尔信息量.

若二阶导数对一切$\theta\in\Theta$都存在,则$I(\theta)$还可用下式计算

$$I(\theta)=-E\left[\frac{\partial^2}{\partial\theta^2}\ln p(x;\theta)\right].$$

6. 常用分布的费希尔信息量

- 二点分布$b(1,p)$的费希尔信息量$I(p)=[p(1-p)]^{-1}$;
- 泊松分布$p(\lambda)$的费希尔信息量$I(\lambda)=\lambda^{-1}$;
- 指数分布$Exp(\lambda)$的费希尔信息量$I(\lambda)=\lambda^2$;
- 正态分布$N(\mu,1)$的费希尔信息量$I(\mu)=1$;
- 正态分布$N(0,\sigma^2)$的费希尔信息量$I(\sigma^2)=\frac{1}{2\sigma^4}$;
- 正态分布$N(\mu,\sigma^2)$的费希尔信息量(信息矩阵)$\boldsymbol{I}(\mu,\sigma^2)=\begin{pmatrix}1/\sigma^2 & 0\\ 0 & 1/(2\sigma^4)\end{pmatrix}$.

7. C-R 不等式　设$T=T(x_1,x_2,\cdots,x_n)$是未知参数$g(\theta)$的一个无偏估计,若$g'(\theta)=\frac{\partial g(\theta)}{\partial\theta}$存在,则在费希尔信息量$I(\theta)$也存在的条件下有

$$\mathrm{Var}(T)\geqslant[g'(\theta)]^2/(nI(\theta)).$$

上式称为克拉默-拉奥(C-R)不等式,$[g'(\theta)]^2/(nI(\theta))$称为$g(\theta)$的无偏估计的方差的C-R下界,简称$g(\theta)$的C-R下界.特别,对$\theta$的无偏估计$\hat{\theta}$,有$\mathrm{Var}(\hat{\theta})\geqslant(nI(\theta))^{-1}$.

注:$g(\theta)$的C-R下界并不是对任意参数函数$g(\theta)$的无偏估计的方差都可达到.但能达到C-R下界的$g(\theta)$的估计$T=T(x_1,x_2,\cdots,x_n)$一定是$g(\theta)$的UMVUE.方差达到C-R下界的无偏估计称为有效估计.

习题与解答 6.4

1. 设总体概率函数是$p(x;\theta)$,$x_1,x_2,\cdots,x_n$是其样本,$T=T(x_1,x_2,\cdots,x_n)$是θ的充分统计量,则对$g(\theta)$的任一估计$\hat{g}$,令$\tilde{g}=E(\hat{g}\mid T)$,证明:$\mathrm{MSE}(\tilde{g})\leqslant\mathrm{MSE}(\hat{g})$.这说明,在均方误差准则下,人们只需要考虑基于充分统计量的估计.

证　我们将均方误差作如下分解

$$\mathrm{MSE}(\hat{g})=E(\hat{g}-g(\theta))^2=E(\hat{g}-\tilde{g}+\tilde{g}-g(\theta))^2$$

$$= E(\hat{g} - \tilde{g})^2 + \mathrm{MSE}(\tilde{g}) + 2E[(\hat{g} - \tilde{g})(\tilde{g} - g(\theta))].$$

注意到 $\tilde{g} = E(\hat{g} \mid T)$,这说明

$$\begin{aligned} E[(\hat{g} - \tilde{g}) \mid T] &= E(\hat{g} \mid T) - E[E(\hat{g} \mid T) \mid T] \\ &= E(\hat{g} \mid T) - E(\hat{g} \mid T) = 0, \end{aligned}$$

于是

$$\begin{aligned} E[(\hat{g} - \tilde{g})(\tilde{g} - g(\theta))] &= E\{E[(\hat{g} - \tilde{g})(\tilde{g} - g(\theta)) \mid T]\} \\ &= E\{(\tilde{g} - g(\theta))E[(\hat{g} - \tilde{g}) \mid T]\} = 0, \end{aligned}$$

因而 $\mathrm{MSE}(\hat{g}) = E(\hat{g} - \tilde{g})^2 + \mathrm{MSE}(\tilde{g}) \geqslant \mathrm{MSE}(\tilde{g})$.

2. 设 T_1, T_2 分别是 θ_1, θ_2 的 UMVUE,证明:对任意的(非零)常数 a, b, $aT_1 + bT_2$ 是 $a\theta_1 + b\theta_2$ 的 UMVUE.

证 由于 T_1, T_2 分别是 θ_1, θ_2 的 UMVUE,故 $E(T_i) = \theta_i$,且对任意一个 $\phi(x)$,满足 $E(\phi) = 0$,由判断准则知 $\mathrm{Cov}(T_i, \phi) = 0, i = 1, 2$,于是

$$E(aT_1 + bT_2) = a\theta_1 + b\theta_2,$$

$$\mathrm{Cov}(aT_1 + bT_2, \phi) = a\mathrm{Cov}(T_1, \phi) + b\mathrm{Cov}(T_2, \phi) = 0,$$

因此 $aT_1 + bT_2$ 是 $a\theta_1 + b\theta_2$ 的 UMVUE.

3. 设 T 是 $g(\theta)$ 的 UMVUE,$\hat{g}$ 是 $g(\theta)$ 的无偏估计,证明:若 $\mathrm{Var}(\hat{g}) < \infty$,则 $\mathrm{Cov}(T, \hat{g}) \geqslant 0$.

证 因为 T 是 $g(\theta)$ 的 UMVUE,$\hat{g}$ 是 $g(\theta)$ 的无偏估计,故其差 $T - \hat{g}$ 是 0 的无偏估计,即 $E(T - \hat{g}) = 0$,且 $\mathrm{Var}(T - \hat{g}) < \infty$,由判断准则知 $\mathrm{Cov}(T, T - \hat{g}) = 0$,这说明

$$\mathrm{Var}(T) - \mathrm{Cov}(T, \hat{g}) = 0,$$

即 $\mathrm{Cov}(T, \hat{g}) = \mathrm{Var}(T) \geqslant 0$.

4. 设总体 $X \sim N(\mu, \sigma^2)$, $x_1, x_2, \cdots, x_n$ 为样本,证明,$\bar{x} = \dfrac{1}{n}\sum\limits_{i=1}^{n} x_i$, $s^2 = \dfrac{1}{n-1}\sum\limits_{i=1}^{n}(x_i - \bar{x})^2$ 分别为 μ, σ^2 的 UMVUE.

证 大家知道:$\bar{x}, s^2$ 分别是 μ, σ^2 的无偏估计,设 $\varphi(x_1, x_2, \cdots, x_n)$ 是 0 的任一无偏估计,则

$$E(\varphi) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \varphi \cdot \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x_i - \mu)^2}{2\sigma^2}\right\} \mathrm{d}x_1 \cdots \mathrm{d}x_n = 0,$$

即

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \varphi \cdot (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n} x_i^2 + \frac{n\bar{x}}{\sigma^2}\mu - \frac{n\mu^2}{2\sigma^2}\right\} \mathrm{d}x_1 \cdots \mathrm{d}x_n = 0. \quad ①$$

将 ① 式两端对 μ 求导,并注意到 $E(\varphi) = 0$,有

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \frac{n\bar{x}}{\sigma^2}\varphi \cdot (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n} x_i^2 + \frac{n\bar{x}}{\sigma^2}\mu - \frac{n\mu^2}{2\sigma^2}\right\} \mathrm{d}x_1 \cdots \mathrm{d}x_n = 0, \quad ②$$

这说明 $E\left(\dfrac{n\bar{x}\varphi}{\sigma^2}\right) = 0$,即 $E(\bar{x}\varphi) = 0$,于是 $\mathrm{Cov}(\bar{x}, \varphi) = E(\bar{x}\varphi) - E(\bar{x})E(\varphi) = 0$,从而 $\bar{x}$ 是 μ 的 UMVUE.

为证明 s^2 是 σ^2 的 UMVUE,我们将 ② 式的两端再对 μ 求导,得

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\left(\frac{n\bar{x}}{\sigma^2}\right)^2\varphi\cdot(2\pi\sigma^2)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}x_i^2+\frac{n\bar{x}}{\sigma^2}\mu-\frac{n\mu^2}{2\sigma^2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n-$$

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\frac{n\bar{x}}{\sigma^2}\cdot\frac{n\mu}{\sigma^2}\varphi\cdot(2\pi\sigma^2)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}x_i^2+\frac{n\bar{x}}{\sigma^2}\mu-\frac{n\mu^2}{2\sigma^2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n=0,$$

由此可以得到 $E(\bar{x}^2\varphi)=0$,下一步,将 ① 式两端对 σ^2 求导,略去几个前面已经指出积分为 0 的项,有

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\sum_{i=1}^{n}x_i^2\varphi\cdot(2\pi\sigma^2)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}x_i^2+\frac{n\bar{x}}{\sigma^2}\mu-\frac{n\mu^2}{2\sigma^2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n=0.$$

这表明 $E\left(\varphi\sum_{i=1}^{n}x_i^2\right)=0$,由此可得到 $E(s^2\varphi)=0$,因而

$$\mathrm{Cov}(s^2,\varphi)=E(s^2\varphi)-E(s^2)E(\varphi)=0,$$

这就证明了 s^2 是 σ^2 的 UMVUE.

5. 设总体 $p(x;\theta)$ 的费希尔信息量存在,若二阶导数 $\frac{\partial^2}{\partial\theta^2}p(x;\theta)$ 对一切的 $\theta\in\Theta$ 存在,证明费希尔信息量

$$I(\theta)=-E\left(\frac{\partial^2}{\partial\theta^2}\ln p(x;\theta)\right).$$

证　记 $S_\theta=\frac{\partial\ln p(x;\theta)}{\partial\theta}$,则

$$\begin{aligned}E(S_\theta)&=\int_{-\infty}^{\infty}\frac{1}{p(x;\theta)}\cdot\frac{\partial p(x;\theta)}{\partial\theta}\cdot p(x;\theta)\mathrm{d}x\\&=\int_{-\infty}^{\infty}\frac{\partial p(x;\theta)}{\partial\theta}\mathrm{d}x=\frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}p(x;\theta)\mathrm{d}x=0,\end{aligned}$$

所以 $\frac{\partial E(S_\theta)}{\partial\theta}=0$.另一方面,

$$\begin{aligned}\frac{\partial E(S_\theta)}{\partial\theta}&=\frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}S_\theta p(x;\theta)\mathrm{d}x=\int_{-\infty}^{\infty}\frac{\partial}{\partial\theta}(S_\theta\cdot p(x;\theta))\mathrm{d}x\\&=\int_{-\infty}^{\infty}\left(\frac{\partial S_\theta}{\partial\theta}\cdot p(x;\theta)+S_\theta\cdot\frac{\partial p(x;\theta)}{\partial\theta}\right)\mathrm{d}x\\&=\int_{-\infty}^{\infty}\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}\cdot p(x;\theta)\mathrm{d}x+\int_{-\infty}^{\infty}\left(\frac{\partial\ln p(x;\theta)}{\partial\theta}\right)^2\cdot p(x;\theta)\mathrm{d}x\\&=E\left(\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}\right)+E(S_\theta^2)\\&=E\left(\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}\right)+I(\theta).\end{aligned}$$

这就证明了 $I(\theta)=-E\left(\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}\right)$.

6. 设总体密度函数为 $p(x;\theta)=\theta x^{\theta-1},0<x<1,\theta>0,x_1,x_2,\cdots,x_n$ 是样本.

(1) 求 $g(\theta)=1/\theta$ 的最大似然估计;

(2) 求 $g(\theta)$ 的有效估计.

解 (1) 似然函数为 $L(\theta)=\prod_{i=1}^{n}\theta x_i^{\theta-1}$,对数似然函数为

$$\ln L(\theta)=n\ln\theta+(\theta-1)\sum_{i=1}^{n}\ln x_i=-n\ln g(\theta)+\left(\frac{1}{g(\theta)}-1\right)\sum_{i=1}^{n}\ln x_i.$$

将对数似然函数求导并令其为0,得似然方程

$$\frac{\partial\ln L(\theta)}{\partial g(\theta)}=-\frac{n}{g(\theta)}-\frac{1}{g^2(\theta)}\sum_{i=1}^{n}\ln x_i=0,$$

解之得 $\hat{g}(\theta)=-\frac{1}{n}\sum_{i=1}^{n}\ln x_i$.

(2) 令 $Y=-\ln X$,则

$$P(Y<y)=P(-\ln X<y)=P(X>\mathrm{e}^{-y})=\int_{\mathrm{e}^{-y}}^{1}\theta x^{\theta-1}\mathrm{d}x=1-\mathrm{e}^{-\theta y},$$

因此 $Y\sim Exp(\theta)=Ga(1,\theta)$,从而有 $\hat{g}(\theta)\sim Ga(n,n\theta)$,于是

$$E(\hat{g})=\frac{n}{n\theta}=\frac{1}{\theta}=g(\theta),\quad \mathrm{Var}(\hat{g})=\frac{n}{(n\theta)^2}=\frac{1}{n\theta^2}.$$

为求有效估计,需求出 θ 的费希尔信息量,注意到,$\ln p(x,\theta)=\ln\theta+(\theta-1)\ln x$,$\frac{\partial\ln p(x,\theta)}{\partial\theta}=\frac{1}{\theta}+\ln x$,$\frac{\partial^2\ln p(x,\theta)}{\partial\theta^2}=-\frac{1}{\theta^2}$,于是

$$I(\theta)=-E\left(\frac{\partial^2}{\partial\theta^2}\ln p(x;\theta)\right)=\frac{1}{\theta^2}.$$

而 $g'(\theta)=-\theta^{-2}$,于是 $g(\theta)$ 的任一无偏估计的C-R下界为 $\frac{[g'(\theta)]^2}{nI(\theta)}=\frac{1}{n\theta^2}$,从而 $\hat{g}(\theta)=-\frac{1}{n}\sum_{i=1}^{n}\ln x_i$ 是 $g(\theta)$ 的无偏估计,且方差达到了C-R下界,所以 $\hat{g}(\theta)=-\frac{1}{n}\sum_{i=1}^{n}\ln x_i$ 是 $g(\theta)$ 的有效估计.

7. 设总体密度函数为 $p(x;\theta)=\frac{2\theta}{x^3}\mathrm{e}^{-\theta/x^2}$,$x>0,\theta>0$,求 θ 的费希尔信息量 $I(\theta)$.

解 对数密度函数为 $\ln p(x;\theta)=\ln 2+\ln\theta-3\ln x-\theta/x^2$,于是

$$\frac{\partial\ln p(x;\theta)}{\partial\theta}=\frac{1}{\theta}-\frac{1}{x^2},\quad \frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}=-\frac{1}{\theta^2},$$

由此给出 $I(\theta)=-E\left(\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}\right)=\frac{1}{\theta^2}$.

8. 设总体密度函数为 $p(x;\theta)=\theta c^\theta x^{-(\theta+1)}$,$x>c,c>0$ 已知,$\theta>0$,求 θ 的费希尔信息量 $I(\theta)$.

解 对数密度函数为

$$\ln p(x;\theta)=\ln\theta+\theta\ln c-(\theta+1)\ln x,$$

将上式对 θ 求导,得到 $\frac{\partial\ln p(x;\theta)}{\partial\theta}=\frac{1}{\theta}+\ln c-\ln x$,二阶导函数为 $\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}=-\frac{1}{\theta^2}$,于是

$$I(\theta)=-E\left(\frac{\partial^2\ln p(x;\theta)}{\partial\theta^2}\right)=\frac{1}{\theta^2}.$$

9. 设总体分布列为 $P(X=x)=(x-1)\theta^2(1-\theta)^{x-2}, x=2,3,\cdots,0<\theta<1$,求 θ 的费希尔信息量 $I(\theta)$.

解　对数分布列为

$$\ln P(X=x)=\ln(x-1)+2\ln\theta+(x-2)\ln(1-\theta).$$

求一、二阶导数,有

$$\frac{\partial\ln P(X=x)}{\partial\theta}=\frac{2}{\theta}-\frac{x-2}{1-\theta},\quad \frac{\partial^2\ln P(X=x)}{\partial\theta^2}=-\frac{2}{\theta^2}-\frac{x-2}{(1-\theta)^2}.$$

在本章 6.2 节第 3 题中,我们已经算得 $E(x)=\frac{2}{\theta}$,于是

$$I(\theta)=-E\left(\frac{\partial^2\ln P(X=x)}{\partial\theta^2}\right)=\frac{2}{\theta^2}+\frac{E(x)-2}{(1-\theta)^2}=\frac{2}{\theta^2(1-\theta)}.$$

10. 设 $x_1,x_2,\cdots,x_n$ 是来自 $Ga(\alpha,\lambda)$ 的样本,$\alpha>0$ 已知,试证明,$\bar{x}/\alpha$ 是 $g(\lambda)=1/\lambda$ 的有效估计,从而也是 UMVUE.

解　总体 $Ga(\alpha,\lambda)$ 的密度函数为 $p(x;\lambda)=\frac{\lambda^\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x}, x>0$,于是

$$\ln p(x;\lambda)=\alpha\ln\lambda-\ln\Gamma(\alpha)+(\alpha-1)\ln x-\lambda x,$$

$$\frac{\partial\ln p(x;\lambda)}{\partial\lambda}=\frac{\alpha}{\lambda}-x,\quad \frac{\partial^2\ln p(x;\lambda)}{\partial\lambda^2}=-\frac{\alpha}{\lambda^2},$$

所以 λ 的费希尔信息量为 $I(\lambda)=\frac{\alpha}{\lambda^2}$,这就是说 $g(\lambda)=\frac{1}{\lambda}$ 的任一无偏估计的C-R下界为

$$\frac{(g'(\lambda))^2}{nI(\lambda)}=\frac{1}{n\alpha\lambda^2}.$$

又

$$E\left(\frac{\bar{x}}{\alpha}\right)=\frac{1}{\alpha}\cdot\frac{\alpha}{\lambda}=\frac{1}{\lambda},\qquad \mathrm{Var}\left(\frac{\bar{x}}{\alpha}\right)=\frac{1}{\alpha^2}\cdot\frac{1}{n}\cdot\frac{\alpha}{\lambda^2}=\frac{1}{n\alpha\lambda^2}.$$

这就证明了 $\bar{x}/\alpha$ 是 $g(\lambda)=1/\lambda$ 的有效估计,从而也是 UMVUE.

11. 设 $x_1,x_2,\cdots,x_m$ i. i. d. $\sim N(a,\sigma^2)$, $y_1,y_2,\cdots,y_n$ i. i. d. $\sim N(a,2\sigma^2)$,求 a 和 σ^2 的 UMVUE.

解　直观上,可考虑 $\bar{x}$ 和 $\bar{y}$ 的凸线性组合 $\hat{a}_l=l\bar{x}+(1-l)\bar{y}$,易知 $\hat{a}_l$ 为 a 的无偏估计,且当 $l=\frac{2m}{2m+n}$ 时,$\mathrm{Var}(\hat{a}_l)$ 达到最小.下证 $\hat{a}=\frac{2m\bar{x}+n\bar{y}}{2m+n}$ 为 a 的 UMVUE.

$(x_1,x_2,\cdots,x_m,y_1,y_2,\cdots,y_n)$ 的联合密度函数为

$$p(x_1,x_2,\cdots,x_m,y_1,y_2,\cdots,y_n,a,\sigma^2)$$

$$=\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}2^{-\frac{n}{2}}\exp\left\{-\sum_{i=1}^{m}\frac{(x_i-a)^2}{2\sigma^2}-\sum_{i=1}^{n}\frac{(y_i-a)^2}{4\sigma^2}\right\}$$

$$=\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}2^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)+\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}a-\frac{\left(m+\frac{1}{2}n\right)}{2\sigma^2}a^2\right\},$$

设 $\varphi(x_1,x_2,\cdots,x_n)$ 是 0 的任一无偏估计,则

$$E(\varphi)=\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\varphi\cdot p(x_1,\cdots,x_m,y_1,\cdots,y_n,a,\sigma^2)\mathrm{d}x_1\cdots\mathrm{d}x_m\mathrm{d}y_1\cdots\mathrm{d}y_n=0,$$

即

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\varphi\cdot\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}2^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)+\right.$$

$$\left.\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}a-\frac{\left(m+\frac{1}{2}n\right)}{2\sigma^2}a^2\right\}\mathrm{d}x_1\cdots\mathrm{d}x_m\mathrm{d}y_1\cdots\mathrm{d}y_n=0,\qquad ①$$

将 ① 式两端对 a 求导,并注意到 $E(\varphi)=0$,有

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}\varphi\cdot\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}2^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)+\right.$$

$$\left.\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}a-\frac{\left(m+\frac{1}{2}n\right)}{2\sigma^2}a^2\right\}\mathrm{d}x_1\cdots\mathrm{d}x_m\mathrm{d}y_1\cdots\mathrm{d}y_n=0,\qquad ②$$

这说明 $E\left(\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)\varphi}{\sigma^2}\right)=0$,即 $E\left(\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)\varphi\right)=0$.

于是

$$\mathrm{Cov}\left(m\bar{x}+\frac{1}{2}n\bar{y},\varphi\right)=E\left(\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)\varphi\right)-E\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)\cdot E(\varphi)=0,$$

从而 $\hat{a}=\frac{2m\bar{x}+n\bar{y}}{2m+n}$ 是 a 的 UMVUE.

我们将 ② 式的两端再对 a 求导,得

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\left(\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)^2}{\sigma^4}-\frac{\left(m+\frac{1}{2}n\right)}{\sigma^2}\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}a\right)\varphi\cdot$$

$$\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}2^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)+\right.$$

$$\left.\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}a-\frac{\left(m+\frac{1}{2}n\right)}{2\sigma^2}a^2\right\}\mathrm{d}x_1\cdots\mathrm{d}x_m\mathrm{d}y_1\cdots\mathrm{d}y_n=0.$$

由此可以得到 $E\left((m\bar{x}+\frac{1}{2}n\bar{y})^2\varphi\right)=0$，下一步，将 ① 式两端对 σ^2 求导，略去几个前面已经指出积分为 0 的项，有

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)\varphi\cdot\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^{m+n}2^{-\frac{n}{2}}\exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)+\right.$$

$$\left.\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)}{\sigma^2}a-\frac{\left(m+\frac{1}{2}n\right)}{2\sigma^2}a^2\right\}\mathrm{d}x_1\cdots\mathrm{d}x_m\mathrm{d}y_1\cdots\mathrm{d}y_n=0.$$

这表明 $E\left(\varphi\cdot\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)\right)=0.$

记

$$T=\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2-\frac{\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)^2}{m+\frac{1}{2}n},$$

由此可得到 $E(T\varphi)=0$，因而 $\mathrm{Cov}(T,\varphi)=0$.

由于

$$E\left(\sum_{i=1}^{m}x_i^2+\frac{1}{2}\sum_{i=1}^{n}y_i^2\right)=\left(m+\frac{1}{2}n\right)a^2+(m+n)\sigma^2,$$

$$E\left(m\bar{x}+\frac{1}{2}n\bar{y}\right)^2=\left(m+\frac{1}{2}n\right)^2a^2+\left(m+\frac{1}{2}n\right)\sigma^2,$$

所以，

$$E(T)=\left(m+\frac{1}{2}n\right)a^2+(m+n)\sigma^2-\left(m+\frac{1}{2}n\right)a^2-\sigma^2=(m+n-1)\sigma^2,$$

故 $(m+n-1)^{-1}T$ 是 σ^2 的 UMVUE.

注意，这里 σ^2 的估计不能是 s_x^2 和 s_y^2 的凸组合，为什么？留给读者思考.

12. 设 $x_1,x_2,\cdots,x_n$ i. i. d. $\sim N(\mu,1)$，求 μ^2 的 UMVUE.证明此 UMVUE 达不到C-R不等式的下界，即它不是有效估计.

解　设 $\varphi(x_1,x_2,\cdots,x_n)$ 是 0 的任一无偏估计，则

$$E(\varphi)=\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\varphi\cdot\prod_{i=1}^{n}\frac{1}{\sqrt{2\pi}}\exp\left\{-\frac{(x_i-\mu)^2}{2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n=0,$$

即

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}\varphi\cdot(2\pi)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2}\sum_{i=1}^{n}x_i^2+n\bar{x}\mu-\frac{n\mu^2}{2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n=0. \qquad ①$$

将 ① 式两端对 μ 求导，并注意到 $E(\varphi)=0$，有

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}n\bar{x}\varphi\cdot(2\pi)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2}\sum_{i=1}^{n}x_i^2+n\bar{x}\mu-\frac{n\mu^2}{2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n=0. \qquad ②$$

这说明 $E(n\bar{x}\varphi)=0$，即 $E(\bar{x}\varphi)=0$.

我们将 ② 式的两端再对 μ 求导，得

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}(n\bar{x})^2\varphi\cdot(2\pi)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2}\sum_{i=1}^{n}x_i^2+n\bar{x}\mu-\frac{n\mu^2}{2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n-$$

$$\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty}n\bar{x}\cdot n\mu\varphi\cdot(2\pi)^{-\frac{n}{2}}\exp\left\{-\frac{1}{2}\sum_{i=1}^{n}x_i^2+n\bar{x}\mu-\frac{n\mu^2}{2}\right\}\mathrm{d}x_1\cdots\mathrm{d}x_n=0,$$

由此可以得到 $E(\bar{x}^2\varphi)=0$.

记

$$T=\bar{x}^2-\frac{1}{n},$$

则

$$\mathrm{Cov}(T,\varphi)=0,\qquad E(T)=\mu^2,$$

从而,$T=\bar{x}^2-\frac{1}{n}$ 为 μ^2 的 UMVUE.

进一步,$\mathrm{Var}(T)=\mathrm{Var}(\bar{x}^2)=\frac{2}{n^2}+\frac{4}{n}\mu^2$,C-R 下界为$\frac{4\mu^2}{nI(\mu)}=\frac{4\mu^2}{n}$.故此 UMVUE 的方差达不到 C-R 不等式的下界.

13. 对泊松分布 $P(\theta)$,

(1) 求 $I\left(\frac{1}{\theta}\right)$;

(2) 找一个函数 $g(\cdot)$,使 $g(\theta)$ 的费希尔信息量与 θ 无关.

解 (1) $I\left(\frac{1}{\theta}\right)=I(\theta)\left(\frac{\mathrm{d}\theta}{\mathrm{d}\left(\frac{1}{\theta}\right)}\right)^2=\theta^4I(\theta)=\theta^3$;

(2) $I(g(\theta))=I(\theta)\left(\frac{\mathrm{d}\theta}{\mathrm{d}g(\theta)}\right)^2$,令 $I(g(\theta))=c$(其中 c 为大于 0 的任意常数),则 $\frac{\mathrm{d}\theta}{\mathrm{d}g(\theta)}=\sqrt{c\theta}$.所以,$g(\theta)=\frac{2}{\sqrt{c}}\sqrt{\theta}+c_2$(其中 c_2 为任意常数).

14. 设 $x_1,x_2,\cdots,x_n$ 为独立同分布变量,$0<\theta<1$,

$$P(x_1=-1)=\frac{1-\theta}{2},\quad P(x_1=0)=\frac{1}{2},\quad P(x_1=1)=\frac{\theta}{2}.$$

(1) 求 θ 的 MLE $\hat{\theta}_1$,并问 $\hat{\theta}_1$ 是否是无偏的;

(2) 求 θ 的矩估计 $\hat{\theta}_2$;

(3) 计算 θ 的无偏估计的方差的 C-R 下界.

解 (1) 方法一 设 $x_1,x_2,\cdots,x_n$ 中取值 $-1,0,1$ 分别有 n_{-1},n_0,n_1 次,有 $n_{-1}+n_0+n_1=n$,则似然函数

$$L(\theta)=\left(\frac{1-\theta}{2}\right)^{n_{-1}}\left(\frac{1}{2}\right)^{n_0}\left(\frac{\theta}{2}\right)^{n_1}=\frac{(1-\theta)^{n_{-1}}\theta^{n_1}}{2^n},$$

有

$$\ln L(\theta)=n_{-1}\ln(1-\theta)+n_1\ln\theta-n\ln 2,$$

令$\dfrac{\mathrm{d}\ln L(\theta)}{\mathrm{d}\theta}=n_{-1}\cdot\dfrac{-1}{1-\theta}+n_1\cdot\dfrac{1}{\theta}=0$,得$\theta=\dfrac{n_1}{n_{-1}+n_1}$,

故θ的MLE $\hat{\theta}_1=\dfrac{n_1}{n_{-1}+n_1}$.

方法二　总体X的密度函数为

$$p(x;\theta)=\left(\frac{1-\theta}{2}\right)^{\frac{x(x-1)}{2}}\left(\frac{1}{2}\right)^{-(x+1)(x-1)}\left(\frac{\theta}{2}\right)^{\frac{x(x+1)}{2}}=\frac{1}{2}(1-\theta)^{\frac{x^2-x}{2}}\theta^{\frac{x^2+x}{2}},\ x=-1,0,1,$$

则似然函数

$$L(\theta)=\prod_{i=1}^{n}\frac{1}{2}(1-\theta)^{\frac{x_i^2-x_i}{2}}\theta^{\frac{x_i^2+x_i}{2}}=\frac{1}{2^n}(1-\theta)^{\frac{1}{2}\left(\sum\limits_{i=1}^{n}x_i^2-\sum\limits_{i=1}^{n}x_i\right)}\theta^{\frac{1}{2}\left(\sum\limits_{i=1}^{n}x_i^2+\sum\limits_{i=1}^{n}x_i\right)},$$

有

$$\ln L(\theta)=\frac{1}{2}\left(\sum_{i=1}^{n}x_i^2-\sum_{i=1}^{n}x_i\right)\ln(1-\theta)+\frac{1}{2}\left(\sum_{i=1}^{n}x_i^2+\sum_{i=1}^{n}x_i\right)\ln\theta-n\ln 2,$$

令

$$\frac{\mathrm{d}\ln L(\theta)}{\mathrm{d}\theta}=\frac{1}{2}\left(\sum_{i=1}^{n}x_i^2-\sum_{i=1}^{n}x_i\right)\frac{-1}{1-\theta}+\frac{1}{2}\left(\sum_{i=1}^{n}x_i^2+\sum_{i=1}^{n}x_i\right)\frac{1}{\theta}=0,$$

得

$$\theta=\frac{\sum\limits_{i=1}^{n}x_i^2+\sum\limits_{i=1}^{n}x_i}{2\sum\limits_{i=1}^{n}x_i^2}=\frac{1}{2}+\frac{\sum\limits_{i=1}^{n}x_i}{2\sum\limits_{i=1}^{n}x_i^2},$$

故θ的MLE$\hat{\theta}_1=\dfrac{1}{2}+\dfrac{\sum\limits_{i=1}^{n}X_i}{2\sum\limits_{i=1}^{n}X_i^2}$.

注:因X_i全部可能取值$-1,0,1$,有$\sum\limits_{i=1}^{n}X_i^2=n_{-1}+n_1$,$\sum\limits_{i=1}^{n}X_i=n_1-n_{-1}$,即以上两个结果一致.

因$E(\hat{\theta}_1)=E\left(\dfrac{n_1}{n_{-1}+n_1}\right)=E\left[E\left(\dfrac{n_1}{n_{-1}+n_1}\middle|n_{-1}+n_1\right)\right]$,

且$P(x_1=1\mid x_1=-1\text{或}x_1=1)=\dfrac{P(x_1=1)}{P(x_1=-1\text{或}x_1=1)}=\dfrac{\frac{\theta}{2}}{\frac{1-\theta}{2}+\frac{\theta}{2}}=\theta$,

则在$n_{-1}+n_1=m$的条件下,n_1服从二项分布$b(m,\theta)$,$E(n_1\mid n_{-1}+n_1=m)=m\theta$,

可得$E\left(\dfrac{n_1}{n_{-1}+n_1}\middle|n_{-1}+n_1=m\right)=\dfrac{1}{m}E(n_1\mid n_{-1}+n_1=m)=\theta$,即$E\left(\dfrac{n_1}{n_{-1}+n_1}\middle|n_{-1}+n_1\right)=\theta$,

故 $E(\hat{\theta}_1)=E\left[E\left(\frac{n_1}{n_{-1}+n_1}\middle| n_{-1}+n_1\right)\right]=E(\theta)=\theta$，$\hat{\theta}_1$ 是 θ 的无偏估计.

(2) 因为 $E(x_1)=-1\times\frac{1-\theta}{2}+0\times\frac{1}{2}+1\times\frac{\theta}{2}=\theta-\frac{1}{2}$，所以 θ 的矩估计为

$$\hat{\theta}_2=\bar{x}+\frac{1}{2}.$$

(3) $\ln p(x;\theta)=\frac{1}{2}(x^2-x)\ln\left(\frac{1-\theta}{2}\right)-(1-x^2)\ln 2+\frac{1}{2}(x^2+x)\ln\left(\frac{\theta}{2}\right)$，

关于 θ 求导，得

$$\frac{\mathrm{d}\ln p(x;\theta)}{\mathrm{d}\theta}=-\frac{1}{2}(x^2-x)\frac{1}{1-\theta}+\frac{1}{2}(x^2+x)\frac{1}{\theta},$$

$$I(\theta)=E\left(\frac{\mathrm{d}\ln p(x;\theta)}{\mathrm{d}\theta}\right)^2=\left(-\frac{1}{1-\theta}\right)^2\frac{1-\theta}{2}+0\times\frac{1}{2}+\left(\frac{1}{\theta}\right)^2\frac{\theta}{2}$$

$$=\frac{1}{2}\left(\frac{1}{1-\theta}+\frac{1}{\theta}\right)=\frac{1}{2\theta(1-\theta)},$$

所以，θ 的无偏估计的方差的 C-R 下界为 $\frac{2\theta(1-\theta)}{n}$.

15. 设总体 $X\sim Exp(1/\theta)$，$x_1,x_2,\cdots,x_n$ 是样本，θ 的矩估计和最大似然估计都是 $\bar{x}$，它也是 θ 的相合估计和无偏估计，试证明在均方误差准则下存在优于 $\bar{x}$ 的估计（提示：考虑 $\hat{\theta}_a=a\bar{x}$，找均方误差最小者）.

证 令 $\hat{\theta}_a=a\bar{x}$，则

$$\mathrm{MSE}(\hat{\theta}_a)=\mathrm{Var}(\hat{\theta}_a)+(E\hat{\theta}_a-\theta)^2=a^2\mathrm{Var}(\bar{x})+(aE(\bar{x})-\theta)^2$$

$$=a^2\frac{\theta^2}{n}+\theta^2(a-1)^2,$$

对上式求导易知，当 $a=\frac{n}{n+1}$ 时上式达到最小，最小值为 $\frac{\theta^2}{n+1}$，它小于 $\bar{x}$ 的均方误差 $\frac{\theta^2}{n}$.

补充习题及解答

16. 设 $x_1,x_2,\cdots,x_n$ 独立同分布，x_1 的取值有四种可能，其概率分别为

$$p_1=1-\theta,p_2=\theta-\theta^2,p_3=\theta^2-\theta^3,p_4=\theta^3,$$

记 N_j 为 $x_1,x_2,\cdots,x_n$ 中出现各种可能结果的次数，$N_1+N_2+N_3+N_4=n$.

(1) 确定 a_1,a_2,a_3,a_4，使 $T=\sum_{i=1}^{4}a_iN_i$ 为 θ 的无偏估计；

(2) 将 $\mathrm{Var}(T)$ 与 θ 的无偏估计方差的 C-R 下界比较.

解 (1) 由于 $N_i\sim b(n,p_i)$，$i=1,2,3,4$，所以 $E(N_i)=np_i$，从而有

$$E(T)=\sum_{j=1}^{4}a_jE(N_j)=a_1n(1-\theta)+a_2n(\theta-\theta^2)+a_3n(\theta^2-\theta^3)+a_4n\theta^3$$
$$=na_1+n(a_2-a_1)\theta+n(a_3-a_2)\theta^2+n(a_4-a_3)\theta^3.$$

若使 T 为 θ 的无偏估计,即要求

$$\begin{cases}na_1=0,\\ n(a_2-a_1)=1,\\ n(a_3-a_2)=0,\\ n(a_4-a_3)=0,\end{cases}$$

解之得

$$a_1=0,a_2=a_3=a_4=\frac{1}{n}.$$

即 $T=(N_2+N_3+N_4)/n$ 是 θ 的无偏估计.

(2) $P(N_j=n_j,j=1,2,3,4)$

$$=\frac{n!}{n_1!\ n_2!\ n_3!\ n_4!}(1-\theta)^{n_1}(\theta-\theta^2)^{n_2}\cdot(\theta^2-\theta^3)^{n_3}(\theta^3)^{n_4}$$
$$=\frac{n!}{n_1!\ n_2!\ n_3!\ n_4!}\theta^{n_2+2n_3+3n_4}(1-\theta)^{n_1+n_2+n_3},$$

对数似然函数为(略去与 θ 无关的项)

$$\ln L=(n_2+2n_3+3n_4)\ln\theta+(n_1+n_2+n_3)\ln(1-\theta).$$

于是

$$\frac{\partial\ln L}{\partial\theta}=\frac{n_2+2n_3+3n_4}{\theta}-\frac{n_1+n_2+n_3}{1-\theta},$$
$$\frac{\partial^2\ln L}{\partial\theta^2}=-\frac{n_2+2n_3+3n_4}{\theta^2}-\frac{n_1+n_2+n_3}{(1-\theta)^2}.$$

注意到观测量 n_1,n_2,n_3,n_4 是随机变量,且 $E(n_j)=np_j$,故

$$E(n_2+2n_3+3n_4)=n((\theta-\theta^2)+2(\theta^2-\theta^3)+3\theta^3)=n(\theta+\theta^2+\theta^3),$$
$$E(n_1+n_2+n_3)=n((1-\theta)+(\theta-\theta^2)+(\theta^2-\theta^3))=n(1-\theta^3).$$

从而费希尔信息量为

$$I(\theta)=-E\left(\frac{\partial^2\ln L}{\partial\theta^2}\right)=\frac{n(\theta+\theta^2+\theta^3)}{\theta^2}+\frac{n(1-\theta^3)}{(1-\theta)^2}=\frac{n(1+\theta+\theta^2)}{\theta(1-\theta)}.$$

所以 θ 的无偏估计方差的 C-R 下界为 $\dfrac{\theta(1-\theta)}{n(1+\theta+\theta^2)}$.由于 $N_2+N_3+N_4=n-N_1\sim b(n,\theta)$,于是 $T=\dfrac{1}{n}(N_2+N_3+N_4)$ 的方差为

$$\mathrm{Var}(T)=\frac{1}{n^2}\mathrm{Var}(N_2+N_3+N_4)=\frac{\theta(1-\theta)}{n}>\frac{\theta(1-\theta)}{n(1+\theta+\theta^2)},$$

即 T 的方差没有达到 θ 的无偏估计方差的 C-R 下界.

17. 设 $x_1,x_2,\cdots,x_n$ 是来自正态总体 $N(\mu,\sigma^2)$ 的一个样本,若均值 μ 已知,证明:

(1) $\hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(x_i-\mu)^2$ 是 σ^2 的有效估计;

(2) $\hat{\sigma}=\frac{1}{n}\sqrt{\frac{\pi}{2}}\sum_{i=1}^{n}|x_i-\mu|$ 是 σ 的无偏估计,但不是有效估计.

证 (1) 由 $\frac{n\hat{\sigma}^2}{\sigma^2}\sim\chi^2(n)$ 知 $E(\hat{\sigma}^2)=\sigma^2$, $\mathrm{Var}(\hat{\sigma}^2)=\frac{2\sigma^4}{n}$. 为了获得 σ^2 的无偏估计的 C-R 下界,需要费希尔信息量,正态分布 $N(\mu,\sigma^2)$ 的密度函数 $p(x)$ 的对数是

$$\ln p(x)=-\frac{1}{2}\ln 2\pi-\frac{1}{2}\ln\sigma^2-\frac{(x-\mu)^2}{2\sigma^2},$$

$$\frac{\partial\ln p(x)}{\partial\sigma^2}=-\frac{1}{2\sigma^2}+\frac{(x-\mu)^2}{2\sigma^4}=\frac{1}{2\sigma^4}[(x-\mu)^2-\sigma^2].$$

由此得 σ^2 的费希尔信息量

$$I(\sigma^2)=E\left[\frac{\partial\ln p(x)}{\partial\sigma^2}\right]^2=\frac{1}{4\sigma^8}[E(x-\mu)^4-2\sigma^2E(x-\mu)^2+\sigma^4]$$

$$=\frac{1}{4\sigma^8}[3\sigma^4-2\sigma^4+\sigma^4]=\frac{1}{2\sigma^4},$$

从而 σ^2 的无偏估计的 C-R 下界为 $[nI(\sigma^2)]^{-1}=\left[\frac{n}{2\sigma^4}\right]^{-1}=\frac{2\sigma^4}{n}$,此下界与上述 σ^2 无偏估计的方差相等,故此 $\hat{\sigma}^2$ 是 σ^2 的有效估计.

(2) 由于

$$E(|x_i-\mu|)=\frac{1}{\sqrt{2\pi}\sigma}\int_{-\infty}^{\infty}|x-\mu|\mathrm{e}^{-\frac{(x-\mu)^2}{2\sigma^2}}\mathrm{d}x=\frac{2\sigma}{\sqrt{2\pi}}\int_0^{\infty}y\mathrm{e}^{-\frac{y^2}{2}}\mathrm{d}y=\sqrt{\frac{2}{\pi}}\sigma.$$

可见,$E(\hat{\sigma})=\sigma$,即 $\hat{\sigma}$ 是 σ 的无偏估计,其方差为

$$\mathrm{Var}(\hat{\sigma})=\frac{\pi}{2n^2}\sum_{i=1}^{n}\mathrm{Var}(|x_i-\mu|)=\frac{\pi}{2n}[E(x_i-\mu)^2-(E|x_i-\mu|)^2]$$

$$=\frac{\pi}{2n}\left(\sigma^2-\frac{2}{\pi}\sigma^2\right)=\frac{\pi-2}{2n}\sigma^2.$$

为了获得 σ 的无偏估计的 C-R 下界,需要知道 σ 的费希尔信息量,由于

$$\frac{\partial\ln p(x)}{\partial\sigma}=-\frac{1}{\sigma}+\frac{(x-\mu)^2}{\sigma^3}=\frac{1}{\sigma^3}[(x-\mu)^2-\sigma^2],$$

$$I(\sigma)=E\left(\frac{\partial\ln p(x)}{\partial\sigma}\right)^2=\frac{1}{\sigma^6}[E(x-\mu)^4-2\sigma^2E(x-\mu)^2+\sigma^4]$$

$$=\frac{1}{\sigma^6}[3\sigma^4-2\sigma^4+\sigma^4]=\frac{2}{\sigma^2},$$

从而 σ 的无偏估计的 C-R 下界为 $[nI(\sigma)]^{-1}=\left[\frac{2n}{\sigma^2}\right]^{-1}=\frac{\sigma^2}{2n}$,由于无偏估计 $\hat{\sigma}$ 的方差 $\frac{\pi-2}{2n}\sigma^2>\frac{\sigma^2}{2n}$,故 $\hat{\sigma}$ 不是 σ 的有效估计.此处,σ 的无偏估计的 C-R 下界与 $\hat{\sigma}$ 的方差的

比为$\dfrac{\sigma^2/(2n)}{(\pi-2)\sigma^2/(2n)}=\dfrac{1}{\pi-2}=0.876$,该比值常称为无偏估计 $\hat{\sigma}$ 的效.

18. 证明:若 T_1 与 T_2 是未知参数 $g(\theta)$ 的两个 UMVUE,则 $T_1=T_2$ 依概率几乎处处成立.这个命题表明:$g(\theta)$ 的 UMVUE 在几乎处处的意义下是唯一的.

证　首先指出 T_1-T_2 是 0 的无偏估计,则由教材中定理 6.4.1 知

$$\mathrm{Cov}(T_i,T_1-T_2)=E[T_i(T_1-T_2)]=0,i=1,2,$$

于是

$$E((T_1-T_2)^2)=E(T_1^2+T_2^2-2T_1T_2)=E[T_1(T_1-T_2)]+E[T_2(T_2-T_1)]=0,$$

由此立即可得$(T_1-T_2)^2=0$,即 $T_1=T_2$ 几乎处处成立.

19. 设 $x_1,x_2,\cdots,x_n$ 是来自正态总体 $N(\mu,\sigma^2)$ 的一个样本,对 σ^2 考虑如下三个估计:

$$\hat{\sigma}_1^2=\frac{1}{n-1}\sum_{i=1}^{n}(x_i-\bar{x})^2,\hat{\sigma}_2^2=\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2,\hat{\sigma}_3^2=\frac{1}{n+1}\sum_{i=1}^{n}(x_i-\bar{x})^2.$$

(1) 哪一个是 σ^2 的无偏估计?

(2) 哪一个均方误差最小?

解　(1) 由于$\dfrac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\sim\chi^2(n-1)$,故有$E\left[\sum_{i=1}^{n}(x_i-\bar{x})^2\right]=(n-1)\sigma^2$,从而

$$E(\hat{\sigma}_1^2)=\sigma^2,E(\hat{\sigma}_2^2)=\frac{n-1}{n}\sigma^2,E(\hat{\sigma}_3^2)=\frac{n-1}{n+1}\sigma^2.$$

这说明仅有$\hat{\sigma}_1^2$是 σ^2 的无偏估计,而$\hat{\sigma}_2^2$与$\hat{\sigma}_3^2$是 σ^2 的有偏估计.

(2) 我们知道,估计的均方误差是估计的方差加上偏差的平方,即

$$E(\hat{\sigma}^2-\sigma^2)^2=\mathrm{Var}(\hat{\sigma}^2)+(E(\hat{\sigma}^2)-\sigma^2)^2.$$

而 $\mathrm{Var}\left(\sum_{i=1}^{n}(x_i-\bar{x})^2\right)=2(n-1)\sigma^4$,这给出

$$\mathrm{Var}(\hat{\sigma}_1^2)=\frac{2\sigma^4}{n-1},\quad \mathrm{Var}(\hat{\sigma}_2^2)=\frac{2(n-1)\sigma^4}{n^2},\quad \mathrm{Var}(\hat{\sigma}_3^2)=\frac{2(n-1)\sigma^4}{(n+1)^2}.$$

于是

$$\mathrm{MSE}(\hat{\sigma}_1^2)=\mathrm{Var}(\hat{\sigma}_1^2)=\frac{2\sigma^4}{n-1},$$

$$\mathrm{MSE}(\hat{\sigma}_2^2)=\frac{2(n-1)}{n^2}\sigma^4+\left(\frac{n-1}{n}\sigma^2-\sigma^2\right)^2=\frac{2n-1}{n^2}\sigma^4,$$

$$\mathrm{MSE}(\hat{\sigma}_3^2)=\frac{2(n-1)}{(n+1)^2}\sigma^4+\left(\frac{n-1}{n+1}\sigma^2-\sigma^2\right)^2=\frac{2}{(n+1)}\sigma^4,$$

显然$\dfrac{2}{n-1}>\dfrac{2}{n+1},\dfrac{2n-1}{n^2}>\dfrac{2}{n+1}(n>1)$,所以$\hat{\sigma}_3^2$的均方误差最小.

注意,这里$\hat{\sigma}_3^2$是 σ^2 的有偏估计,上述结论表明,在均方误差意义下,有时有偏估计要比无偏估计更优.

事实上,我们还可讨论 σ^2 的估计类 $\hat{\sigma}_l^2 = l\Sigma(x_i - \bar{x})^2$ 中的均方误差的最小性问题.易知

$$\begin{aligned}\mathrm{MSE}(\hat{\sigma}_l^2) &= (E(\hat{\sigma}_l^2) - \sigma^2)^2 + \mathrm{Var}(\hat{\sigma}_l^2)\\ &= ((n-1)l-1)^2\sigma^4 + 2(n-1)l^2\sigma^4\end{aligned}$$

不难求出当 $l = \dfrac{1}{n+1}$ 时,上式达到最小.所以,在形如 $\hat{\sigma}_l^2$ 的估计类中,上述 $\hat{\sigma}_3^2$ 是均方误差最小的.

20. 设 x_1, x_2 独立同分布,其共同的密度函数为

$$p(x;\theta) = \frac{3x^2}{\theta^3}, 0 < x < \theta, \theta > 0.$$

(1) 证明:$T_1 = \dfrac{2}{3}(x_1 + x_2)$ 和 $T_2 = \dfrac{7}{6}\max\{x_1, x_2\}$ 都是 θ 的无偏估计;

(2) 计算 T_1 和 T_2 的均方误差并进行比较;

(3) 证明:在均方误差意义下,在形如 $T_c = c\max\{x_1, x_2\}$ 的估计中,$T_{8/7}$ 最优.

解 (1) 先计算总体均值为 $E(X) = \int_0^\theta x \cdot \dfrac{3x^2}{\theta^3}\mathrm{d}x = \dfrac{3}{4}\theta$,故 $E(T_1) = \dfrac{2}{3} \cdot 2E(X) = \theta$,这说明 T_1 是 θ 的无偏估计.又总体分布函数为 $F(x;\theta) = \int_0^x \dfrac{3u^2}{\theta^3}\mathrm{d}u = \left(\dfrac{x}{\theta}\right)^3, 0 < x < \theta$,记 $Y = \max\{x_1, x_2\}$,则 Y 的密度函数为

$$f(y;\theta) = 2F(y;\theta)p(y;\theta) = \frac{6y^5}{\theta^6}, \quad 0 < y < \theta.$$

于是有

$$E(T_2) = \frac{7}{6}E(Y) = \frac{7}{6}\int_0^\theta \frac{6y^6}{\theta^6}\mathrm{d}y = \frac{7}{6} \cdot \frac{6}{7}\theta = \theta.$$

这表明 T_2 也是 θ 的无偏估计.

(2) 无偏估计的方差就是均方误差.由于

$$E(x_1^2) = \int_0^\theta x^2 \cdot \frac{3x^2}{\theta^3}\mathrm{d}x = \frac{3}{5}\theta^2,$$

$$\mathrm{Var}(x_1) = E(x_1^2) - (E(x_1))^2 = \frac{3}{5}\theta^2 - \left(\frac{3}{4}\theta\right)^2 = \frac{3}{80}\theta^2,$$

故有

$$\mathrm{MSE}(T_1) = \mathrm{Var}(T_1) = \frac{4}{9} \cdot 2\mathrm{Var}(x_1) = \frac{8}{9} \cdot \frac{3}{80}\theta^2 = \frac{1}{30}\theta^2.$$

又

$$E(Y^2) = \int_0^\theta y^2 \cdot \frac{6y^5}{\theta^6}\mathrm{d}y = \frac{3}{4}\theta^2,$$

$$\mathrm{Var}(Y) = E(Y^2) - (E(Y))^2 = \frac{3}{4}\theta^2 - \left(\frac{6}{7}\theta\right)^2 = \frac{3}{196}\theta^2,$$

从而

$$\mathrm{MSE}(T_2)=\mathrm{Var}(T_2)=\frac{49}{36}\cdot\frac{3}{196}\theta^2=\frac{1}{48}\theta^2.$$

由于 $\mathrm{MSE}(T_1)>\mathrm{MSE}(T_2)$，因此在均方误差意义下，$T_2$ 优于 T_1.

(3) 对形如 $T_c=c\max\{x_1,x_2\}$ 的估计有 $E(T_c)=\frac{6}{7}c\theta$，$E(T_c^2)=\frac{3}{4}c^2\theta^2$，故

$$\mathrm{MSE}(T_c)=E(T_c-\theta)^2=E(T_c^2)-2\theta E(T_c)+\theta^2=\left(\frac{3}{4}c^2-\frac{12}{7}c+1\right)\theta^2,$$

因此当 $c=\frac{12/7}{3/2}=\frac{8}{7}$ 时，上述均方误差最小. 所以在均方误差意义下，在形如 $T_c=c\max\{x_1,x_2\}$ 的估计中，$T_{8/7}$ 最优.

§6.5　贝叶斯估计

内容概要

1. 贝叶斯统计推断使用的三种信息

- 总体信息，总体分布或总体所属分布族提供的信息；
- 样本信息，从总体中抽取样本所得观测值提供的信息；
- 先验信息，在试验前人们对要做的问题在经验上和资料上所了解的信息.

2. 贝叶斯统计的基本观点　任一未知量 θ 都可看作随机变量，用一个概率分布来描述 θ 是最好的办法，在获得样本以前这个分布称为先验分布. 在获得样本以后，这个分布称为后验分布.

3. 贝叶斯公式的密度函数形式

- 总体依赖于参数 θ 的概率函数在贝叶斯统计中记为 $p(x\mid\theta)$，它表示在随机变量 θ 取某个给定值时总体的条件概率函数；
- 根据参数 θ 的先验信息设法确定先验分布 $\pi(\theta)$；
- 从贝叶斯观点看，样本 $x_1,x_2,\cdots,x_n$ 的产生分两步进行. 首先从先验分布 $\pi(\theta)$ 产生一个样本 θ_0，然后从 $p(x_1,x_2,\cdots,x_n\mid\theta_0)$ 中产生一组样本. 这时样本的**联合条件概率函数**为 $p(x_1,x_2,\cdots,x_n\mid\theta_0)=\prod_{i=1}^{n}p(x_i\mid\theta_0)$，这个分布综合了总体信息和样本信息；
- θ_0 是不可知的，它是按先验分布 $\pi(\theta)$ 产生的. 为把先验信息综合进去，不能只考虑 θ_0，对 θ 的其他值发生的可能性也要加以考虑，故要用 $\pi(\theta)$ 进行综合. 这样一来，样本 $x_1,x_2,\cdots,x_n$ 和参数 θ 的联合分布为 $h(x_1,x_2,\cdots,x_n,\theta)=p(x_1,x_2,\cdots,x_n\mid\theta)\cdot\pi(\theta)$，这个联合分布把总体信息、样本信息和先验信息三种可用信息都综合进去了；
- 分析的目的是要对未知参数 θ 作统计推断. 在没有样本信息时，人们只能依据先验分布对 θ 作出推断. 在有了样本观测值 $x_1,x_2,\cdots,x_n$ 之后，则应依据 $h(x_1,x_2,\cdots,x_n,\theta)$ 对 θ 作出推断. 由于 $h(x_1,x_2,\cdots,x_n,\theta)$ 可分解为 $h(x_1,x_2,\cdots,x_n,\theta)=$