即认为年龄因素与问题的回答有关联.此处的 p 值为 $p = P(\chi^2 \geqslant 9.613\ 3) = 0.047\ 5$.

§7.5　正态性检验

内容概要

1. 正态概率纸检验　　具体步骤如下:

- 首先将数据按从小到大的次序排列:$x_{(1)} \leqslant x_{(2)} \leqslant \cdots \leqslant x_{(n)}$;
- 对每一个 i,计算修正频率 $\hat{F}_i = (i - 0.375)/(n + 0.25)$, $i = 1,2,\cdots,n$,将 $\hat{F}_i$ 看作概率 $F(x_{(i)})$ 的估计;
- 将点 $(x_{(i)}, \hat{F}_i)$, $i = 1,2,\cdots,n$ 逐一描在正态概率纸上;
- 判断:若诸点在一条直线附近,则认为该数据来自正态总体;

若诸点明显不在一条直线附近,则认为该数据不是来自正态分布总体;

- 如果从正态概率纸上确认总体是非正态分布时,可从如下变换

$$y = \ln x, \quad y = 1/x, \quad y = \sqrt{x}$$

中选一个作数据变换,然后用 $(y_{(i)}, \hat{F}_i)$ 再描点,判断变换后的数据是否来自正态分布,若 $\ln x \sim N(\mu,\sigma^2)$,则 $x \sim LN(\mu,\sigma^2)$,若 $\frac{1}{x} \sim N(\mu,\sigma^2)$,则 $x \sim IN(\mu,\sigma^2)$(倒正态分布),若 $\sqrt{x} \sim N(\mu,\sigma^2)$,则 x 服从非中心 χ^2 分布(更一般的 χ^2 分布).

2. W 检验　　具体步骤如下:

- 首先将观测值按从小到大的次序排列:$x_{(1)} \leqslant x_{(2)} \leqslant \cdots \leqslant x_{(n)}$;
- 从附表6中查得对应 n 的系数 $a_1, a_2, \cdots, a_n$,其中 $a_{n+1-i} = -a_i$, $i = 1,2,\cdots,[n/2]$;
- 计算检验统计量 $W = \dfrac{\left[\sum\limits_{i=1}^{[n/2]} a_i(x_{(n+1-i)} - x_{(i)})\right]^2}{\sum\limits_{i=1}^{n}(x_{(i)} - \bar{x})^2}$;
- 拒绝域 $W = \{W \leqslant W_\alpha\}$,其中 W_α 可查附表7.

注:国家标准GB/T4882—2001中规定:样本量 $n \geqslant 8$,因为在 $n < 8$ 时,对偏离正态分布的检验不太有效.

3. 爱泼斯 - 普利检验(EP 检验)　EP 检验统计量定义为

$$T_{\mathrm{EP}} = 1 + \frac{n}{\sqrt{3}} + \frac{2}{n}\sum_{i=2}^{n}\sum_{j=1}^{i-1}\exp\left\{\frac{-(x_j - x_i)^2}{2s_n^2}\right\} - \sqrt{2}\sum_{i=1}^{n}\exp\left\{\frac{-(x_i - \bar{x})^2}{4s_n^2}\right\},$$

其中 $\bar{x}, s_n^2$ 就是前述的样本均值和(除以 n 的)样本方差.该统计量通常需要编程计算,其拒绝域为 $\{T_{\mathrm{EP}} \geqslant T_{1-\alpha,\mathrm{EP}}(n)\}$, $T_{1-\alpha,\mathrm{EP}}(n)$ 可查附表11,当 $n > 200$ 时,统计量 T_{EP} 的分位数可以用 $n = 200$ 时的分位数代替.对小于200而不在表内的 n,可采用线性插值的方

法得到近似的分位数.

注意:样本观测值的次序是随机的,但一经选定后在计算 T_{EP} 中必须保持不变.计算 T_{EP} 的程序框图如图 7.4 所示(引自国标 GB/T4882—2001).

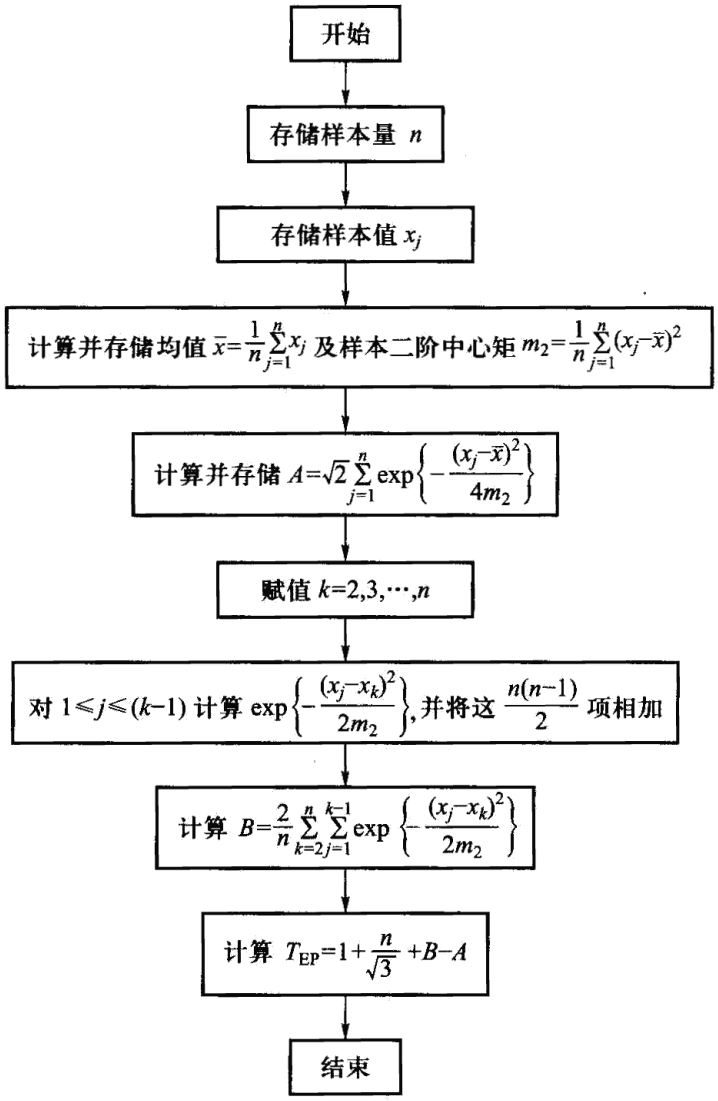

图 7.4 EP 检验中计算检验统计量的流程图

习题与解答 7.5

1. 在检查了一个车间生产的 20 个轴承外座圈的内径(单位:mm)后得到下面数据:

15.04	15.36	14.57	14.53	15.57	14.69	15.37	14.66	14.52	15.41
15.34	14.28	15.01	14.76	14.38	15.87	13.66	14.97	15.29	14.95

(1) 作正态概率图,并作初步判断;

(2) 请用 W 检验方法检验这组数据是否来自正态分布($\alpha=0.05$).

解 (1) ① 首先将数据按从小到大的顺序排列:$x_{(1)}\leqslant x_{(2)}\leqslant\cdots\leqslant x_{(20)}$.具体数据为

13.66　14.28　14.38　14.52　14.53　14.57　14.66　14.69　14.76　14.95

14.97　15.01　15.04　15.29　15.34　15.36　15.37　15.41　15.57　15.87

② 对每一个 i,计算修正频率$(i-0.375)/(20+0.25)$,结果见表:

i	$x_{(i)}$	$\frac{i-0.375}{20+0.25}$	i	$x_{(i)}$	$\frac{i-0.375}{20+0.25}$
1	13.66	0.030 9	11	14.97	0.524 7
2	14.28	0.080 2	12	15.01	0.574 1
3	14.38	0.129 6	13	15.04	0.623 5
4	14.52	0.179 0	14	15.29	0.672 8
5	14.53	0.228 4	15	15.34	0.722 2
6	14.57	0.277 8	16	15.36	0.771 6
7	14.66	0.327 2	17	15.37	0.821 0
8	14.69	0.376 5	18	15.41	0.870 4
9	14.76	0.425 9	19	15.57	0.919 8
10	14.95	0.475 3	20	15.87	0.969 1

③ 将点$(x_{(i)},(i-0.375)/(20+0.25))$逐一描在正态概率纸上(利用软件),得到

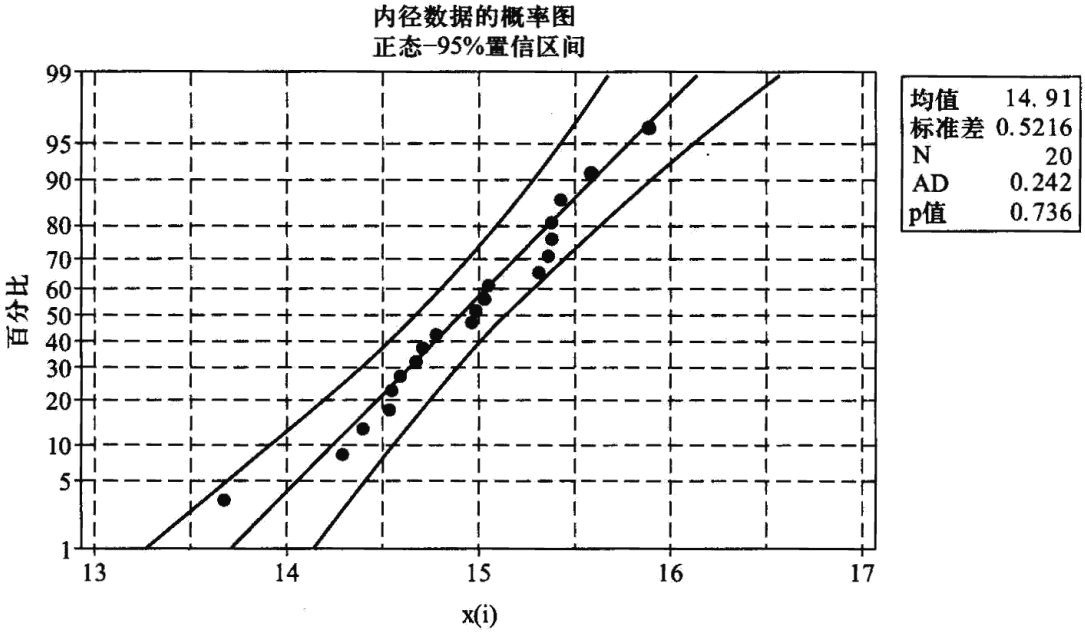

图 7.5

④ 观察上述点的分布,可以判断上述 20 个点基本在一直线附近.

(2) W 检验.由数据可算得 $\bar{x}=14.911\,5$, $\sum_{i=1}^{20}(x_{(i)}-\bar{x})^2=5.168\,5$,为计算方便,建立如下表格

k	$x_{(k)}$	$x_{(n-k+1)}$	d_k	a_k	k	$x_{(k)}$	$x_{(n-k+1)}$	d_k	a_k
1	13.66	15.87	2.21	0.473 4	6	14.57	15.34	0.77	0.133 4
2	14.28	15.57	1.29	0.321 1	7	14.66	15.29	0.63	0.101 3
3	14.38	15.41	1.03	0.256 5	8	14.69	15.04	0.35	0.071 1
4	14.52	15.37	0.85	0.208 5	9	14.76	15.01	0.25	0.042 2
5	14.53	15.36	0.83	0.168 6	10	14.95	14.97	0.02	0.014 0

从上表中可以计算出 W 的值:

$$W=\frac{(0.4734\times 2.21+0.3211\times 1.29+\cdots+0.0140\times 0.02)^2}{5.1685}=0.9743.$$

当 $n=20$ 时,查表知 $W_{0.05}=0.905$,拒绝域为 $\{W\leqslant 0.905\}$,由于样本观测值没有落入拒绝域内,故在显著性水平 $\alpha=0.05$ 下不拒绝原假设,即可以认为这批数据服从正态分布.

2. 抽查克矽平治疗矽肺患者 10 名,得到他们治疗前后的血红蛋白量之差如下:

2.7　-1.2　-1.0　0　0.7　2.0　3.7　-0.6　0.8　-0.3

(1) 作正态概率图,并作初步判断;

(2) 请用 W 检验方法检验治疗前后的血红蛋白量之差是否服从正态分布($\alpha=0.05$)?

解　(1) 仿上题,首先将数据排序,得到

-1.2　-1.0　-0.6　-0.3　0　0.7　0.8　2.0　2.7　3.7,

对每一个 i,计算修正频率 $\frac{i-0.375}{10+0.25}$,$i=1,2,\cdots,10$.结果见表:

i	$x_{(i)}$	$\frac{i-0.375}{10+0.25}$
1	-1.2	0.0610
2	-1.0	0.1585
3	-0.6	0.2561
4	-0.3	0.3537
5	0	0.4512
6	0.7	0.5488
7	0.8	0.6463
8	2.0	0.7439
9	2.7	0.8415
10	3.7	0.9390

利用软件可得到正态概率图如下:

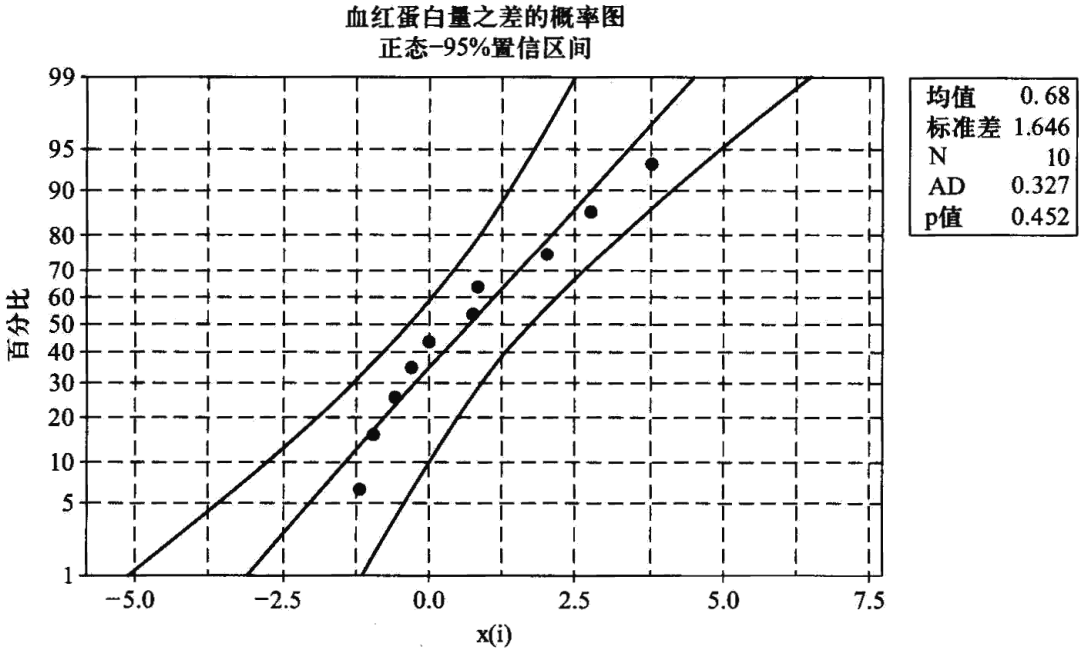

图 7.6

图形显示 10 个点基本在一条直线附近.

(2) W 检验.由数据可算得 $\bar{x}=0.68$, $\sum_{i=1}^{10}(x_{(i)}-\bar{x})^2=24.376$,为计算方便,建立如下表格

k	$x_{(k)}$	$x_{(n-k+1)}$	d_k	a_k
1	-1.2	3.7	4.9	0.573 9
2	-1.0	2.7	3.7	0.329 1
3	-0.6	2.0	2.6	0.214 1
4	-0.3	0.8	1.1	0.122 4
5	0.0	0.7	0.7	0.039 9

从上表中可以计算出 W 的值:

$$W=\frac{(0.573\,9\times4.9+0.329\,1\times3.7+0.214\,1\times2.6+0.122\,4\times1.1+0.039\,9\times0.7)^2}{24.376}$$

$$=0.925\,2$$

当 $n=10$ 时,查表知 $W_{0.05}=0.842$,拒绝域为 $\{W\leqslant0.842\}$,由于样本观测值没有落入拒绝域内,故在显著性水平 $\alpha=0.05$ 下不拒绝原假设,即可以认为治疗前后的血红蛋白量之差服从正态分布.

3. 某种岩石中的一种元素的含量在 25 个样本中为

0.32　0.25　0.29　0.25　0.28　0.30　0.23　0.23　0.40　0.32　0.35

0.19　0.34　0.33　0.33　0.28　0.28　0.22　0.30　0.24　0.35　0.24

0.30　0.23　0.22

有专家认为该样本来自对数正态分布总体,请设法用 W 检验方法作检验($\alpha=0.05$).

解　首先应对数据进行对数变换.记 $y=\ln x$,则 25 个 y 的观测值可算出,我们把它列在下表中,由此可算得 $\bar{y}=-1.28$, $\sum_{i=1}^{25}(y_{(i)}-\bar{y})^2=0.824\,6$,为计算方便,建立如下表格

k	$y_{(k)}$	$y_{(n-k+1)}$	d_k	a_k	k	$y_{(k)}$	$y_{(n-k+1)}$	d_k	a_k
1	-1.66	-0.92	0.74	0.445 0	7	-1.43	-1.14	0.29	0.128 3
2	-1.51	-1.05	0.46	0.306 9	8	-1.43	-1.14	0.29	0.104 6
3	-1.51	-1.05	0.46	0.254 3	9	-1.39	-1.20	0.19	0.082 3
4	-1.47	-1.08	0.39	0.214 8	10	-1.39	-1.20	0.19	0.061 0
5	-1.47	-1.11	0.36	0.182 2	11	-1.27	-1.20	0.07	0.040 3
6	-1.47	-1.11	0.36	0.153 9	12	-1.27	-1.24	0.03	0.020 0

从上表中可以计算出 W 的值为

$$W=\frac{(0.445\,0\times0.74+0.306\,9\times0.46+\cdots+0.020\,0\times0.03)^2}{0.824\,6}=0.961\,5.$$

当 $n=25$ 时,查表知 $W_{0.05}=0.918$,拒绝域为 $\{W\leqslant0.918\}$,由于样本观测值没有落入拒绝域内,故在显著性水平 $\alpha=0.05$ 下不拒绝原假设,即可以认为样本来自对数正态

分布.

4. 对第3题的数据,试用EP检验方法检验这些数据是否来自正态总体(取 $\alpha = 0.05$).

解 该问题可按计算 T_{EP} 的框图用任一种软件编程计算,这里用SAS软件编程算得 $T_{EP} = 0.083\ 1$.

若取显著性水平 $\alpha = 0.05$,在附表11中通过线性插值得到 $n = 25$ 时的0.95分位数约为 $0.368 + \frac{0.371 - 0.368}{30 - 20} \times (25 - 20) = 0.369\ 5$.计算得到的 T_{EP} 小于该临界值.因此在显著性水平0.05下接受这些数据是来自正态总体的.

§7.6 非参数检验

内容概要

1. 游程检验 在怀疑数据可能不符合随机选取的原则时可对数据进行游程检验.

设 $x_1, x_2, \cdots, x_n$ 为依时间顺序连续得到的一组样本观测值序列.要考察如下原假设是否成立.

H_0:样本观察值序列符合随机抽取的原则,

为此记样本中位数为 m_e,把序列中小于 m_e 的那些 x_i 换成0;大于或等于 m_e 的那些 x_i 换成1.把以0为界的一连串的1称为1游程,以1为界的一连串的0称为0游程,统称为游程.设序列中0和1的个数分别为 n_1 和 n_2,设 R 表示样本序列的总游程数,则检验的拒绝域为 $\{R \leqslant c_1\} \cup \{R \geqslant c_2\}$,其中临界值 c_1 和 c_2 根据 H_0 为真时 R 的分布确定,可查表.

当 n_1, n_2 都不太大时,游程检验用 p 值进行更加方便,记 R 的观测值为 R_0,则 $p = 2\min\{P(R \leqslant R_0), P(R \geqslant R_0)\}$,其概率可用下述两式进行计算

$$P(R = 2k) = \frac{2\binom{n_1 - 1}{k - 1}\binom{n_2 - 1}{k - 1}}{\binom{n_1 + n_2}{n_1}}, \quad k = 1, 2, \cdots, \left[\frac{n}{2}\right],$$

$$P(R = 2k + 1) = \frac{\binom{n_1 - 1}{k - 1}\binom{n_2 - 1}{k} + \binom{n_1 - 1}{k}\binom{n_2 - 1}{k - 1}}{\binom{n_1 + n_2}{n_1}}, \quad k = 1, 2, \cdots, \left[\frac{n - 1}{2}\right].$$

对比较大的 n_1, n_2,可以使用渐近分布.对给定的显著性水平 α,两个临界值可近似取为