第八章
方差分析与回归分析

§8.1 方差分析

内容概要

1. 单因子方差分析

(1) 问题与数据

设因子有 r 个水平,记为 $A_1,A_2,\cdots,A_r$,在每一水平下各做 m 次独立重复试验,若记第 i 个水平下第 j 次重复的试验结果为 y_{ij},所有试验的结果可列表如下:

因子水平	试验数据				和	平均
A_1	y_{11}	y_{12}	$\cdots$	y_{1m}	T_1	$\bar{y}_{1\cdot}$
A_2	y_{21}	y_{22}	$\cdots$	y_{2m}	T_2	$\bar{y}_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$
A_r	y_{r1}	y_{r2}	$\cdots$	y_{rm}	T_r	$\bar{y}_{r\cdot}$
					T	$\bar{y}$

对这个试验要研究的问题是:r 个水平 $A_1,A_2,\cdots,A_r$ 间有无显著差异.

(2) 基本假定

A1:正态性:第 i 个水平下的数据 $y_{i1},y_{i2},\cdots,y_{im}$ 是来自正态总体 $N(\mu_i,\sigma_i^2)$ 的一个样本,$i=1,2,\cdots,r$;

A2:等方差性:r 个方差相同,即 $\sigma_1^2=\sigma_2^2=\cdots=\sigma_r^2=\sigma^2$;

A3:独立性:诸数据 y_{ij} 都相互独立.

在这三个基本假定下,要检验的假设是

$$H_0:\mu_1=\mu_2=\cdots=\mu_r \quad \text{vs} \quad H_1:\mu_1,\mu_2,\cdots,\mu_r \text{ 不全相等.}$$

方差分析就是在上述三个基本假定下,对若干个正态均值是否相等作检验.

(3) 平方和分解式

$$S_T=S_A+S_e,\quad f_T=f_A+f_e,$$

若记 $\bar{y}_{i\cdot}=\dfrac{1}{m}\sum\limits_{j=1}^{m}y_{ij}$,$\bar{y}=\dfrac{1}{rm}\sum\limits_{i=1}^{r}\sum\limits_{j=1}^{m}y_{ij}=\dfrac{1}{r}\sum\limits_{i=1}^{r}\bar{y}_{i\cdot}$.上述诸平方和分别为

- $S_T=\sum_{i=1}^{r}\sum_{j=1}^{m}(y_{ij}-\bar{y})^2$ 称为总偏差平方和,其自由度 $f_T=rm-1=n-1$;
- $S_A=m\sum_{i=1}^{r}(\bar{y}_{i\cdot}-\bar{y})^2$ 称为组间偏差平方和或因子 A 的偏差平方和,其自由度 $f_A=r-1$;
- $S_e=\sum_{i=1}^{r}\sum_{j=1}^{m}(y_{ij}-\bar{y}_{i\cdot})^2$ 称为组内偏差平方和或误差偏差平方和,其自由度 $f_e=r(m-1)=n-r$.

注:数据 y_{ij} 的平移 $y'=y_{ij}-a$ 不会改变其平方和的值.用此性质可简化计算.

(4) 方差分析表

来源	平方和	自由度	均方	F 比
因子	$S_A=\frac{1}{m}\sum_{i=1}^{r}T_i^2-\frac{T^2}{rm}$	$f_A=r-1$	$MS_A=S_A/f_A$	$F=MS_A/MS_e$
误差	$S_e=S_T-S_A$	$f_e=r(m-1)$	$MS_e=S_e/f_e$	
总和	$S_T=\sum_{i=1}^{r}\sum_{j=1}^{m}y_{ij}^2-\frac{T^2}{rm}$	$f_T=rm-1$		

(5) 判断

在 H_0 成立下,$F=MS_A/MS_e\sim F(f_A,f_e)$,对给定的显著性水平 $\alpha(0<\alpha<1)$,其拒绝域为 $W=\{F\geqslant F_{1-\alpha}(f_A,f_e)\}$,其中 $F_{1-\alpha}(f_A,f_e)$ 可从附表 5 中查得.

- 若 $F\geqslant F_{1-\alpha}(f_A,f_e)$,则认为因子 A 显著,即诸正态均值间有显著差异;
- 若 $F<F_{1-\alpha}(f_A,f_e)$,则说明因子 A 不显著,即接受原假设 H_0.

给出检验的 p 值是更常用的,若以 X 记服从 $F(f_A,f_e)$ 的随机变量,F 为统计量,$F=MS_A/MS_e$ 的观测值为 F_0,则 $p=P(X\geqslant F_0)$,可用软件计算,如在 MATLAB 中使用如下命令:$p=1-\mathrm{fcdf}(F_0,f_A,f_e)$.

2. 数据结构式及其参数估计

(1) 数据结构式

$$y_{ij}=\mu+a_i+\varepsilon_{ij},\qquad i=1,2,\cdots,r,j=1,2,\cdots,m,$$

其中 μ 为总均值,a_i 为第 i 个水平的效应,且 $\sum_{i=1}^{r}a_i=0$,ε_{ij} 为试验误差,所有 ε_{ij} 可作为来自 $N(0,\sigma^2)$ 的一个样本,在上述数据结构式下,$y_{ij}\sim N(\mu+a_i,\sigma^2)$.要检验的假设检验可改写为

$$H_0:a_1=a_2=\cdots=a_r=0\qquad\text{vs}\qquad H_1:a_1,a_2,\cdots,a_r\text{ 不全为 }0.$$

(2) 点估计

- 总均值 μ 的估计 $\hat{\mu}=\bar{y}$;
- 各水平均值 μ_i 的估计 $\hat{\mu}_i=\bar{y}_{i\cdot},i=1,2,\cdots,r$;
- 主效应 a_i 的估计 $\hat{a}_i=\bar{y}_{i\cdot}-\bar{y},i=1,2,\cdots,r$;
- 误差方差 σ^2 的估计 $\hat{\sigma}^2=MS_e=S_e/f_e$.

(3) $1-\alpha$ 置信区间$(0<\alpha<1)$

- μ_i 的 $1-\alpha$ 置信区间为 $[\bar{y}_{i\cdot}-\hat{\sigma}\cdot t_{1-\alpha/2}(f_e)/\sqrt{m},\bar{y}_{i\cdot}+\hat{\sigma}\cdot t_{1-\alpha/2}(f_e)/\sqrt{m}]$.

3. 单因子试验的统计分析可给出如下三个结果：

- 因子 A 是否显著；
- 试验误差方差 σ^2 的估计；
- 诸水平均值 μ_i 的点估计与区间估计(此项在因子 A 不显著时无需进行).

4. 重复数不等情形下的方差分析

(1) 数据略有不同

设因子 A 有 r 个水平 $A_1,A_2,\cdots,A_r$，并且第 i 个水平 A_i 下重复进行 m_i 次试验，获得如下数据：

水平	重复数	数据	和	平均
A_1	m_1	$y_{11},y_{12},\cdots,y_{1m_1}$	T_1	$\bar{y}_{1\cdot}$
A_2	m_2	$y_{21},y_{22},\cdots,y_{2m_2}$	T_2	$\bar{y}_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
A_r	m_r	$y_{r1},y_{r2},\cdots,y_{rm_r}$	T_r	$\bar{y}_{r\cdot}$
合计	n	T	T	$\bar{y}$

(2) 基本假定、平方和分解、方差分析及判断准则都和前面一样，只是因子 A 的平方和 S_A 的计算公式略有不同：记 $n=\sum_{i=1}^{r}m_i$，则

$$S_A=\frac{T_1^2}{m_1}+\frac{T_2^2}{m_2}+\cdots+\frac{T_r^2}{m_r}-\frac{T^2}{n}.$$

(3) 数据结构式及其参数估计基本同前，但要注意以下两点：

- 总均值 $\mu=\frac{1}{n}\sum_{i=1}^{r}m_i\mu_i$；
- 主效应的约束条件为 $\sum_{i=1}^{r}m_ia_i=0$.

习题与解答 8.1

1. 在一个单因子试验中，因子 A 有三个水平，每个水平下各重复 4 次，具体数据如下：

水平	数据			
一水平	8	5	7	4
二水平	6	10	12	9
三水平	0	1	5	2

试计算误差平方和 S_e、因子 A 的平方和 S_A 与总平方和 S_T，并指出它们各自的自由度.

解　此处因子水平数 $r=3$，每个水平下的重复次数 $m=4$，总试验次数为

$n = mr = 12$.首先,算出每个水平下的数据和以及总数据和:

$$T_1 = 8 + 5 + 7 + 4 = 24,$$
$$T_2 = 6 + 10 + 12 + 9 = 37,$$
$$T_3 = 0 + 1 + 5 + 2 = 8,$$
$$T = T_1 + T_2 + T_3 = 24 + 37 + 8 = 69.$$

误差平方和 S_e 由三个平方和组成:

$$S_{e1} = (8^2 + 5^2 + 7^2 + 4^2) - \frac{24^2}{4} = 10, \qquad f_{e1} = 3,$$

$$S_{e2} = (6^2 + 10^2 + 12^2 + 9^2) - \frac{37^2}{4} = 18.75, \qquad f_{e2} = 3,$$

$$S_{e3} = (0^2 + 1^2 + 5^2 + 2^2) - \frac{8^2}{4} = 14, \qquad f_{e3} = 3,$$

于是

$$S_e = S_{e1} + S_{e2} + S_{e3} = 10 + 18.75 + 14 = 42.75,$$
$$f_e = f_{e1} + f_{e2} + f_{e3} = 9.$$

而

$$S_A = \sum_{i=1}^{r} \frac{T_i^2}{m} - \frac{T^2}{n} = \frac{24^2}{4} + \frac{37^2}{4} + \frac{8^2}{4} - \frac{69^2}{12} = 105.5, \qquad f_A = 3 - 1 = 2,$$

$$S_T = \sum_{i=1}^{r} \sum_{j=1}^{m} y_{ij}^2 - \frac{T^2}{12} = (8^2 + 5^2 + \cdots + 2^2) - \frac{69^2}{12} = 148.25, \ f_T = 12 - 1 = 11.$$

注:在所有的计算公式中可以用数据和也可以用数据均值,但在实际计算中应尽可能用和而不用均值,这样可避免不必要的误差(如四舍五入造成的误差等).

2. 在一个单因子试验中,因子 A 有4个水平,每个水平下重复次数分别为5,7,6,8.那么误差平方和、A 的平方和及总平方和的自由度各是多少?

解 此处因子水平数 $r = 4$,总试验的次数 $n = 5 + 7 + 6 + 8 = 26$,因而有

误差平方和的自由度 $f_e = n - r = 26 - 4 = 22$,

因子 A 的平方和的自由度 $f_A = r - 1 = 3$,

总平方和的自由度 $f_T = n - 1 = 25$.

3. 在单因子试验中,因子 A 有 4 个水平,每个水平下各重复 3 次试验,现已求得每个水平下试验结果的样本标准差分别为 1.5,2.0,1.6,1.2,则其误差平方和为多少?误差的方差 σ^2 的估计值是多少?

解 此处因子水平数 $r = 4$,每个水平下的试验次数 $m = 3$,误差平方和 S_e 由四个平方组成,它们分别为

$$S_{e1} = (3 - 1) \times 1.5^2 = 4.5, \qquad S_{e2} = (3 - 1) \times 2^2 = 8,$$
$$S_{e3} = (3 - 1) \times 1.6^2 = 5.12, \qquad S_{e4} = (3 - 1) \times 1.2^2 = 2.88,$$

于是

$$S_e = S_{e1} + S_{e2} + S_{e3} + S_{e4} = 20.5,$$

其自由度为 $f_e = mr - r = 8$,误差方差 σ^2 的估计值为

$$\hat{\sigma}^2 = \frac{S_e}{f_e} = \frac{20.5}{8} = 2.562\ 5.$$

4. 在单因子方差分析中，因子 A 有三个水平，每个水平各做 4 次重复试验，请完成下列方差分析表，并在显著性水平 $\alpha = 0.05$ 下对因子 A 是否显著作出检验.

方差分析表

来源	平方和	自由度	均方	F 比	p 值
因子 A	4.2				
误差 e	2.5				
总和 T	6.7				

解　补充的方差分析表如下所示：

方差分析表

来源	平方和	自由度	均方	F 比	p 值
因子 A	4.2	2	2.1	7.5	0.012 1
误差 e	2.5	9	0.28		
总和 T	6.7	11			

对于给定的显著性水平 $\alpha = 0.05$，查表知 $F_{0.95}(2,9) = 4.26$，故拒绝域为 $W = \{F \geqslant 4.26\}$，由于 $F = 7.5 > 4.26$，因而认为因子 A 是显著的.此处检验的 p 值为

$$p = 1 - \mathrm{fcdf}(7.5,2,9) = 0.012\ 1.$$

5. 用4种安眠药在兔子身上进行试验，特选24只健康的兔子，随机把它们均分为4组，每组各服一种安眠药，安眠时间(单位：h) 如下所示.

安眠药试验数据

安眠药	安眠时间					
A_1	6.2	6.1	6.0	6.3	6.1	5.9
A_2	6.3	6.5	6.7	6.6	7.1	6.4
A_3	6.8	7.1	6.6	6.8	6.9	6.6
A_4	5.4	6.4	6.2	6.3	6.0	5.9

在显著性水平 $\alpha = 0.05$ 下对其进行方差分析，可以得到什么结果？

解　这是一个单因子方差分析的问题，根据样本数据计算，列表如下：

安眠药	m	T_i	T_i^2	$\sum_{j=1}^{m} y_{ij}^2$
A_1	6	36.6	1 339.56	223.36
A_2	6	39.6	1 568.16	261.76
A_3	6	40.8	1 664.64	277.62
A_4	6	36.2	1 310.44	219.06
和	24	153.2	5 882.8	981.8

于是

$$S_T = \sum_{i=1}^{r}\sum_{j=1}^{m} y_{ij}^2 - \frac{T^2}{n} = 981.8 - \frac{153.2^2}{24} = 3.87, \qquad f_T = 23,$$

$$S_A = \frac{1}{m}\sum_{i=1}^{r} T_i^2 - \frac{T^2}{n} = \frac{5\,882.8}{6} - \frac{153.2^2}{24} = 2.54, \qquad f_A = 3,$$

$$S_e = S_T - S_A = 1.33, \qquad f_e = 20.$$

根据以上结果进行方差分析,并继续计算得到各均方以及 F 比,列于下表:

来源	平方和	自由度	均方	F 比
因子 A	2.54	3	0.846 7	12.732 3
误差 e	1.33	20	0.066 5	
总计	3.87	23		

在显著性水平 $\alpha = 0.05$ 下,查表得 $F_{0.95}(3,20) = 3.10$,拒绝域为 $W = \{F \geqslant 3.10\}$,由于 $F = 12.732\,3 > 3.10$,故认为因子 A(安眠药)是显著的,即四种安眠药对兔子的安眠作用有明显的差别.此处检验的 p 值为

$$p = 1 - \mathrm{fcdf}(12.732\,3, 3, 20) = 7.048\,4 \times 10^{-5}.$$

6. 为研究咖啡因对人体功能的影响,随机选择 30 名体质大致相同的健康男大学生进行手指叩击训练,此外咖啡因选三个水平:

$$A_1 = 0\ \mathrm{mg}, \qquad A_2 = 100\ \mathrm{mg}, \qquad A_3 = 200\ \mathrm{mg}.$$

每个水平下冲泡 10 杯水,外观无差别,并加以编号,然后让 30 名大学生每人从中任选一杯服下,2 小时后,请每人做手指叩击,统计员记录其每分钟叩击次数,试验结果统计如下表:

咖啡因剂量	叩击次数									
A_1: 0 mg	242	245	244	248	247	248	242	244	246	242
A_2: 100 mg	248	246	245	247	248	250	247	246	243	244
A_3: 200 mg	246	248	250	252	248	250	246	248	245	250

请对上述数据进行方差分析,从中可得到什么结论?

解 我们知道,对数据作线性变换不会影响方差分析的结果,这里将原始数据同时减去 240,并作相应的计算,计算结果列入下表:

水平	数据(原始数据 - 240)										T_i	T_i^2	$\sum_{j=1}^{m} y_{ij}^2$
A_1	2	5	4	8	7	8	2	4	6	2	48	2 304	282
A_2	8	6	5	7	8	10	7	6	3	4	64	4 096	448
A_3	6	8	10	12	8	10	6	8	5	10	83	6 889	733
和											195	13 289	1 463

于是可计算得到三个平方和

$$S_T = \sum_{i=1}^{r}\sum_{j=1}^{m} y_{ij}^2 - \frac{T^2}{n} = 1\ 463 - \frac{195^2}{30} = 195.5, \qquad f_T = 29,$$

$$S_A = \frac{1}{m}\sum_{i=1}^{r} T_i^2 - \frac{T^2}{n} = \frac{13\ 289}{10} - \frac{195^2}{30} = 61.4, \qquad f_A = 2,$$

$$S_e = S_T - S_A = 134.1, \qquad f_e = 27.$$

把上述诸平方和及其自由度填入方差分析表,并继续计算得到各均方以及 F 比:

来源	平方和	自由度	均方	F 比
因子 A	61.4	2	30.7	6.181 2
误差 e	134.1	27	4.966 7	
总计	195.5	29		

若取 $\alpha = 0.05$,查表知 $F_{0.95}(2,27) = 3.362$,从而拒绝域为 $W = \{F \geqslant 3.362\}$,由于 $F = 6.181\ 2 > 3.362$,故认为因子 A(咖啡因剂量)是显著的,即三种不同剂量对人的作用有明显的差别.此处检验的 p 值为

$$p = 1 - \mathrm{fcdf}(6.181\ 2, 2, 27) = 0.006\ 2.$$

7. 某粮食加工厂试验三种储藏方法对粮食含水率有无显著影响.现取一批粮食分成若干份,分别用三种不同的方法储藏,过一段时间后测得的含水率(单位:%)如下表:

储藏方法	含水率数据				
A_1	7.3	8.3	7.6	8.4	8.3
A_2	5.4	7.4	7.1	6.8	5.3
A_3	7.9	9.5	10.0	9.8	8.4

(1) 假定各种方法储藏的粮食的含水率服从正态分布,且方差相等,试在 $\alpha = 0.05$ 下检验这三种方法对含水率有无显著影响;

(2) 对每种方法的平均含水率给出置信水平为 0.95 的置信区间.

解　(1) 这是一个单因子方差分析的问题,由所给数据计算如下表:

储藏方法	T_i	T_i^2	$\sum_{j=1}^{m} y_{ij}^2$
A_1	39.9	1 592.01	319.39
A_2	32	1 024	208.66
A_3	45.6	2 079.36	419.26
和	117.5	4 695.37	947.31

三个平方和分别为

$$S_T = \sum_{i=1}^{r}\sum_{j=1}^{m} y_{ij}^2 - \frac{T^2}{n} = 947.31 - \frac{117.5^2}{15} = 26.893, \qquad f_T = 14,$$

$$S_A = \frac{1}{m}\sum_{i=1}^{r} T_i^2 - \frac{T^2}{n} = \frac{4\,695.37}{5} - \frac{117.5^2}{15} = 18.657, \qquad f_A = 2,$$

$$S_e = S_T - S_A = 8.236, \qquad f_e = 12.$$

据此可建立方差分析表：

来源	平方和	自由度	均方	F 比
因子 A	18.657	2	9.329	13.599
误差 e	8.236	12	0.686	
总计	26.893	14		

在显著性水平 $\alpha = 0.05$ 下，查表得 $F_{0.95}(2,12) = 3.89$，故拒绝域为 $W = \{F \geqslant 3.89\}$，由于 $F = 13.599 > 3.89$，故认为因子 A（储藏方法）是显著的，即三种不同储藏方法对粮食的含水率有显著影响.检验的 p 值为

$$p = 1 - \mathrm{fcdf}(13.599,2,12) = 8.232\,0 \times 10^{-4}.$$

（2）每种水平含水率的均值估计分别为

$$\hat{\mu}_1 = \bar{y}_{1\cdot} = 7.98, \quad \hat{\mu}_2 = \bar{y}_{2\cdot} = 6.4, \quad \hat{\mu}_3 = \bar{y}_{3\cdot} = 9.12,$$

而误差方差的无偏估计为 $\hat{\sigma}^2 = MS_e = 0.686$，因而 $\hat{\sigma} = \sqrt{0.686} = 0.828$，若取 $\alpha = 0.05$，则 $t_{1-\alpha/2}(f_e) = t_{0.975}(12) = 2.178\,8$，$\hat{\sigma}\, t_{0.975}(12)/\sqrt{5} = 0.807$，于是三个水平均值的 0.95 置信区间分别为

$$\mu_1 : [7.98 \pm 0.807] = [7.173, 8.787],$$
$$\mu_2 : [6.40 \pm 0.807] = [5.593, 7.207],$$
$$\mu_3 : [9.12 \pm 0.807] = [8.313, 9.927].$$

8. 在入户推销上有五种方法，某大公司想比较这五种方法有无显著的效果差异，设计了一项实验：从应聘的且无推销经验的人员中随机挑选一部分人，将他们随机地分为五个组，每一组用一种推销方法进行培训，培训相同时间后观察他们在一个月内的推销额（单位：千元），数据如下：

组别	推销额						
第一组	20.0	16.8	17.9	21.2	23.9	26.8	22.4
第二组	24.9	21.3	22.6	30.2	29.9	22.5	20.7
第三组	16.0	20.1	17.3	20.9	22.0	26.8	20.8
第四组	17.5	18.2	20.2	17.7	19.1	18.4	16.5
第五组	25.2	26.2	26.9	29.3	30.4	29.7	28.2

（1）假定数据满足进行方差分析的假定，对数据进行分析，在 $\alpha = 0.05$ 下，这五种方法在平均月推销额上有无显著差异？

（2）哪种推销方法的效果最好？试对该种方法一个月的平均推销额求置信水平为 0.95 的置信区间.

解 （1）方便起见，将计算结果列入下表：

推销方法	T_i	T_i^2	$\sum_{j=1}^{m} y_{ij}^2$
A_1	149	22 201	3 243.3
A_2	172.1	29 618.41	4 325.25
A_3	143.9	20 707.21	3 030.99
A_4	127.6	16 281.76	2 334.44
A_5	195.9	38 376.81	5 505.07
和	788.5	127 185.19	18 439.05

各平方和的结果为

$$S_T = \sum_{i=1}^{r}\sum_{j=1}^{m} y_{ij}^2 - \frac{T^2}{n} = 18\ 439.05 - \frac{788.5^2}{35} = 675.271\ 4, \quad f_T = 34,$$

$$S_A = \frac{1}{m}\sum_{i=1}^{r} T_i^2 - \frac{T^2}{n} = \frac{127\ 185.19}{7} - \frac{788.5^2}{35} = 405.534\ 3, \quad f_A = 4,$$

$$S_e = S_T - S_A = 269.737\ 1, \qquad f_e = 30.$$

将上述诸平方和及其自由度移至方差分析表上，并继续计算得到各均方以及 F 比：

来源	平方和	自由度	均方	F 比
因子 A	405.534 3	4	101.383 6	11.275 9
误差 e	269.737 1	30	8.991 2	
总计	675.271 4	34		

在显著性水平 $\alpha = 0.05$ 下，查表知 $F_{0.95}(4,30) = 2.69$，故拒绝域为 $W = \{F \geqslant 2.69\}$，由于 $F = 11.275\ 9 > 2.69$，故认为五种不同推销方法在平均月推销额上有显著影响.检验的 p 值为

$$p = 1 - \mathrm{fcdf}(11.275\ 9,4,30) = 1.052\ 6 \times 10^{-5}.$$

(2) 每种推销方法平均月推销额的估计值分别为

$$\hat{\mu}_1 = \bar{y}_{1\cdot} = 21.285\ 7, \quad \hat{\mu}_2 = \bar{y}_{2\cdot} = 24.585\ 7, \quad \hat{\mu}_3 = \bar{y}_{3\cdot} = 20.557\ 1,$$

$$\hat{\mu}_4 = \bar{y}_{4\cdot} = 18.228\ 6, \quad \hat{\mu}_5 = \bar{y}_{5\cdot} = 27.985\ 7,$$

从点估计来看，水平 5(第 5 种推销方法) 是最优的.此处误差方差的无偏估计为 $\hat{\sigma}^2 = MS_e = 8.991\ 2$，即 $\hat{\sigma} = \sqrt{8.991\ 2} = 2.998\ 5$，若取 $\alpha = 0.05$，查表知 $t_{1-\alpha/2}(f_e) = t_{0.975}(30) = 2.042\ 3$，$\hat{\sigma}\, t_{0.975}(30)/\sqrt{7} = 2.314\ 6$，于是水平 5 下均值的 0.95 置信区间为

$$\mu_5 : [27.985\ 7 \pm 2.314\ 6] = [25.671\ 1, 30.300\ 3].$$

补充习题及解答

9. 某组装产品内有部分噪声很大的次品，产生次品的原因似乎是由于这种组装品的某个部位的间隙过大引起的，为检验这个认识是否正确，特从正品 A_1 和次品 A_2 中各

抽出 8 个,对其间隙进行了测量,测量数据(单位:μm) 如下:

A_1	4	8	2	3	5	4	6	7
A_2	7	12	13	15	8	10	12	9

在正态分布假设下请对 A_1 与 A_2 中的间隙的均值间是否存在显著差异进行检验(取$\alpha = 0.05$).

解 这是单因子(间隙) 二水平等重复试验,其均值比较可用两种方法进行检验.

解法一 方差分析法,具体操作如下.

(1) 计算各个和:$T_1 = 39$, $T_2 = 86$, $T = T_1 + T_2 = 125$.

(2) 计算各个平方和:

$$S_T = \sum_{i=1}^{2}\sum_{j=1}^{8} y_{ij}^2 - \frac{T^2}{16} = 1\ 195 - \frac{125^2}{16} = 218.437\ 5,$$

$$S_A = \frac{T_1^2}{8} + \frac{T_2^2}{8} - \frac{T^2}{16} = \frac{39^2}{8} + \frac{86^2}{8} - \frac{125^2}{16} = 138.062\ 5,$$

$$S_e = S_T - S_A = 218.437\ 5 - 138.062\ 5 = 80.375.$$

(3) 列出方差分析表:

来源	平方和	自由度	均方	F 比
因子 A	138.062 5	1	138.062 5	24.048 1
误差 e	80.375	14	5.741 1	
总计	218.437 5	15		

(4) 判断:若给定显著性水平 $\alpha = 0.05$,可查得 $F_{0.95}(1,14) = 4.60$,拒绝域为 $W = \{F \geqslant 4.60\}$,由于 $F > 4.60$,故因子 A 显著,即正品与次品的该部位的平均间隙有显著差异.

解法二 双样本 t 检验.

在正态总体方差相等的条件下两均值的比较还可用双样本的 t 检验.检验统计量为

$$t = \frac{\bar{y}_1 - \bar{y}_2}{S_w\sqrt{\frac{1}{m_1} + \frac{1}{m_2}}} \sim t(m_1 + m_2 - 2),$$

其中 m_1 与 m_2 是两样本量,$\bar{y}_1$ 与$\bar{y}_2$ 是两样本均值,

$$s_w^2 = \frac{1}{m_1 + m_2 - 2}\left[\sum_{j=1}^{m_1}\left(y_{1j} - \bar{y}_1\right)^2 + \sum_{j=1}^{m_2}\left(y_{2j} - \bar{y}_2\right)^2\right].$$

如今由样本可算得

$$m_1 = m_2 = 8,\quad \bar{y}_1 = 4.875,\quad \bar{y}_2 = 10.75,\quad s_w = 2.396\ 1,$$

$$t = \frac{4.875 - 10.75}{2.396\ 1 \times \sqrt{\frac{1}{8} + \frac{1}{8}}} = -4.903\ 9.$$

对给定显著性水平 $\alpha = 0.05$，拒绝域为 $W = \{|t| > t_{1-\alpha/2}(m_1 + m_2 - 2)\}$，查表得 $t_{0.975}(14) = 2.1448$，由于 $|t| > 2.1448$，故应拒绝两均值相等的假设，此结论与方差分析相同.

这里两种检验的结果相同的现象不是偶然的，因为自由度为 f_2 的 t 变量的平方就是 $F(1,f_2)$ 分布，因此这两个方法是等价的.其临界值亦有 $(-4.9039)^2 = 24.0481$.

10. 某乳制品公司有四个车间生产同一种酸乳酪，为考察四个车间产品中脂肪含量是否一致，特在每个车间生产的产品中各抽取 8 个样品送到实验室进行脂肪含量测定，测量结果（单位：%）如下：

车间	脂肪含量 y_{ij}							
A_1	3.11	3.36	3.24	2.96	3.15	3.18	3.30	3.06
A_2	2.94	3.04	3.13	2.86	3.27	3.19	3.10	2.99
A_3	3.18	3.26	3.48	3.35	3.30	3.06	3.24	3.41
A_4	2.84	2.95	2.73	3.18	3.04	2.90	3.08	2.98

试比较各车间生产的酸乳酪中脂肪含量均值有无显著差异（取 $\alpha = 0.05$）.

解　为简化运算先把测量值 y_{ij} 减去 3 后再乘 100，可得下表：

车间	$z_{ij} = (y_{ij} - 3) \times 100$								T_i	$\sum_{j=1}^{8} z_{ij}^2$
A_1	11	36	24	−4	15	18	30	6	136	3 494
A_2	−6	4	13	−14	27	19	10	−1	52	1 608
A_3	18	26	48	35	30	6	24	41	228	7 722
A_4	−16	−5	−27	18	4	−10	8	−2	−30	1 518
									$T=386$	14 342

利用上表数据可算得各平方和.

$$S_T = \sum_{i=1}^{4}\sum_{j=1}^{8} z_{ij}^2 - \frac{T^2}{32} = 14\,342 - \frac{386^2}{32} = 9\,685.875,$$

$$S_A = \frac{1}{8}\sum_{i=1}^{4} T_i^2 - \frac{T^2}{32} = 4\,604.375,$$

$$S_e = S_T - S_A = 9\,685.875 - 4\,604.375 = 5\,081.500.$$

把它们移至方差分析表，继续计算.

来源	平方和	自由度	均方	F 比
因子 A	4 604.375	3	1 534.791 7	8.46
误差 e	5 081.500	28	181.482 1	
总计	9 685.875	31		

对给定的显著性水平 $\alpha = 0.05$，查表得 $F_{0.95}(3,28) \approx 2.92$，由于 $F = 8.46 > 2.92$，故因子 A 显著，即四个车间生产的酸乳酪中脂肪含量均值有显著差异.

进一步可以给出各车间生产的酸乳酪中脂肪含量均值的估计.大家知道，线性变

换 $z_{ij}=(y_{ij}-3)\times 100$ 不会改变方差分析表中 F 比的值,故不影响方差分析的结果,但会影响诸水平均值与误差方差的估计值,这是因为上述变换的逆变换为

$$y_{ij}=3+z_{ij}/100,$$

从而有

$$\bar{y}_i=3+\bar{z}_i/100,\quad i=1,2,3,4,$$

$$\hat{\sigma}_y^2=\sigma_z^2/10\,000.$$

如今有

$$\bar{z}_1=17,\quad \bar{z}_2=6.5,\quad \bar{z}_3=28.5,\quad \bar{z}_4=-3.75,\quad \hat{\sigma}_z^2=MS_e=181.482\,1,$$

从而可知

$$\bar{y}_1=3.17,\quad \bar{y}_2=3.065,\quad \bar{y}_3=3.285,\quad \bar{y}_4=2.963,$$

$$\hat{\sigma}_y^2=0.018\,148\,21,\qquad \hat{\sigma}_y=0.134\,7.$$

§8.2 多重比较

内容概要

1. 问题 在单因子方差分析中,当因子 A 显著时,就要继续研究如下问题:在多个水平均值中同时比较任意两个水平间有无明显差异的问题,这个问题的检验法则称**多重比较**.

若因子 A 有 r 个水平,则同时检验 $r(r-1)/2$ 个假设

$$H_0^{ij}:\mu_i=\mu_j,\quad 1\leqslant i<j\leqslant r,$$

其拒绝域 $W=\bigcup\limits_{1\leqslant i<j\leqslant r}\{|\bar{y}_{i\cdot}-\bar{y}_{j\cdot}|\geqslant c_{ij}\}$.对给定的显著性水平 $\alpha(0<\alpha<1)$,诸临界值 c_{ij} 由 $P(W)=\alpha$ 决定.

2. 重复数相等场合的 T 法 在各水平试验次数相同时,诸临界值 c_{ij} 也相同,具体为

$$c=q_{1-\alpha}(r,f_e)\hat{\sigma}/\sqrt{m},$$

其中 $\hat{\sigma}=\sqrt{MS_e}$,$q_{1-\alpha}(r,f_e)$ 是分布 $q(r,f_e)$ 的 $1-\alpha$ 分位数,可从附表 8 中查得.

3. 重复数不等场合的 S 法 在各水平试验次数不同时,诸临界值 c_{ij} 也不同,具体为

$$c_{ij}=\sqrt{(r-1)F_{1-\alpha}(r-1,f_e)\left(\frac{1}{m_i}+\frac{1}{m_j}\right)\hat{\sigma}^2},$$

其中 $F_{1-\alpha}(r-1,f_e)$ 为分布 $F(r-1,f_e)$ 的 $1-\alpha$ 分位数.

习题与解答 8.2

1. 采用习题 8.1 中第 7 题的数据,对三种储藏方法的平均含水率在 $\alpha=0.05$ 下作