著,即四个平均出口速度间有显著差异.

(4) 由于各水平的重复数相等,故用 T 法进行多重比较.对给定显著性水平 $\alpha = 0.05$,查附表 8 得 $q_{0.95}(4,28) \approx 3.85$,临界值为

$$c = q_{0.95}(4,28)\sqrt{\frac{MS_e}{m}} \approx 3.85 \times \sqrt{\frac{27.81}{8}} = 7.18.$$

把 c 与各均值差的绝对值 $|\bar{y}_i - \bar{y}_j|$ 分别进行比较,只有

$$|\bar{y}_1 - \bar{y}_2| = 5.52 < c = 7.18,$$

其他 5 个绝对值都大于 7.18,这表明 A_1 与 A_2 间无显著差异,其他 5 对水平间都有显著差异.

§8.4　一元线性回归

内容概要

1. 问题　考察两个变量 x 与 y 之间是否存在线性相关关系,其中 x 是一般(可控)变量,y 是随机变量,其线性回归关系可表示如下(可用散点图显示):

$$y = \beta_0 + \beta_1 x + \varepsilon,$$

其中 β_0 为截距,β_1 为斜率,ε 为随机误差,常假设 $\varepsilon \sim N(0,\sigma^2)$.这里 β_0,β_1,σ^2 是三个待估参数.上式表明,y 与 x 之间有线性关系,但受到随机误差的干扰.

2. 数据　对 x 与 y 通过试验或观察可得 n 对数据(注:数据是成对的,不允许错位).在 y 与 x 之间存在线性关系的假设下,有如下统计模型:

$$\begin{cases} y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, i = 1,2,\cdots,n, \\ \text{各 } \varepsilon_i \text{ 独立同分布,其分布为 } N(0,\sigma^2). \end{cases}$$

利用成对数据可获得 β_0 与 β_1 的估计,设估计分别为 $\hat{\beta}_0$ 与 $\hat{\beta}_1$,则称 $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ 为回归方程,其图形称为回归直线.

3. 参数估计　用最小二乘法可得 β_0 与 β_1 的无偏估计

$$\begin{cases} \hat{\beta}_1 = l_{xy}/l_{xx}, \\ \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \end{cases}$$

其中 $\bar{x} = \frac{1}{n}\sum x_i, \bar{y} = \frac{1}{n}\sum y_i$(此处 $\sum$ 表示 $\sum_{i=1}^{n}$,下同),

$$l_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y}) = \sum x_i y_i - n\bar{x}\bar{y} = \sum x_i y_i - \frac{1}{n}\sum x_i \sum y_i,$$

$$l_{xx} = \sum(x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2 = \sum x_i^2 - \frac{1}{n}\left(\sum x_i\right)^2,$$

$$l_{yy} = \sum(y_i - \bar{y})^2 = \sum y_i^2 - n\bar{y}^2 = \sum y_i^2 - \frac{1}{n}\left(\sum y_i\right)^2.$$

4. 回归方程的显著性检验 回归方程的显著性检验就是要对如下一对假设作出判断：

$$H_0: \beta_1 = 0 \quad \text{vs} \quad H_1: \beta_1 \neq 0.$$

对此可采用如下两种等价的检验方法.

(1) F **检验**

如下的平方和分解式是非常重要的，它在许多统计领域都有应用：

$$S_T = S_R + S_e, \quad f_T = f_R + f_e,$$

其中

$S_T = \sum(y_i - \bar{y})^2 = \sum y_i^2 - \frac{1}{n}(\sum y_i)^2 = l_{yy}$是总偏差平方和，其自由度$f_T = n-1$，

$S_R = \sum(\hat{y}_i - \bar{y})^2 = \sum(\hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{y})^2 = \hat{\beta}_1 l_{xy} = \hat{\beta}_1^2 l_{xx}$是回归平方和，其自由度$f_R = 1$，

$S_e = \sum(y_i - \hat{y}_i)^2 = \sum(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$ 是残差平方和，其自由度$f_e = n-2$.

而 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ 是在 $x = x_i$ 的回归值(拟合值)，它与实测值 y_i 通常是不相等的.

在原假设 H_0 成立的条件下，**检验统计量** $F = \frac{S_R}{S_e/(n-2)} \sim F(1, n-2)$，拒绝域为

$$W = \{F \geqslant F_{1-\alpha}(1, n-2)\}.$$

上述检验过程一般用如下方差分析表列出：

来源	平方和	自由度	均方	F 比
回归	S_R	$f_R = 1$	$MS_R = S_R$	$F = \frac{MS_R}{MS_e}$
残差	S_e	$f_e = n-2$	$MS_e = \frac{S_e}{n-2}$	
总计	S_T	$f_T = n-1$		

(2) t **检验**

检验统计量为 $t = \frac{\hat{\beta}_1}{\hat{\sigma}/\sqrt{l_{xx}}}$，其中 $\hat{\sigma} = \sqrt{S_e/(n-2)}$，在原假设成立下，$t \sim t(n-2)$，因此拒绝域为

$$W = \{|t| \geqslant t_{1-\alpha/2}(n-2)\}.$$

注意到 $t^2 = F$，因此 t 检验与 F 检验是等价的，选其中之一使用即可.

5. 相关系数及其检验

(1) **相关系数**

对容量为 n 的二维样本 $\{(x_i, y_i), i = 1, 2, \cdots, n\}$ 的线性相关程度可用如下(样本)相关系数度量

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}} = \frac{l_{xy}}{\sqrt{l_{xx} l_{yy}}}.$$

- $r = \pm 1$，n 个点完全在一条直线上，此时两者之间可能是确定性关系；
- $r > 0$，当 x 增加时，y 有线性增加趋势，此时称正相关；

- $r<0$,当 x 增加时,y 反而有线性减少趋势,此时称负相关;
- $r=0$,n 个点可能杂乱无章,也可能呈某种曲线趋势,此时称不(线性)相关.

(2) **相关系数的检验**

记 ρ 为二维总体的相关系数,于是可建立如下假设:

$$H_0:\rho=0 \quad \text{vs} \quad H_1:\rho\neq 0.$$

对此,采用检验统计量 $r=\dfrac{l_{xy}}{\sqrt{l_{xx}l_{yy}}}$,拒绝域为

$$W=\{|r|\geqslant r_{1-\alpha}(n-2)\},$$

其中 $r_{1-\alpha}(n-1)$ 是 $|r|$ 分布的 $1-\alpha$ 分位数,可查附表 9.

(3) **检验统计量 r 与 F 统计量之间关系**

$$r^2=\frac{F}{F+(n-2)},$$

这表明 $|r|$ 是 F 的严格增函数,所以相关系数检验与前面的 F 检验也是等价的.

6. 估计与预测 —— 回归方程的应用

- 当 $x=x_0$ 时,$\hat{y}_0=\hat{\beta}_0+\hat{\beta}_1x_0$ 是 $E(y_0)=\beta_0+\beta_1x_0$ 的点估计;
- 当 $x=x_0$ 时,$E(y_0)=\beta_0+\beta_1x_0$ 的置信水平为 $1-\alpha$ 的置信区间是 $[\hat{y}_0-\delta_0,\hat{y}_0+\delta_0]$,其中 $\delta_0=t_{1-\alpha/2}(n-2)\hat{\sigma}\sqrt{\dfrac{1}{n}+\dfrac{(x_0-\bar{x})^2}{l_{xx}}}$, $\hat{\sigma}=\sqrt{MS_e}$;
- 当 $x=x_0$ 时,$y_0=\beta_0+\beta_1x_0+\varepsilon_0$ 的 $1-\alpha$ 预测区间是 $[\hat{y}_0-\delta,\hat{y}_0+\delta]$,其中 $\delta=\delta(x_0)=t_{1-\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\dfrac{1}{n}+\dfrac{(x_0-\bar{x})^2}{l_{xx}}}$.

注:$E(y_0)$ 是未知参数,而 y_0 是随机变量.对 $E(y_0)$ 谈论的是置信区间,对 y_0 谈论的是预测区间,两者是不同的,显然,预测区间要比置信区间宽很多.

要提高预测区间(置信区间也一样)的精度,即要使 δ(或 δ_0)较小,这要求:(1) 增大样本量 n;(2) 增大 l_{xx},即要求 $x_1,x_2,\cdots,x_n$ 较为分散;(3) 使 x_0 靠近 $\bar{x}$.

习题与解答 8.4

1. 假设回归直线过原点,即一元线性回归模型为

$$y_i=\beta x_i+\varepsilon_i,\quad i=1,2,\cdots,n,$$

$E(\varepsilon_i)=0$,$\mathrm{Var}(\varepsilon_i)=\sigma^2$,诸观测值相互独立.

(1) 写出 β 的最小二乘估计和 σ^2 的无偏估计;

(2) 对给定的 x_0,其对应的因变量均值的估计为 $\hat{y}_0$,求 $\mathrm{Var}(\hat{y}_0)$.

解　(1) 由最小二乘法原理,令 $Q=\sum\limits_{i=1}^{n}(y_i-\beta x_i)^2$,则正规方程为

$$\left.\frac{\partial Q}{\partial\beta}\right|_{\hat{\beta}}=-2\sum_{i=1}^{n}(y_i-\hat{\beta}x_i)x_i=0.$$

从中解得 β 的最小二乘估计为 $\hat{\beta}=\dfrac{\sum_{i=1}^{n}x_iy_i}{\sum_{i=1}^{n}x_i^2}$.不难看出

$$E(\hat{\beta})=\frac{1}{\sum_{i=1}^{n}x_i^2}\sum_{i=1}^{n}x_iE(y_i)=\beta,$$

$$\mathrm{Var}(\hat{\beta})=\left(\sum_{i=1}^{n}x_i^2\right)^{-2}\sum_{i=1}^{n}x_i^2\mathrm{Var}(y_i)=\frac{\sigma^2}{\sum_{i=1}^{n}x_i^2}.$$

于是,由

$$S_e=\sum(y_i-\hat{y}_i)^2=\sum(\beta x_i+\varepsilon_i-\hat{\beta}x_i)^2=\sum[x_i^2(\hat{\beta}-\beta)^2+\varepsilon_i^2-2(\hat{\beta}-\beta)x_i\varepsilon_i],$$

有

$$E(S_e)=\sum x_i^2\mathrm{Var}(\hat{\beta})+n\mathrm{Var}(\varepsilon)-2\sum x_iE(\hat{\beta}\varepsilon_i).$$

将 $\hat{\beta}$ 写成 $y_1,y_2,\cdots,y_n$ 的线性组合,利用 y_j 与 $\varepsilon_i(i\neq j)$ 间的独立性,有

$$E(\hat{\beta}\varepsilon_i)=\frac{1}{\sum_{j=1}^{n}x_j^2}E\left(\varepsilon_i\sum_j x_jy_j\right)=\frac{x_i}{\sum_{j=1}^{n}x_j^2}\sigma^2,$$

由此即有 $\sum x_iE(\hat{\beta}\varepsilon_i)=\sigma^2$,从而

$$E(S_e)=\sum\frac{x_i^2}{\sum_{i=1}^{n}x_i^2}\sigma^2+n\sigma^2-2\sigma^2=(n-1)\sigma^2,$$

这给出 σ^2 的无偏估计为$\dfrac{1}{n-1}S_e$.

(2) 对给定的 x_0,对应的因变量均值的估计为 $\hat{y}_0=\hat{\beta}x_0$,于是

$$\mathrm{Var}(\hat{y}_0)=x_0^2\mathrm{Var}(\hat{\beta})=\frac{x_0^2\sigma^2}{\sum_{i=1}^{n}x_i^2}.$$

2: 设回归模型为

$$\begin{cases}y_i=\beta_0+\beta_1x_i+\varepsilon_i,i=1,2,\cdots,n,\\ \text{各 }\varepsilon_i\text{ 独立同分布,其分布为 }N(0,\sigma^2),\end{cases}$$

试求 β_0,β_1 的最大似然估计,它们与其最小二乘估计一致吗?

解 似然函数为

$$L=\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n\exp\left\{-\frac{\sum_{i=1}^{n}(y_i-\beta_0-\beta_1x_i)^2}{2\sigma^2}\right\},$$

其对数似然函数为 $l=-\dfrac{n}{2}\ln\sigma^2-\dfrac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i-\beta_0-\beta_1x_i)^2$(忽略常数项),将其分别对

β_0,β_1 求导并令导函数为 0,得到如下似然方程组(忽略常数因数)

$$\begin{cases}\left.\dfrac{\partial l}{\partial \beta_0}\right|_{\hat{\beta}_0}=\sum\limits_{i=1}^{n}(y_i-\hat{\beta}_0-\hat{\beta}_1x_i)=0,\\ \left.\dfrac{\partial l}{\partial \beta_1}\right|_{\hat{\beta}_1}=\sum\limits_{i=1}^{n}(y_i-\hat{\beta}_0-\hat{\beta}_1x_i)x_i=0,\end{cases}$$

经过整理可以解出

$$\begin{cases}\hat{\beta}_1=l_{xy}/l_{xx},\\ \hat{\beta}_0=\bar{y}-\hat{\beta}_1\bar{x},\end{cases}$$

可以看到 β_0,β_1 的最大似然估计与其最小二乘估计是一致的.

3. 在回归分析计算中,常对数据进行变换

$$\tilde{y}_i=\frac{y_i-c_1}{d_1},\quad \tilde{x}_i=\frac{x_i-c_2}{d_2},\quad i=1,2,\cdots,n,$$

其中 $c_1,c_2,d_1(d_1>0),d_2(d_2>0)$ 是适当选取的常数.

(1) 试建立由原始数据和变换后数据得到的最小二乘估计、总平方和、回归平方和以及残差平方和之间的关系;

(2) 证明:由原始数据和变换后数据得到的 F 检验统计量的值保持不变.

解　(1) 经变换后,各平方和的表达式如下:

$$\bar{\tilde{x}}=\frac{1}{n}\sum_{i=1}^{n}\tilde{x}_i=\frac{1}{d_2}(\bar{x}-c_2),\quad \bar{\tilde{y}}=\frac{1}{n}\sum_{i=1}^{n}\tilde{y}_i=\frac{1}{d_1}(\bar{y}-c_1),$$

$$l_{\tilde{x}\tilde{y}}=\sum_{i=1}^{n}(\tilde{x}_i-\bar{\tilde{x}})(\tilde{y}_i-\bar{\tilde{y}})=\frac{1}{d_1d_2}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})=\frac{1}{d_1d_2}l_{xy},$$

$$l_{\tilde{x}\tilde{x}}=\sum_{i=1}^{n}(\tilde{x}_i-\bar{\tilde{x}})^2=\frac{1}{d_2^2}\sum_{i=1}^{n}(x_i-\bar{x})^2=\frac{1}{d_2^2}l_{xx},$$

$$l_{\tilde{y}\tilde{y}}=\sum_{i=1}^{n}(\tilde{y}_i-\bar{\tilde{y}})^2=\frac{1}{d_1^2}\sum_{i=1}^{n}(y_i-\bar{y})^2=\frac{1}{d_1^2}l_{yy},$$

所以由原始数据和变换后数据得到的最小二乘估计间的关系为

$$\begin{cases}\tilde{\beta}_1=\dfrac{l_{\tilde{x}\tilde{y}}}{l_{\tilde{x}\tilde{x}}}=\dfrac{d_2^2l_{xy}}{d_1d_2l_{xx}}=\dfrac{d_2}{d_1}\hat{\beta}_1,\\ \tilde{\beta}_0=\bar{\tilde{y}}-\tilde{\beta}_1\bar{\tilde{x}}=\dfrac{1}{d_1}(\bar{y}-c_1)-\dfrac{1}{d_1}\hat{\beta}_1(\bar{x}-c_2)=\dfrac{1}{d_1}\hat{\beta}_0-\dfrac{1}{d_1}(c_1-\hat{\beta}_1c_2).\end{cases}$$

在实际应用中,人们往往先由变换后的数据求出 $\tilde{\beta}_1,\tilde{\beta}_0$,然后再据此给出 $\hat{\beta}_1,\hat{\beta}_0$,它们的关系为

$$\hat{\beta}_1=\frac{d_1}{d_2}\tilde{\beta}_1,$$

$$\hat{\beta}_0=d_1\tilde{\beta}_0+c_1\left(1-\frac{d_1/c_1}{d_2/c_2}\tilde{\beta}_1\right),$$

总平方和、回归平方和以及残差平方和分别为

$$S_T = l_{yy} = d_1^2 l_{\tilde{y}\tilde{y}} = d_1^2 \tilde{S}_T,$$

$$S_R = \hat{\beta}_1^2 l_{xx} = \frac{d_1^2}{d_2^2}\tilde{\beta}_1^2 \cdot d_2^2 l_{\tilde{x}\tilde{x}} = d_1^2 \tilde{S}_R,$$

$$S_e = d_1^2 \tilde{S}_e.$$

(2) 由(1)的结果我们知道 $F = \dfrac{S_R}{S_e/(n-2)} = \dfrac{\tilde{S}_R}{\tilde{S}_e/(n-2)} = \tilde{F}$,即说明了由原始数据和变换后数据得到的 F 检验统计量的值保持不变.

4. 对给定的 n 组数据 (x_i, y_i), $i = 1, 2, \cdots, n$,若我们关心的是 y 如何依赖 x 的取值而变动,则可以建立回归方程

$$\hat{y} = a + bx.$$

反之,若我们关心的是 x 如何依赖 y 的取值而变动,则可以建立另一个回归方程

$$\hat{x} = c + dy.$$

试问这两条直线在直角坐标系中是否重合?为什么?若不重合,它们有无交点?若有,试给出交点的坐标.

解 一般不重合.因为回归方程 $\hat{y} = a + bx$ 可化为

$$\hat{y} - \bar{y} = \frac{l_{xy}}{l_{xx}}(x - \bar{x}),$$

而 $\hat{x} = c + dy$ 化为

$$\hat{x} - \bar{x} = \frac{l_{xy}}{l_{yy}}(y - \bar{y}).$$

当且仅当 $l_{xy}^2 = l_{xx} l_{yy}$ 时两条直线重合.我们知道,$l_{xy}^2 = l_{xx} l_{yy}$ 表示相关系数的绝对值为1,即 n 组数据 (x_i, y_i), $i = 1, 2, \cdots, n$ 在一条直线上,这在实际中极其罕见,所以说"一般不重合".

注:不重合时,它们一定有交点 $(\bar{x}, \bar{y})$.

5. 为考察某种维尼纶纤维的耐水性能,安排了一组试验,测得其甲醇浓度 x 及相应的"缩醇化度" y 数据如下:

x	18	20	22	24	26	28	30
y	26.86	28.35	28.75	28.87	29.75	30.00	30.36

(1) 作散点图;

(2) 求样本相关系数;

(3) 建立一元线性回归方程;

(4) 对建立的回归方程作显著性检验($\alpha = 0.01$).

解 (1) 散点图如图8.1,y 有随着 x 增加而增加趋势.

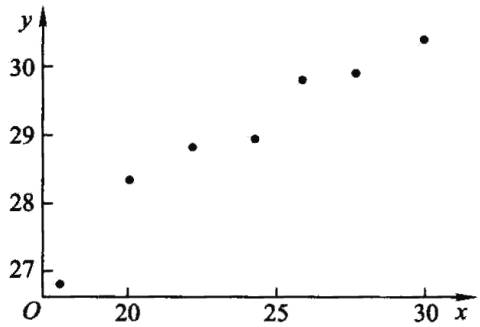

图 8.1

(2) 由样本数据可以算得

$$\sum_{i=1}^{n} x_i = 168, \qquad l_{xx} = \sum_{i=1}^{n} (x_i - \bar{x})^2 = 112,$$

$$\sum_{i=1}^{n} y_i = 202.94, \qquad l_{yy} = \sum_{i=1}^{n} (y_i - \bar{y})^2 = 8.493\ 1,$$

$$l_{xy} = \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}) = 29.6.$$

因此样本相关系数 $r = \dfrac{l_{xy}}{\sqrt{l_{xx} l_{yy}}} = \dfrac{29.6}{\sqrt{112 \times 8.493\ 1}} = 0.959\ 7.$

(3) 应用最小二乘估计公式，$\hat{\beta}_1 = \dfrac{l_{xy}}{l_{xx}} = \dfrac{29.6}{112} = 0.264\ 3$，$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 22.648\ 2$，于是一元线性回归方程为

$$\hat{y} = 22.648\ 2 + 0.264\ 3x.$$

(4) 首先计算几个平方和

$$S_T = l_{yy} = 8.493\ 1,$$

$$S_R = \hat{\beta}_1^2 l_{xx} = 0.264\ 3^2 \times 112 = 7.823\ 7,$$

$$S_e = S_T - S_R = 0.669\ 4,$$

将各平方和移入方差分析表，继续计算，可以得到

来源	平方和	自由度	均方	F 比
回归	7.823 7	1	7.823 7	58.43
残差	0.669 4	5	0.133 9	
总计	8.493 1	6		

若取 $\alpha = 0.01$，查表知 $F_{0.99}(1,5) = 16.26 < 58.43$，拒绝域为 $W = \{F \geqslant 16.26\}$，现检验统计量值落入拒绝域，因此在显著性水平 0.01 下回归方程是显著的. 此处，回归方程显著性检验的 p 值为(用 MATLAB 语句表示)

$$p = 1 - \mathrm{fcdf}(58.43, 1, 5) = 0.000\ 6.$$

6. 测得一组弹簧形变 x(单位：cm) 和相应的外力 y(单位：N) 数据如下：

y	1	1.2	1.4	1.6	1.8	2.0	2.2	2.4	2.8	3.0
x	3.08	3.76	4.31	5.02	5.51	6.25	6.74	7.40	8.54	9.24

由胡克定律知 $\hat{y} = kx$，试估计 k，并在 $x_0 = 2.6$ cm 处给出相应的外力 y_0 的 0.95 预测区间.

解　由本节的第 1 题可以给出 k 的最小二乘估计为

$$\hat{k} = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2} = \frac{128.296}{395.319\ 9} = 0.324\ 5.$$

在第 1 题中已经给出 $\hat{k}$ 的均值和方差分别为 k 和 $\dfrac{\sigma^2}{\sum x_i^2}$，所以 $\hat{k} \sim N\left(k, \dfrac{\sigma^2}{\sum x_i^2}\right)$，从而 $\hat{y}_0 =$

$\hat{k}x_0 \sim N\left(E(y_0), \frac{x_0^2}{\sum x_i^2}\sigma^2\right)$，其中 $E(y_0)=kx_0$，又 $y_0 \sim N(E(y_0),\sigma^2)$，且两者独立，从而有

$$y_0-\hat{y}_0 \sim N\left(0, \left(1+\frac{x_0^2}{\sum x_i^2}\right)\sigma^2\right).$$

因此 y_0 的预测区间为 $(\hat{y}_0-\delta, \hat{y}_0+\delta)$，其中

$$\delta=t_{1-\alpha/2}(n-1)\hat{\sigma}\sqrt{1+\frac{x_0^2}{\sum x_i^2}}, \quad \hat{\sigma}=\sqrt{\frac{\sum(y_i-\hat{k}x_i)^2}{n-1}}.$$

此处，由样本数据可计算得到

$$\begin{aligned} S_e &= \sum(\hat{k}x_i-y_i)^2=\hat{k}^2\sum x_i^2-2\hat{k}\sum x_iy_i+\sum y_i^2 \\ &= 0.324\,5^2\times 395.319\,9-2\times 0.324\,5\times 128.296+41.64 \\ &= 0.003\,2, \end{aligned}$$

从而

$$\hat{\sigma}=\sqrt{0.003\,2/(10-1)}=0.018\,9.$$

而 $x_0=2.6$ cm 相应的外力的预测值为

$$\hat{y}_0=0.324\,5\times 2.6=0.843\,7,$$

当 $\alpha=0.05$ 时，查表知 $t_{0.975}(9)=2.262\,2$，故

$$\delta=2.262\,2\times 0.018\,9\times\sqrt{1+\frac{2.6^2}{395.319\,9}}=0.043\,1.$$

因而得到 y_0 的预测区间为 $[0.843\,7-0.043\,1, 0.843\,7+0.043\,1]=[0.800\,6, 0.886\,8]$.

7. 设由 $(x_i,y_i)(i=1,2,\cdots,n)$ 可建立一元线性回归方程，$\hat{y}_i$ 是由回归方程得到的拟合值，证明：样本相关系数 r 满足关系

$$r^2=\frac{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2},$$

上式也称为回归方程的决定系数.

证 因为 $S_R=\hat{\beta}_1^2 l_{xx}=\frac{l_{xy}^2}{l_{xx}^2}l_{xx}=\frac{l_{xy}^2}{l_{xx}}$，即 $l_{xy}^2=S_R l_{xx}$，将之代入样本相关系数 r 的表达式中，即有

$$r^2=\frac{l_{xy}^2}{l_{xx}l_{yy}}=\frac{S_R l_{xx}}{l_{xx}l_{yy}}=\frac{S_R}{S_T}=\frac{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}{\sum_{i=1}^{n}(y_i-\bar{y})^2}.$$

证明完成.

8. 现收集了 16 组合金钢中的碳含量 x 及强度 y 的数据，求得

$\bar{x}=0.125$, $\bar{y}=45.788\,6$, $l_{xx}=0.302\,4$, $l_{xy}=25.521\,8$, $l_{yy}=2\,432.456\,6$.

(1) 建立 y 关于 x 的一元线性回归方程 $\hat{y}=\hat{\beta}_0+\hat{\beta}_1 x$；

(2) 写出$\hat{\beta}_0$和$\hat{\beta}_1$的分布；

(3) 求$\hat{\beta}_0$和$\hat{\beta}_1$的相关系数；

(4) 列出对回归方程作显著性检验的方差分析表($\alpha = 0.05$)；

(5) 给出β_1的0.95置信区间；

(6) 在$x_0 = 0.15$时求对应的y_0的0.95预测区间.

解　(1) 根据已知数据可以得到回归系数的估计为

$$\hat{\beta}_1 = \frac{l_{xy}}{l_{xx}} = \frac{25.521\ 8}{0.302\ 4} = 84.397\ 5,$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x} = 35.238\ 9.$$

于是y关于x的一元线性回归方程为

$$\hat{y} = 35.238\ 9 + 84.397\ 5x.$$

(2) 我们知道

$$\hat{\beta}_0 \sim N\left(\beta_0, \left(\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}}\right)\sigma^2\right),\ \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right),$$

利用已给数据可计算出

$$\frac{1}{l_{xx}} = \frac{1}{0.302\ 4} = 3.306\ 9,$$

$$\frac{1}{n} + \frac{\bar{x}^2}{l_{xx}} = \frac{1}{16} + \frac{0.125^2}{0.302\ 4} = 0.114\ 2.$$

由此可得到$\hat{\beta}_0$和$\hat{\beta}_1$的分布分别为$\hat{\beta}_0 \sim N(\beta_0, 0.114\ 2\sigma^2)$，$\hat{\beta}_1 \sim N(\beta_1, 3.306\ 9\sigma^2)$，

(3) 由于$\mathrm{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}}{l_{xx}}\sigma^2 = -\frac{0.125}{0.302\ 4}\sigma^2 = -0.413\ 4\sigma^2$，故$\hat{\beta}_0$和$\hat{\beta}_1$的相关系数为

$$r_{\hat{\beta}_0,\hat{\beta}_1} = \frac{\mathrm{Cov}(\hat{\beta}_0, \hat{\beta}_1)}{\sqrt{\mathrm{Var}(\hat{\beta}_0)\mathrm{Var}(\hat{\beta}_1)}} = \frac{-0.413\ 4}{\sqrt{0.114\ 2 \times 3.306\ 9}} = -0.672\ 7.$$

(4) 首先计算三个平方和

$$S_T = l_{yy} = 2\ 432.456\ 6,$$

$$S_R = \frac{l_{xy}^2}{l_{xx}} = 2\ 153.975\ 8,$$

$$S_e = S_T - S_R = 2\ 432.456\ 6 - 2\ 153.975\ 8 = 278.480\ 8.$$

于是可建立如下方差分析表：

来源	平方和	自由度	均方	F比
回归	2 153.975 8	1	2 153.975 8	108.286 2
残差	278.480 8	14	19.891 5	
总计	2 432.456 6	15		

若取显著性水平$\alpha = 0.05$，查表知$F_{0.95}(1,14) = 4.60$，拒绝域为$W = \{F \geqslant 4.60\}$，此处检

验统计量落入拒绝域,因此,在显著性水平 0.05 下回归方程是显著的.此处,回归方程显著性检验的 p 值为

$$p = 1 - \mathrm{fcdf}(108.286\,2, 1, 14) = 5.692\,9 \times 10^{-8},$$

这是一个很小的概率,说明回归方程显著性很高.

(5) 由教材中定理 8.4.1 与定理 8.4.3 知, $\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{l_{xx}}\right)$, $\frac{S_e}{\sigma^2} \sim \chi^2(n-2)$, 且 $\hat{\beta}_1$ 与 $\hat{\sigma}^2 = \frac{1}{n-2} S_e$ 相互独立,因此 β_1 的置信区间为

$$\left(\hat{\beta}_1 - t_{1-\alpha/2}(n-2)\frac{\hat{\sigma}}{\sqrt{l_{xx}}}, \hat{\beta}_1 + t_{1-\alpha/2}(n-2)\frac{\hat{\sigma}}{\sqrt{l_{xx}}}\right),$$

其中 $\hat{\sigma} = \sqrt{19.891\,5} = 4.46$,当 $\alpha = 0.05$ 时, $t_{0.975}(14) = 2.144\,8$,由此可得到 β_1 的置信区间为 $[84.397\,5 - 2.144\,8 \times 4.46/\sqrt{0.302\,4}, 84.397\,5 + 2.144\,8 \times 4.46/\sqrt{0.302\,4}] = [67.002\,2, 101.792\,8]$.

(6) 首先算出 $x_0 = 0.15$ 对应的 y_0 的预测值为

$$\hat{y}_0 = 35.238\,9 + 84.397\,5 \times 0.15 = 47.898\,5.$$

而

$$\begin{aligned}\delta = \delta(x_0) &= t_{1-\alpha/2}(n-2)\hat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{l_{xx}}} \\ &= 2.144\,8 \times 4.46 \times \sqrt{1 + \frac{1}{16} + \frac{(0.15 - 0.125)^2}{0.302\,4}} \\ &= 9.869\,8,\end{aligned}$$

所以 $x_0 = 0.15$ 时求对应的 y_0 的 0.95 预测区间为 $[47.898\,5 - 9.869\,8, 47.898\,5 + 9.869\,8] = [38.028\,7, 57.768\,3]$.

9. 设回归模型为 $\begin{cases} y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \\ \varepsilon_i \sim N(0, \sigma^2), \end{cases}$ 现收集了 15 组数据,经计算有

$$\bar{x} = 0.85,\ \bar{y} = 25.60,\ l_{xx} = 19.56,\ l_{xy} = 32.54,\ l_{yy} = 46.74,$$

后经核对,发现有一组数据记录错误,正确数据为(1.2,32.6),记录为(1.5,32.3).

(1) 求 β_0, β_1 修正后的 LSE;

(2) 对回归方程作显著性检验($\alpha = 0.05$);

(3) 若 $x_0 = 1.1$,给出对应响应变量的 0.95 预测区间.

解 (1) 由于有一组数据记录错误,应将 $\bar{x}, \bar{y}, l_{xx}, l_{yy}, l_{xy}$ 作修正,修正后的量分别记为 $x_i', y_i', \bar{x}', \bar{y}', l_{xx}', l_{yy}', l_{xy}'$,则

$$\bar{x}' = \bar{x} + \frac{1}{15}(1.2 - 1.5) = 0.83,$$

$$\bar{y}' = \bar{y} + \frac{1}{15}(32.6 - 32.3) = 25.62,$$

$$l'_{xx} = \sum x_i'^2 - n\bar{x}'^2 = l_{xx} + n\bar{x}^2 - n\bar{x}'^2 - 1.5^2 + 1.2^2$$
$$= 19.56 + 10.837\ 5 - 10.333\ 5 - 2.25 + 1.44 = 19.254,$$

$$l'_{yy} = \sum y_i'^2 - n\bar{y}'^2 = l_{yy} + n\bar{y}^2 - n\bar{y}'^2 - 32.3^2 + 32.6^2$$
$$= 46.74 + 9\ 830.4 - 9\ 845.766 - 1\ 043.29 + 1\ 062.76 = 50.844,$$

$$l'_{xy} = \sum x_i' y_i' - n\bar{x}'\bar{y}' = l_{xy} + n\bar{x}\bar{y} - n\bar{x}'\bar{y}' - 1.5 \times 32.3 + 1.2 \times 32.6$$
$$= 32.54 + 326.4 - 318.969 - 48.45 + 39.12 = 30.641.$$

根据修正后的数据可计算得到 β_0, β_1 的 LSE 为

$$\hat{\beta}_1 = \frac{l'_{xy}}{l'_{xx}} = 1.591\ 4,$$

$$\hat{\beta}_0 = \bar{y}' - \hat{\beta}_1 \bar{x}' = 24.299\ 1.$$

(2) 利用修正后的数据可计算三个平方和为

$$S_T = l'_{yy} = 50.844, \quad f_T = 14,$$

$$S_R = \frac{(l'_{xy})^2}{l'_{xx}} = 48.762\ 4, \quad f_R = 1,$$

$$S_e = S_T - S_R = 2.081\ 6, \quad f_e = 13.$$

因而检验统计量 $F = \frac{MS_R}{MS_e} = \frac{48.762\ 4}{2.081\ 6/13} = \frac{48.762\ 4}{0.160\ 1} = 304.574\ 6$，若取显著性水平 $\alpha = 0.05$，查表知 $F_{0.95}(1,13) = 4.67$，拒绝域为 $W = \{F \geqslant 4.67\}$，由于检验统计量落入拒绝域，因此回归方程是显著的.此处，回归方程显著性检验的 p 值为

$$p = 1 - \mathrm{fcdf}(304.574\ 6, 1, 13) = 2.104\ 3 \times 10^{-10}.$$

这是一个非常小的概率，说明回归方程显著性很高.

(3) 对于 $x_0 = 1.1$，其对应响应变量的预测值为

$$\hat{y}_0 = 24.299\ 1 + 1.591\ 4 \times 1.1 = 26.049\ 6,$$

而 $\hat{\sigma} = \sqrt{0.160\ 1} = 0.400\ 1$，查表知 $t_{0.975}(13) = 2.160\ 4$，

$$\delta(x_0) = 2.160\ 4 \times 0.400\ 1\sqrt{1 + \frac{1}{15} + \frac{(1.1 - 0.83)^2}{19.254}} = 0.894\ 3,$$

因此响应变量的 0.95 预测区间为 $[26.049\ 6 - 0.894\ 3, 26.049\ 6 + 0.894\ 3] = [25.155\ 3, 26.943\ 9]$.

10. 在生产中积累了 32 组某种铸件在不同腐蚀时间 x 下腐蚀深度 y 的数据，求得回归方程为

$$\hat{y} = -0.444\ 1 + 0.002\ 263x,$$

且误差方差的无偏估计为 $\hat{\sigma}^2 = 0.001\ 452$，总偏差平方和为 0.124 6.

(1) 对回归方程作显著性检验($\alpha = 0.05$)，列出方差分析表；

(2) 求样本相关系数；

(3) 若腐蚀时间 $x = 870$,试给出 y 的 0.95 近似预测区间.

解 (1) 由已给条件可以得到 $S_T = 0.124\,6$,$S_e = (n-2)\hat{\sigma}^2 = 0.043\,56$,因此 $S_R = 0.124\,6 - 0.043\,56 = 0.081\,04$,把这些平方和移至如下方差分析表上,继续计算

来源	平方和	自由度	均方	F 比
回归	0.081 04	1	0.081 04	55.812 7
残差	0.043 56	30	0.001 452	
总计	0.124 6	31		

若取显著性水平 $\alpha = 0.05$,则 $F_{0.95}(1,30) = 4.17 < 55.812\,7$,因此回归方程是显著的,此处,回归方程检验的 p 值为

$$p = 1 - \mathrm{fcdf}(55.812\,7,1,30) = 2.510\,1 \times 10^{-8}.$$

这是一个很小的概率,说明回归方程显著性很高.

(2) 样本相关系数 $r = \sqrt{\dfrac{S_R}{S_T}} = \sqrt{\dfrac{0.081\,04}{0.124\,6}} = 0.806\,5.$

(3) 若腐蚀时间 $x = 870$,则 y 的预测值为

$$\hat{y} = -0.444\,1 + 0.002\,263 \times 870 = 1.524\,7.$$

其 0.95 近似预测区间的半径为

$$\delta \approx \hat{\sigma} u_{0.975} = \sqrt{0.001\,452} \times 1.96 = 0.074\,7,$$

从而 y 的 0.95 近似预测区间为 $[1.524\,7 - 0.074\,7, 1.524\,7 + 0.074\,7] = [1.450\,0, 1.599\,4]$.

11. 我们知道营业税税收总额 y 与社会商品零售总额 x 有关.为能从社会商品零售总额去预测税收总额,需要了解两者之间的关系.现收集了如下 9 组数据:

单位:亿元

序号	社会商品零售总额	营业税税收总额
1	142.08	3.93
2	177.30	5.96
3	204.68	7.85
4	242.68	9.82
5	316.24	12.50
6	341.99	15.55
7	332.69	15.79
8	389.29	16.39
9	453.40	18.45

(1) 画散点图;

(2) 建立一元线性回归方程,并作显著性检验(取 $\alpha = 0.05$),列出方差分析表;

(3) 若已知某年社会商品零售额为 300 亿元,试给出营业税税收总额的概率为 0.95 的预测区间;

(4) 若已知回归直线过原点，试求回归方程，并在显著性水平 0.05 下作显著性检验.

解　(1) 散点图如图 8.2.

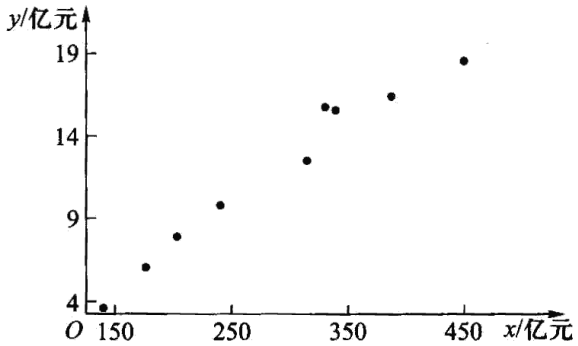

图 8.2

(2) 类似的问题我们已经做过多次，此处我们使用 MATLAB 统计软件来进行，把数据输入到 worksheet 中，在选项 stat 中选择 regression.在弹出的对话框中将因变量和自变量选入即可，得到的回归方程为 $\hat{y} = -2.26 + 0.048\,7x$，方差分析表如下：

来源	平方和	自由度	均方和	F 比	p 值
回归	203.40	1	203.40	180	0.000
残差	7.93	7	1.13		
总计	211.33	8			

根据以上结果，在显著性水平 $\alpha = 0.05$ 下，回归方程是显著的.

(3) 按照(2) 的步骤进入 regression 对话框，点击 options 后，在 prediction of new observation 中给出自变量 x 的值 300，就可以得到 y 的 0.95 预测区间为[9.688，14.999].

(4) 若想要拟合不带截距的过原点的回归方程，只要在 options 中在 Fit intercept 选项中不选，即可得到过原点的回归直线为 $\hat{y} = 0.041\,7x$，此时检验的 p 值为 0.000，因此在显著性水平 $\alpha = 0.05$ 下，过原点的回归方程是显著的.

补充习题及解答

12. 求一回归直线 $y = A + Bx$，使所有样本点 $(x_1, y_1), (x_2, y_2), \cdots, (x_n, y_n)$ 到该直线的垂直距离平方和最小.

解　点 (x_i, y_i) 到直线 $y = A + Bx$ 的垂直距离的平方为

$$d_i^2 = \frac{(y_i - A - Bx_i)^2}{1 + B^2}.$$

如今要求 A 与 B，使

$$\varphi(A, B) = \sum_{i=1}^{n} \frac{(y_i - A - Bx_i)^2}{1 + B^2}.$$

最小，使用微分法，并命其导数为零，可得如下两个方程：

$$\sum_{i=1}^{n}(y_i-\hat{A}-\hat{B}x_i)=0 \quad 或 \quad \bar{y}-\hat{A}-\hat{B}\bar{x}=0, \qquad ①$$

$$(1+\hat{B}^2)\sum_{i=1}^{n}(y_i-\hat{A}-\hat{B}x_i)x_i+\hat{B}\sum_{i=1}^{n}(y_i-\hat{A}-\hat{B}x_i)^2=0, \qquad ②$$

由①式可得 $\hat{A}=\bar{y}-\hat{B}\bar{x}$ 并将其代入②式,可得

$$(1+\hat{B}^2)\sum_{i=1}^{n}[(y_i-\bar{y})-\hat{B}(x_i-\bar{x})]x_i+\hat{B}\sum_{i=1}^{n}[(y_i-\bar{y})-\hat{B}(x_i-\bar{x})]^2=0,$$

注意到恒等式

$$\sum_{i=1}^{n}[(y_i-\bar{y})-\hat{B}(x_i-\bar{x})]\bar{x}=0,$$

可将上式化为

$$(1+\hat{B}^2)\sum_{i=1}^{n}[(y_i-\bar{y})-\hat{B}(x_i-\bar{x})](x_i-\bar{x})+\hat{B}\sum_{i=1}^{n}[(y_i-\bar{y})-\hat{B}(x_i-\bar{x})]^2=0,$$

使用相同的记号

$$l_{xx}=\sum_{i=1}^{n}(x_i-\bar{x})^2,\quad l_{yy}=\sum_{i=1}^{n}(y_i-\bar{y})^2,\quad l_{xy}=\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y}),$$

则上式可表示为

$$(1+\hat{B}^2)(l_{xy}-\hat{B}l_{xx})+\hat{B}(l_{yy}+\hat{B}^2l_{xx}-2\hat{B}l_{xy})=0.$$

整理后可得如下 $\hat{B}$ 的二次方程

$$l_{xy}\hat{B}^2+(l_{xx}-l_{yy})\hat{B}-l_{xy}=0.$$

由于判别式 $\Delta=(l_{xx}-l_{yy})^2+4l_{xy}^2\geqslant 0$,故此二次方程有实根.

$$\hat{B}=\frac{(l_{yy}-l_{xx})\pm\sqrt{(l_{xx}-l_{yy})^2+4l_{xy}^2}}{2l_{xy}},$$

这里 $\hat{B}$ 是斜率,根据散点图上的上升趋势或下降趋势选择 $\hat{B}$ 表达式中的 ±号.

讨论:这样一来,通过二维样本 $(x_i,y_i)(i=1,2,\cdots,n)$ 建立一元线性回归方程有两个标准:

(1) 使残差平方和 $\sum_{i=1}^{n}(y_i-a-bx_i)^2$ 达到最小;

(2) 使到回归方程的垂直距离平方和 $\dfrac{\sum_{i=1}^{n}(y_i-A-Bx_i)^2}{1+B^2}$ 达到最小.

它们导出的回归系数估计也是不同的,但两条回归直线都通过点 $(\bar{x},\bar{y})$.哪一个好呢?这要看你使用什么标准,实际情况是(1)的理论已很完善,使用的人已很多,效果也很好,而(2)的研究甚少,几乎还无人在实际中使用.实际研究表明,当相关系数的绝对值 $|r|$ 接近于 1 时,两个标准下得到的回归系数都很接近,即 $a\approx A,b\approx B$.倘若 $|r|$ 远离 1 时,两个标准下得到的回归系数相差就大了,接下去的两个习题分别说明这个现象.

13. 在用光电比色计检验尿汞时,对给定的尿汞含量 x(单位:mg/l),消光系数 y 服从正态分布,且方差与 x 无关,观测得如下数据:

尿汞含量 x	2	4	6	8	10
消光系数 y	64	138	205	285	360

试用两个标准分别建立一元回归方程.

解　由这组数据可计算得到

$$\bar{x} = 6, \quad \bar{y} = 210.4,$$

$$l_{xx} = 40, \quad l_{yy} = 54\ 649.2, \quad l_{xy} = 1\ 478.$$

(1) 用残差平方和最小的标准,可得两回归系数为

$$\hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{1\ 478}{40} = 36.95,$$

$$\hat{a} = \bar{y} - \hat{b}\,\bar{x} = 210.4 - 36.95 \times 6 = -11.3.$$

(2) 用到回归直线垂直距离平方和最小的标准(见补充习题 12),可得两回归系数为

$$\hat{B} = \frac{54\ 649.2 - 40 + \sqrt{(54\ 649.2 - 40)^2 + 4 \times 1\ 478^2}}{2 \times 1\ 478} = 36.975\ 1,$$

$$\hat{A} = 210.4 - 36.975\ 1 \times 6 = -11.450\ 6.$$

比较两个标准下的结果,可见 $\hat{a} \approx \hat{A}, \hat{b} \approx \hat{B}$,这是因为其相关系数 $r = 0.999\ 66$,很接近 1.

14. 某合金钢的抗拉强度 y 与碳含量 x 有关,现有 92 炉钢样数据,从中算得

$$\bar{x} = 0.125\ 5, \quad \bar{y} = 45.80,$$

$$l_{xx} = 0.301\ 8, \quad l_{yy} = 2\ 981, \quad l_{xy} = 26.70,$$

试用两个标准分别建立一元回归方程.

解　(1) 用残差平方和最小的标准,可得两回归系数为

$$\hat{b} = \frac{l_{xy}}{l_{xx}} = \frac{26.7}{0.301\ 8} = 88.47,$$

$$\hat{a} = \bar{y} - \hat{b}\,\bar{x} = 45.80 - 88.47 \times 0.125\ 5 = 34.70.$$

(2) 用到回归直线垂直距离平方和最小的标准(见补充习题 12),可得两回归系数为

$$\hat{B} = \frac{(2\ 981 - 0.301\ 8) + \sqrt{(2\ 981 - 0.301\ 8)^2 + 4 \times 26.7^2}}{2 \times 26.70} = 111.645\ 6,$$

$$\hat{A} = 45.80 - 111.645\ 6 \times 0.125\ 5 = 31.788\ 5.$$

比较两种标准下的结果,可见 $\hat{a}$ 与 $\hat{A}$,$\hat{b}$ 与 $\hat{B}$ 之间相差较大,这是因其相关系数 $r = 0.890\ 2$ 与 1 有较大差距.

§8.5　一元非线性回归

内容概要

1. 非线性函数形式　根据二维样本的散点图确定可能的非线性函数形式,部分